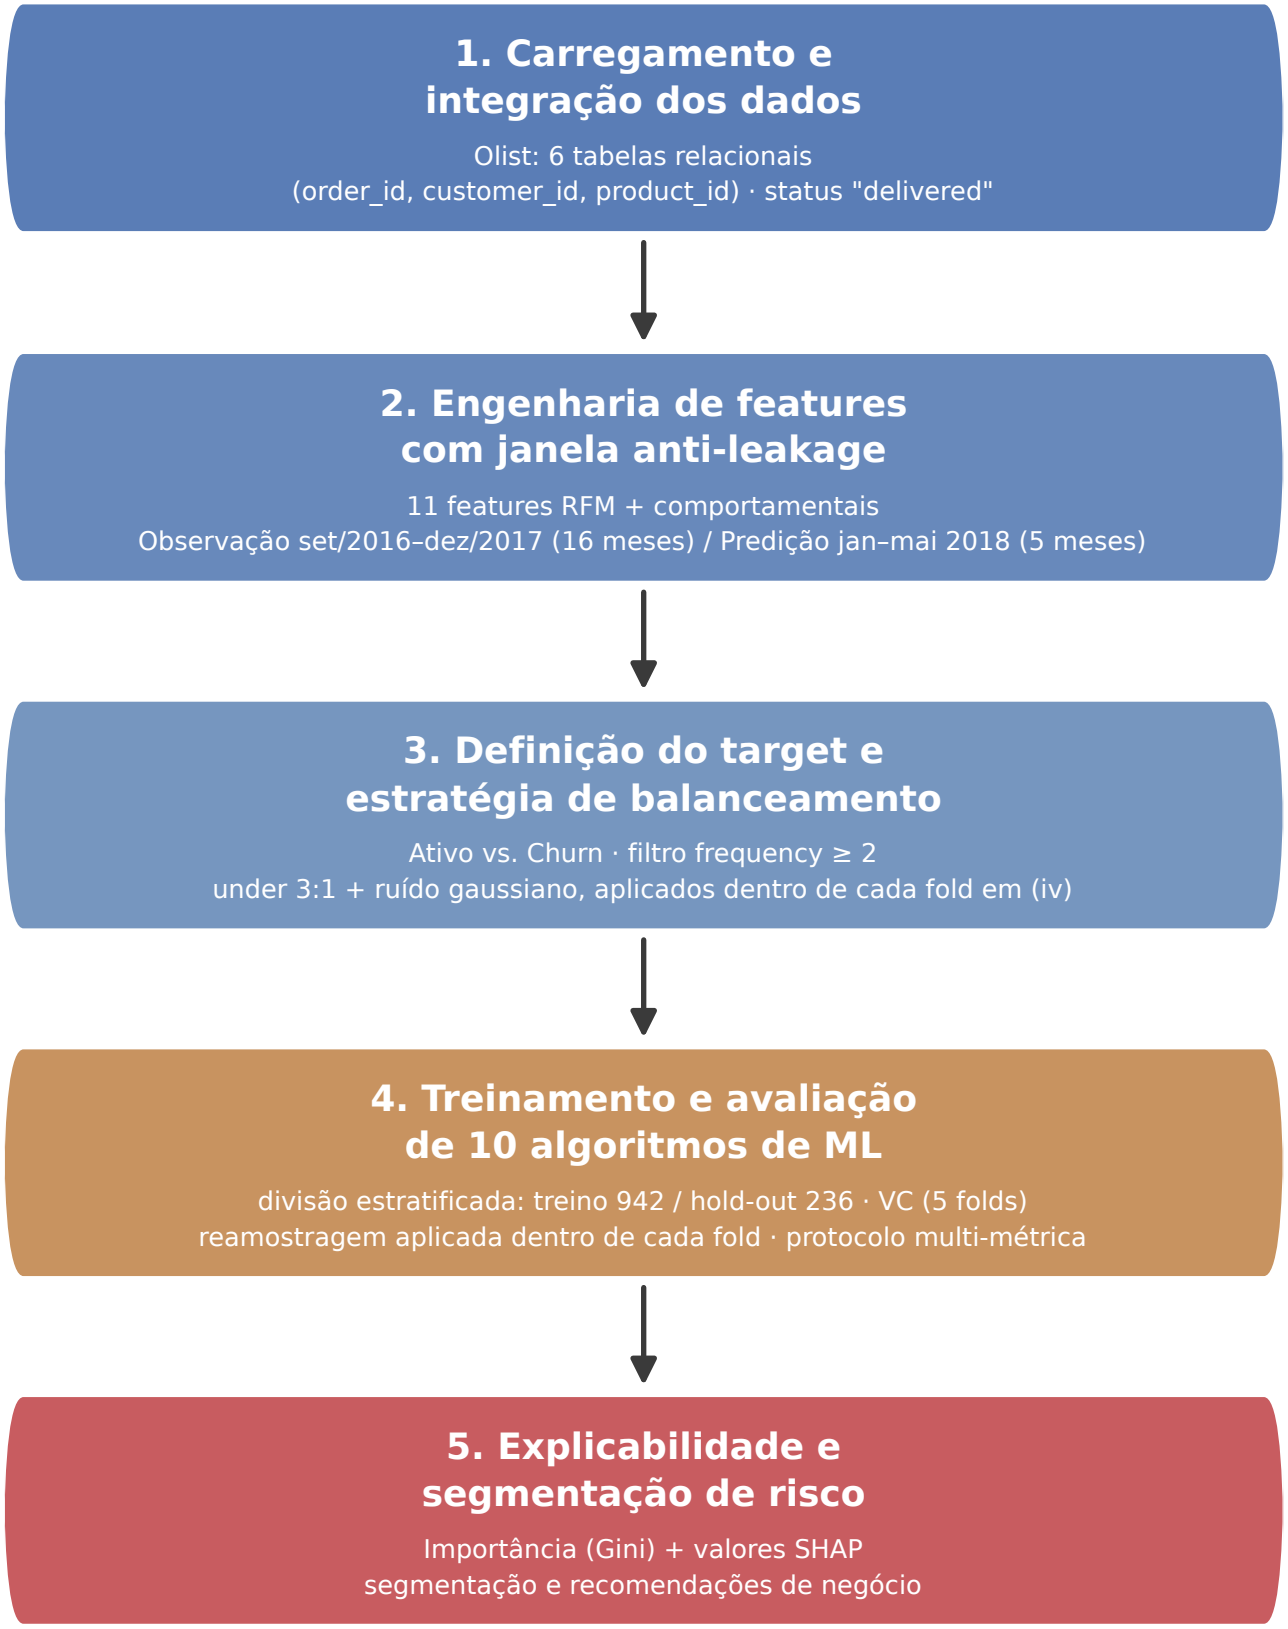
1. Carregamento e integração dos dados
Olist: 6 tabelas relacionais
(order_id, customer_id, product_id) · status "delivered"
2. Engenharia de features com janela anti-leakage
11 features RFM + comportamentais
Observação set/2016–dez/2017 (16 meses) / Predição jan–mai 2018 (5 meses)
3. Definição do target e estratégia de balanceamento
Ativo vs. Churn · filtro frequency ≥ 2
under 3:1 + ruído gaussiano, aplicados dentro de cada fold em (iv)
4. Treinamento e avaliação de 10 algoritmos de ML
divisão estratificada: treino 942 / hold-out 236 · VC (5 folds)
reamostragem aplicada dentro de cada fold · protocolo multi-métrica
5. Explicabilidade e segmentação de risco
Importância (Gini) + valores SHAP
segmentação e recomendações de negócio