UNIVERSIDADE DE SÃO PAULO
Instituto de Ciências Matemáticas e de Computação

Análise Preditiva de Churn de Clientes utilizando Machine Learning

Fabiano Rodrigues Ugulino

Monografia - MBA em Inteligência Artificial e Big Data

ICMC USP SÃO CARLOS

SERVIÇO DE PÓS-GRADUAÇÃO DO ICMC-USP

Data de Depósito:

Assinatura: _____

Fabiano Rodrigues Ugulino

Análise Preditiva de Churn de Clientes utilizando Machine Learning

Monografia apresentada ao Departamento de Ciências de Computação do Instituto de Ciências Matemáticas e de Computação, Universidade de São Paulo - ICMC/USP, como parte dos requisitos para obtenção do título de Especialista em Inteligência Artificial e Big Data.

Área de concentração: Inteligência Artificial

Orientadora: Profa. Dra. Cibele M. Russo

Versão original

São Carlos

2026

AUTORIZO A REPRODUÇÃO E DIVULGAÇÃO TOTAL OU PARCIAL DESTE TRABALHO, POR QUALQUER MEIO CONVENCIONAL OU ELETRÔNICO PARA FINS DE ESTUDO E PESQUISA, DESDE QUE CITADA A FONTE.

Ficha catalográfica elaborada pela Biblioteca Prof. Achille Bassi, ICMC/USP, com os dados fornecidos pelo(a) autor(a)

Ugulino, Fabiano
Análise Preditiva de Churn de Clientes utilizando Machine Learning / Fabiano Rodrigues Ugulino ; orientadora Cibele M. Russo. – São Carlos, 2026.
85 p. : il. (algumas color.) ; 30 cm.

Monografia (MBA em Inteligência Artificial e Big Data) – Instituto de Ciências Matemáticas e de Computação, Universidade de São Paulo, 2026.

1. Churn. 2. Machine Learning. 3. Random Forest. 4. RFM. 5. E-commerce. I. Russo, Cibele M., orient. II. Título.

Fabiano Rodrigues Ugulino

Predictive Analysis of Customer Churn using Machine Learning

Monograph presented to the Departamento de Ciências de Computação do Instituto de Ciências Matemáticas e de Computação, Universidade de São Paulo - ICMC/USP, as part of the requirements for obtaining the title of Specialist in Artificial Intelligence and Big Data.

Concentration area: Artificial Intelligence

Advisor: Profa. Dra. Cibele M. Russo

Original version

São Carlos

2026

À minha família, pelo apoio incondicional em cada etapa desta jornada.

AGRADECIMENTOS

À minha orientadora, Profa. Dra. Cibele M. Russo, pela orientação precisa, pela paciência e pelos ensinamentos fundamentais que guiaram a condução deste trabalho. Sua dedicação e suporte acadêmico foram essenciais para o sucesso desta jornada.

Ao Instituto de Ciências Matemáticas e de Computação (ICMC/USP), pelo acolhimento e pela excelência do programa, que proporcionou a base necessária para o desenvolvimento desta pesquisa.

À minha família, pelo apoio incondicional, compreensão e carinho durante todos os momentos de dedicação ao curso, sendo o meu porto seguro e a minha maior motivação para superar os desafios.

Aos meus colegas de jornada no MBA em Inteligência Artificial e Big Data, pelas trocas de experiências e pelo incentivo constante.

A todos que, direta ou indiretamente, contribuíram para a realização deste trabalho e para o meu crescimento profissional e pessoal.

"Em Deus nós confiamos;
todos os outros devem trazer dados."
W. Edwards Deming

RESUMO

UGULINO, F. **Análise Preditiva de Churn de Clientes utilizando Machine Learning**. 2026. 85 p. Monografia (MBA em Inteligência Artificial e Big Data) - Instituto de Ciências Matemáticas e de Computação, Universidade de São Paulo, São Carlos, 2026.

A retenção de clientes constitui fator crítico para a sustentabilidade financeira de organizações de comércio eletrônico, uma vez que o custo de aquisição de novos clientes supera substancialmente o de manutenção dos existentes. A capacidade de antecipar quais clientes apresentam maior propensão ao abandono (churn) torna-se decisiva para a adoção de estratégias proativas de relacionamento. O objetivo deste trabalho é identificar e caracterizar, de forma antecipada e a partir de dados históricos de transações, o perfil dos clientes com maior risco de abandono e o dos que retornam à plataforma. Propõe-se um pipeline completo de análise preditiva aplicado a um conjunto de dados públicos do comércio eletrônico brasileiro (Olist), fundamentado na engenharia de variáveis comportamentais e em uma estratégia de janelas temporais que previne o vazamento de informação (data leakage) entre os períodos de observação e predição. O estudo compara sistematicamente diferentes algoritmos de aprendizado de máquina, adota técnicas para lidar com o desbalanceamento acentuado entre as classes e emprega um protocolo de avaliação com múltiplas métricas adequadas a esse cenário, complementado por análise de explicabilidade (XAI). Os principais resultados demonstram que modelos ensemble baseados em árvores alcançam, a partir de variáveis comportamentais simples, o melhor desempenho discriminativo entre os algoritmos avaliados (ROC-AUC de 0,81 no conjunto de teste, com média de 0,67 em trinta partições independentes), e que a diversidade de categorias de compra figura entre os fatores mais associados à retenção, mantendo-se entre os três principais preditores em 29 de trinta partições, achado de implicação direta para estratégias de fidelização. A escolha do modelo adotado é sustentada pela qualidade da ordenação dos clientes por risco, verificada em cobertura fixa contra os dois modelos concorrentes de melhor desempenho sob métricas de decisão binária. O trabalho contribui ainda com a validação empírica das decisões metodológicas adotadas ao longo do pipeline.

Palavras-chave: churn; aprendizado de máquina; retenção de clientes; RFM; e-commerce; explicabilidade.

ABSTRACT

UGULINO, F. **Predictive Analysis of Customer Churn using Machine Learning**. 2026. 85 p. Monograph (MBA in Artificial Intelligence and Big Data) - Instituto de Ciências Matemáticas e de Computação, Universidade de São Paulo, São Carlos, 2026.

Customer retention is a critical factor for the financial sustainability of e-commerce organizations, since the cost of acquiring new customers substantially exceeds that of retaining existing ones. The ability to anticipate which customers are most likely to abandon the platform (churn) becomes decisive for adopting proactive relationship strategies. The objective of this work is to identify and characterize, in advance and from historical transaction data, the profile of the customers at greatest risk of abandonment and that of those who return to the platform. A complete predictive analysis pipeline is proposed and applied to a public Brazilian e-commerce dataset (Olist), grounded in the engineering of behavioral features and in a temporal windowing strategy that prevents data leakage between the observation and prediction periods. The study systematically compares different machine learning algorithms, adopts techniques to handle the marked class imbalance, and employs an evaluation protocol with multiple metrics suitable for imbalanced contexts, complemented by explainability analysis (XAI). The main results show that ensemble tree-based models achieve, from simple behavioral features, the best discriminative performance among the algorithms evaluated (ROC-AUC of 0.81 on the test set, with a mean of 0.67 across thirty independent partitions), and that the diversity of purchase categories ranks among the factors most associated with retention, remaining among the three leading predictors in 29 out of thirty partitions, a finding with direct implications for loyalty strategies. The choice of the production model is supported by the quality of the risk ranking of customers, verified at fixed coverage against the two competing models with the best performance under binary decision metrics. The work further contributes with the empirical validation of the methodological decisions adopted throughout the pipeline.

Keywords: churn; machine learning; customer retention; RFM; e-commerce; explainability.

LISTA DE FIGURAS

Figura 1 – Pipeline metodológico do estudo 28
Figura 2 – Estratégia de janela temporal dupla (anti-leakage) 30
Figura 3 – Análise exploratória de recência 40
Figura 4 – Análise exploratória de frequência 40
Figura 5 – Análise exploratória de review score 41
Figura 6 – Proporção Churn versus Ativo 41
Figura 7 – Matrizes de confusão do Logistic Regression, Decision Tree, Random Forest, Extra Trees e Gradient Boosting no conjunto de teste (limiar out-of-fold) 55
Figura 8 – Matrizes de confusão do HistGradient Boosting, AdaBoost, KNN, Naive Bayes e SVM no conjunto de teste (limiar out-of-fold) 56
Figura 9 – Critério de escolha do ponto de corte em função do limiar (Random Forest) 57
Figura 10 – Curva Precision-Recall por classe, independente do limiar (Random Forest) 57
Figura 11 – Importância das features por impureza de Gini (Random Forest) 61
Figura 12 – Top-5 Features por impureza de Gini (Random Forest) 62
Figura 13 – Importância média |SHAP| das features (Random Forest) 63
Figura 14 – Valores SHAP (beeswarm) das features no conjunto de teste 65
Figura 15 – Dependence plots da feature frequency no SHAP (Random Forest) . . 67
Figura 16 – Dependence plots da feature recency_days no SHAP (Random Forest) 68
Figura 17 – Dependence plots da feature n_categories no SHAP (Random Forest) . 69
Figura 18 – Decomposição SHAP da predição para o cliente mais próximo do centroide da classe Ativo 70
Figura 19 – Decomposição SHAP da predição para o cliente mais próximo do centroide da classe Churn 71
Figura 20 – Distribuição dos scores de probabilidade de churn e limiares de segmentação nos três modelos 72

LISTA DE TABELAS

Tabela 1 – Features RFM construídas na janela de observação (até dez/2017) . . . 30
Tabela 2 – Comparação empírica de estratégias de balanceamento (split de referência) 42
Tabela 3 – Robustez das estratégias de balanceamento em trinta divisões estratificadas . . . 42
Tabela 4 – Benchmark comparativo dos dez algoritmos de Machine Learning . . . 44
Tabela 5 – Validação de representatividade via PSI e KS-test (features numéricas) 58
Tabela 6 – Importância das cinco principais features do modelo Random Forest (Gini) . . . 60
Tabela 7 – Posição e participação relativa das features no ranking por importância média |SHAP| nos três modelos . . . 64
Tabela 8 – Segmentação de risco de churn e ações recomendadas por segmento . . 73

LISTA DE QUADROS

Quadro 1 – Análise comparativa de estratégias de balanceamento de classes 33
Quadro 2 – Hierarquia das métricas de avaliação segundo o papel na seleção . . . 35
Quadro 3 – Análise de vantagens e desvantagens dos três modelos de melhor desempenho 47

LISTA DE ABREVIATURAS E SIGLAS

ABNT	Associação Brasileira de Normas Técnicas
AdaBoost	*Adaptive Boosting*
AP	*Average Precision* (área sob a curva *Precision-Recall*)
AUC	*Area Under the ROC Curve*
Churn	Rotatividade de clientes
Extra Trees	*Extremely Randomized Trees*
G-Mean	*Geometric Mean* (média geométrica de sensibilidade e especificidade)
Gini	Impureza de Gini
Gradient Boosting	*Gradient Boosting Machine*
HistGradient Boosting	*Histogram-based Gradient Boosting*
ICMC	Instituto de Ciências Matemáticas e de Computação
Kappa	Kappa de Cohen
KNN	*K-Nearest Neighbors*
KS-test	*Kolmogorov-Smirnov Test*
MBA	*Master of Business Administration*
MCC	*Matthews Correlation Coefficient* (Coeficiente de Correlação de Matthews)
Naive Bayes	*Naive Bayes* (Classificador Bayesiano ingênuo)
Olist	Olist (Plataforma de *e-commerce*)
PSI	*Population Stability Index*
RFM	*Recency, Frequency, Monetary* (Recência, Frequência e Valor Monetário)
ROC-AUC	*Receiver Operating Characteristic - Area Under the Curve*
SHAP	*SHapley Additive exPlanations*
SVM	*Support Vector Machine*
USP	Universidade de São Paulo
XAI	*Explainable Artificial Intelligence* (Inteligência Artificial Explicável)

SUMÁRIO

1 INTRODUÇÃO 18
1.1 Contexto 18
1.2 Problema de Pesquisa 19
1.3 Justificativa e Motivação 19
1.4 Objetivo Geral 20
1.5 Objetivos Específicos 20
2 REFERENCIAL TEÓRICO 22
2.1 Customer Churn: Conceituação e Importância Estratégica 22
2.2 Metodologia RFM e Engenharia de Features 22
2.3 Algoritmos de Machine Learning para Classificação 23
2.4 Desbalanceamento de Classes e Técnicas de Balanceamento 24
2.5 Métricas de Avaliação para Dados Desbalanceados 24
2.6 Explicabilidade de Modelos: Valores SHAP e Importância de Features 25
2.7 Estudos Relacionados 26
3 METODOLOGIA 28
3.1 Base de Dados e Integração 29
3.2 Estratégia Temporal Anti-Leakage 29
3.3 Engenharia de Features RFM 30
3.4 Target e Balanceamento de Classes 32
3.5 Protocolo de Treinamento e Avaliação 34
4 AVALIAÇÃO EXPERIMENTAL 39
4.1 Análise Exploratória dos Dados 39
4.2 Comparação Empírica de Estratégias de Balanceamento 42
4.3 Benchmark Comparativo de Algoritmos 44
4.4 Correlação entre Rankings de Métricas 53
4.5 Análise do Limiar de Classificação e Curvas de Desempenho 53
4.6 Validação da Representatividade do Balanceamento 58
4.6.1 Discussão: representatividade e clientes informativos 59
4.7 Interpretabilidade: Importância das Features e SHAP 59
4.7.1 Perfil do cliente que retorna: leitura sob a ótica da retenção 65
4.8 Segmentação de Risco e Recomendações de Negócio 71
5 CONCLUSÃO 75
REFERÊNCIAS 80

DECLARAÇÃO DE USO DE INTELIGÊNCIA ARTIFICIAL 83

1 INTRODUÇÃO

1.1 Contexto

A aceleração da transformação digital nas últimas décadas modificou estruturalmente os padrões de consumo, consolidando o comércio eletrônico como canal de crescente relevância em diversos setores da economia global. Esse fenômeno, caracterizado pela migração de transações dos ambientes físicos para plataformas digitais, ampliou significativamente tanto a oferta de produtos e serviços quanto o poder de escolha dos consumidores. Em consequência, intensificou-se a competição entre organizações, que passaram a disputar clientes em mercados marcados pela elevada transparência de preços, facilidade de comparação e baixo custo de migração entre concorrentes (TURBAN *et al.*, 2018).

Nesse contexto, a retenção de clientes emergiu como fator crítico de vantagem competitiva, uma vez que o customer churn, definido como o abandono ou interrupção do relacionamento comercial por parte do cliente, representa um dos principais riscos à sustentabilidade financeira dos negócios digitais. Estudos indicam que tanto as taxas quanto os próprios critérios de classificação de churn variam consideravelmente entre setores (IMANI *et al.*, 2025), e que a aquisição de clientes no comércio eletrônico é particularmente custosa, tornando muitas relações não lucrativas em seus primeiros anos e conferindo à retenção papel central na geração de resultados (REICHHELD; SCHEFTER, 2000).

Apesar da relevância do tema, observa-se a presumível dominância de abordagens reativas na gestão do churn em organizações de e-commerce, nas quais as ações de retenção são implementadas apenas após a perda efetiva do cliente, comprometendo a eficácia e o custo-benefício das estratégias organizacionais (HADDEN *et al.*, 2007; MATUSZELAŃSKI; KOPCZEWSKA, 2022). A incapacidade de identificar, de forma antecipada, os clientes com maior propensão ao abandono resulta em perdas financeiras evitáveis e na subutilização de recursos destinados às iniciativas de marketing e relacionamento (NESLIN *et al.*, 2006).

Diante desse cenário, técnicas de Machine Learning têm se consolidado como abordagens eficazes para a construção de modelos preditivos de churn, permitindo identificar padrões complexos e não lineares em grandes volumes de dados históricos e comportamentais (IMANI *et al.*, 2025). A aplicação dessas técnicas viabiliza a transição de uma postura reativa para um modelo proativo de gestão do relacionamento com o cliente, no qual ações de retenção são direcionadas com maior precisão, fundamentadas em evidências quantitativas extraídas dos próprios dados transacionais da organização (MANZOOR *et al.*, 2024).

Adicionalmente, a incorporação de técnicas de Inteligência Artificial Explicável (XAI), como os valores SHAP (SHapley Additive exPlanations), contribui para a expli-

cabilidade das predições de modelos preditivos (LUNDBERG; LEE, 2017), ampliando a interpretabilidade dos fatores determinantes do abandono e fornecendo subsídios para melhorias estruturais em produtos, serviços e processos organizacionais. A explicabilidade torna-se especialmente relevante em contextos de negócio, onde decisões baseadas em modelos precisam ser justificadas e comunicadas a gestores e equipes operacionais.

1.2 Problema de Pesquisa

O problema central deste trabalho pode ser formulado da seguinte maneira: como é possível identificar, de forma antecipada e com base em dados históricos de transações de e-commerce, quais clientes apresentam maior propensão ao churn, possibilitando a adoção de estratégias proativas de retenção?

Para o estudo empírico, utiliza-se o dataset Olist Brazilian E-Commerce Public Dataset (OLIST, 2018), disponível na plataforma Kaggle e já consolidado como base de referência em estudos de churn no e-commerce brasileiro (MATUSZELAŃSKI; KOPCZEWSKA, 2022). O dataset contém dados reais de transações de um marketplace brasileiro, com aproximadamente 100.000 pedidos realizados entre 2016 e 2018, contemplando informações de pedidos, clientes, itens, pagamentos, avaliações e produtos, características que o tornam um ambiente propício para a aplicação de técnicas de análise preditiva com rigor metodológico.

1.3 Justificativa e Motivação

A relevância deste trabalho fundamenta-se em três dimensões complementares. Do ponto de vista econômico, a previsão antecipada do churn permite às organizações alocar recursos de retenção com maior eficiência, concentrando esforços nos clientes com maior risco de abandono e maior valor estratégico para o negócio. Considerando o diferencial de custo entre retenção e aquisição de clientes (REICHHELD; SCHEFTER, 2000), o impacto financeiro de modelos preditivos bem calibrados é substancial.

Do ponto de vista metodológico, o problema apresenta desafios técnicos relevantes, especialmente quanto ao tratamento do desbalanceamento de classes (no contexto do e-commerce, a maioria dos clientes realiza apenas uma compra) e quanto à necessidade de construção de janelas temporais que evitem vazamento de informação (data leakage) entre os períodos de observação e predição (KAUFMAN *et al.*, 2012). A adequação rigorosa dessas etapas é determinante para a validade externa dos modelos construídos.

Do ponto de vista científico, o trabalho contribui para o campo da análise preditiva aplicada ao varejo digital, ao comparar sistematicamente dez algoritmos de Machine Learning, incorporar análise de explicabilidade via importância de features e valores SHAP, e adotar um protocolo de avaliação multi-métrica que vai além do ROC-AUC isolado,

abordagem recomendada por De la Cruz Huayanay, Bazán e Russo (2025) para cenários de dados desbalanceados. Essas dimensões permanecem ainda subexploradas em estudos aplicados ao contexto brasileiro de e-commerce (MATUSZELAŃSKI; KOPCZEWSKA, 2022).

1.4 Objetivo Geral

Desenvolver e avaliar modelos preditivos de customer churn para o contexto de e-commerce, utilizando técnicas de Machine Learning aplicadas ao dataset Olist, com vistas a subsidiar estratégias proativas de retenção de clientes.

Cabe destacar que predição de churn e gestão da retenção são duas faces do mesmo problema: o mesmo modelo que estima a probabilidade de abandono fornece, por complementaridade, o perfil dos clientes que tendem a retornar. Por essa razão, embora a variável-alvo seja formalmente definida como churn, a análise de explicabilidade (Seção 4.7, em especial 4.7.1) e as recomendações de negócio (Seção 4.8) são conduzidas sob a ótica da retenção, buscando responder não apenas "quem abandona", mas sobretudo "qual o perfil do cliente que volta a comprar", perspectiva de maior valor acionável para a organização.

1.5 Objetivos Específicos

1. Construir um pipeline de engenharia de features baseado na metodologia RFM (Recência, Frequência e Monetário), adotando estratégia de janela temporal dupla para eliminação de vazamento de informação (data leakage) entre os períodos de observação e predição, a partir dos dados transacionais do dataset Olist.

2. Comparar o desempenho de dez algoritmos de Machine Learning (Regressão Logística, Árvore de Decisão, Random Forest, Extra Trees, Gradient Boosting, HistGradient Boosting, AdaBoost, K-Nearest Neighbors, Naive Bayes e SVM) por meio de um protocolo de avaliação multi-métrica adequado ao contexto de classes desbalanceadas, a saber, ROC-AUC, G-Mean, MCC, Kappa de Cohen, F1-Macro e Precision-Recall.

3. Implementar e avaliar técnicas de balanceamento de classes, combinando undersampling da classe majoritária e oversampling sintético da classe minoritária, e validar empiricamente a representatividade do subconjunto resultante via PSI e KS-test.

4. Analisar a importância das features do modelo de melhor desempenho via impureza de Gini e valores SHAP, identificando as variáveis mais determinantes para a predição do churn e seus efeitos direcionais sobre as predições.

5. Caracterizar, sob a ótica da retenção, o perfil comportamental dos clientes que retornam à plataforma, identificando os fatores associados à recompra (como diversidade

de categorias e frequência de compras) que possam fundamentar estratégias proativas de fidelização.

2 REFERENCIAL TEÓRICO

2.1 Customer Churn: Conceituação e Importância Estratégica

O conceito de customer churn refere-se ao processo pelo qual clientes encerram ou interrompem seu relacionamento comercial com uma organização, deixando de realizar compras ou de utilizar seus serviços (MANZOOR *et al.*, 2024). No contexto do comércio eletrônico, o churn pode manifestar-se de forma explícita, como no cancelamento de assinaturas, ou implícita, caracterizada pela ausência de novas transações em um determinado período, o que torna sua identificação mais complexa e dependente da definição de janelas temporais de observação.

Do ponto de vista estratégico, a gestão do churn ocupa posição central nos modelos de Customer Relationship Management (CRM), uma vez que a rentabilidade de longo prazo das organizações está diretamente vinculada à capacidade de manutenção e expansão de sua base de clientes. Estudos clássicos demonstraram que reduções de 5% na taxa de churn podem resultar em incrementos de 25% a 95% nos lucros, em função do aumento do valor gerado pelo cliente ao longo do ciclo de vida do relacionamento (REICHHELD; SCHEFTER, 2000). Adicionalmente, a geração de receita por clientes recorrentes tende a ser mais estável e previsível do que aquela proveniente de novos clientes, cujo custo de aquisição é substancialmente superior ao de retenção, especialmente no comércio eletrônico (REICHHELD; SCHEFTER, 2000).

No setor de e-commerce, o desafio da retenção é amplificado pela abundância de concorrentes e pela facilidade com que os consumidores podem migrar para outras plataformas. Como as taxas de churn variam consideravelmente entre setores (IMANI *et al.*, 2025), torna-se imperativa a adoção de estratégias preditivas que permitam antecipar o abandono e direcionar ações de retenção de forma proativa.

2.2 Metodologia RFM e Engenharia de Features

A metodologia RFM, acrônimo para Recência (R), Frequência (F) e Monetário (M), constitui um dos frameworks mais consolidados para segmentação e análise comportamental de clientes, com origem na área de marketing direto (HUGHES, 1994). A Recência mensura o intervalo de tempo desde a última transação do cliente; a Frequência quantifica o número de transações realizadas em um período determinado; e o valor Monetário corresponde ao volume financeiro total gasto pelo cliente no período de análise.

No contexto de modelos preditivos de churn, o framework RFM serve como base para a engenharia de features, uma vez que as três dimensões capturam de forma objetiva os principais aspectos do comportamento transacional do cliente. Clientes com elevada

recência, ou seja, com longa data desde a última compra, tendem a apresentar maior propensão ao churn, enquanto aqueles com alta frequência e alto valor monetário representam os perfis mais valiosos e tipicamente mais estáveis.

Um aspecto metodológico crítico na construção de features RFM para modelos preditivos é o tratamento rigoroso da dimensão temporal, de modo a evitar o vazamento de informação futura para o conjunto de treino, problema conhecido como data leakage (KAUFMAN *et al.*, 2012). Uma estratégia consolidada para mitigar esse risco é a separação entre uma janela de observação, na qual as features são computadas, e uma janela de predição, na qual o target é definido, estratégia detalhada na Seção 3.2.

2.3 Algoritmos de Machine Learning para Classificação

A literatura sobre predição de churn contempla ampla variedade de algoritmos de classificação, com desempenhos variáveis a depender das características do dataset, do grau de desbalanceamento entre classes (HE; GARCIA, 2009) e da complexidade das relações não lineares entre as features (VAFEIADIS *et al.*, 2015). Entre os modelos mais amplamente aplicados, destacam-se a Regressão Logística, os métodos baseados em árvores e os algoritmos ensemble.

A Regressão Logística, modelo linear de referência amplamente utilizado em estudos de churn por sua interpretabilidade e eficiência computacional, apresenta limitações diante de relações não lineares entre variáveis, sendo frequentemente superada por modelos baseados em árvores em contextos de maior complexidade (PRABADEVI; SHALINI; KAVITHA, 2023).

O Random Forest consiste em um ensemble de árvores de decisão treinadas com bootstrap sampling e seleção aleatória de features, o que confere ao modelo robustez ao overfitting e capacidade de capturar interações não lineares entre variáveis (BREIMAN, 2001). O algoritmo fornece, naturalmente, medidas de importância de features via impureza de Gini, tornando-se especialmente útil em contextos onde a interpretabilidade do modelo é relevante.

Os métodos de Gradient Boosting, incluindo o Gradient Boosting clássico (FRIEDMAN, 2001) e suas variantes otimizadas como o HistGradient Boosting, operam pela construção sequencial de modelos fracos (weak learners), cada um focado na correção dos erros do anterior, minimizando uma função de perda de forma iterativa. Tais abordagens têm consistentemente demonstrado desempenho superior em benchmarks de classificação com dados tabulares.

2.4 Desbalanceamento de Classes e Técnicas de Balanceamento

O desbalanceamento de classes constitui um dos principais desafios práticos em problemas de predição de churn, especialmente no contexto do e-commerce, onde a proporção de clientes que efetivamente retornam é tipicamente muito menor do que a daqueles que não voltam a comprar. Quando não tratado adequadamente, o desbalanceamento induz os modelos a favorecerem a classe majoritária, resultando em alta acurácia geral, porém com baixa capacidade de identificação dos casos de churn (HE; GARCIA, 2009).

A literatura propõe diversas abordagens para mitigar esse problema. O oversampling da classe minoritária, como implementado pelo algoritmo SMOTE (Synthetic Minority Over-sampling Technique), gera instâncias sintéticas baseadas na interpolação entre exemplos reais da classe minoritária (CHAWLA *et al.*, 2002). O undersampling da classe majoritária, por sua vez, reduz a proporção dos exemplos mais frequentes, equilibrando o dataset de treino. Estudos indicam que a combinação de ambas as estratégias tende a produzir resultados superiores às abordagens isoladas: técnicas híbridas como SMOTE combinado com Tomek Links ou com Edited Nearest Neighbors (ENN) geram conjuntos de dados com fronteiras de classe mais bem definidas, atenuando o overfitting (BATISTA; PRATI; MONARD, 2004). No domínio específico da predição de churn, estudos comparativos recentes avaliam o desempenho de diferentes métodos de resampling sobre dados altamente desbalanceados provenientes de setores como telecomunicações, varejo online e bancário (HADDADI *et al.*, 2024).

2.5 Métricas de Avaliação para Dados Desbalanceados

A seleção de métricas de avaliação adequadas é uma decisão crítica em problemas de classificação com dados desbalanceados. A acurácia global constitui métrica enganosa nesses contextos, uma vez que um classificador trivial que prediz sempre a classe majoritária pode atingir alta acurácia sem qualquer capacidade preditiva real. De la Cruz Huayanay, Bazán e Russo (2025) demonstraram que a ROC-AUC isolada é insuficiente como critério de seleção de modelos em dados desbalanceados, ao mostrar, em estudo de simulação com modelo verdadeiro conhecido, que ela não distingue o modelo corretamente especificado do mal especificado em nenhum cenário avaliado, enquanto MCC, G-Mean e Kappa de Cohen o fazem de forma consistente: achado que motivou a adoção de um portfólio de métricas complementares neste trabalho.

Entre as métricas usualmente empregadas para contextos desbalanceados, destacam-se cinco. A ROC-AUC (Area Under the ROC Curve) mede a capacidade discriminatória geral do modelo, de forma independente do threshold (FAWCETT, 2006). O G-Mean (Geometric Mean), proposto originalmente por Kubat e Matwin (1997), é definido como a raiz quadrada do produto entre Sensibilidade (Recall da classe positiva) e Especificidade (Recall da classe negativa), penalizando modelos que sacrificam o desempenho em uma

das classes. O MCC (Coeficiente de Correlação de Matthews), introduzido por Matthews (1975), é considerado por Chicco e Jurman (2020) a métrica mais informativa e confiável para classificação binária, por levar em conta, de forma simétrica, todos os quadrantes da matriz de confusão (verdadeiros positivos, verdadeiros negativos, falsos positivos e falsos negativos). O Kappa de Cohen (COHEN, 1960) corrige o desempenho pelo acerto esperado ao acaso. Por fim, o F1-Macro, média harmônica não ponderada de Precisão e Recall por classe, complementa o conjunto ao capturar o equilíbrio entre as classes no ponto de corte adotado. Luque *et al.* (2019) demonstram analiticamente como o desbalanceamento de classes distorce o comportamento dessas métricas, o que reforça a necessidade de interpretá-las em conjunto e à luz da distribuição real do conjunto de teste.

A Curva Precision-Recall (PR), especialmente sua área (AUPRC ou Average Precision), é preferível à ROC-AUC em cenários de desbalanceamento severo, por ser mais sensível ao desempenho na classe minoritária e não ser afetada pela grande quantidade de verdadeiros negativos típica desses contextos (SAITO; REHMSMEIER, 2015). Cabe registrar que a Average Precision pondera de forma desproporcional o extremo inicial da ordenação, região em que a precisão é estimada sobre poucas observações, característica que se torna relevante na interpretação conduzida na Seção 4.3.

2.6 Explicabilidade de Modelos: Valores SHAP e Importância de Features

A crescente adoção de modelos complexos de Machine Learning em contextos de negócio impõe desafios à interpretabilidade das predições, especialmente em organizações onde decisões baseadas em algoritmos precisam ser justificadas a gestores e reguladores. Nesse contexto, a área de Inteligência Artificial Explicável (XAI) tem ganhado relevância crescente, propondo métodos para tornar os modelos mais transparentes sem necessariamente sacrificar seu desempenho.

Os valores SHAP (SHapley Additive exPlanations) foram propostos por Lundberg e Lee (2017) como um framework unificado de explicabilidade, fundamentado na teoria dos jogos cooperativos de Shapley (SHAPLEY, 1953) e dotado de propriedades teóricas desejáveis, como consistência e atribuição aditiva. Desde então, tornaram-se um dos métodos mais consolidados para explicabilidade local e global de modelos de Machine Learning. Para cada predição, os valores SHAP quantificam a contribuição marginal de cada feature para o desvio do resultado em relação ao valor base do modelo. O TreeSHAP, implementado na classe TreeExplainer da biblioteca shap (LUNDBERG *et al.*, 2020), permite o cálculo eficiente de valores SHAP para modelos baseados em árvores, como o Random Forest. Cabe registrar que o TreeSHAP decompõe as predições percorrendo a mesma estrutura de árvores ajustada da qual deriva a importância por impureza de Gini, de modo que a concordância entre os dois estimadores é esperada por construção e não constitui, isoladamente, validação independente da hierarquia de importância obtida.

Para modelos lineares, a mesma decomposição admite forma fechada. Sob a hipótese de independência entre as features, o valor SHAP da variável j na instância x é dado por $\varphi_j(x) = \beta_j \cdot (x_j - \mathbb{E}[x_j])$, em que β_j é o coeficiente estimado. Essa propriedade permite que os valores SHAP sejam calculados para estimadores de naturezas distintas, o que os torna o único terreno comum de comparação de importância entre modelos que não compartilham medida nativa, recurso empregado na Seção 4.7. Cabe a ressalva de que as contribuições assim obtidas encontram-se em escalas diferentes conforme a saída do modelo: em espaço de probabilidade para o Random Forest sob TreeSHAP, e em log-odds para modelos lineares e para o boosting, de modo que apenas posições e participações relativas são comparáveis entre eles.

2.7 Estudos Relacionados

A predição de churn em e-commerce tem sido objeto de crescente atenção na literatura científica. Revisões clássicas do estado da arte já apontavam o bom desempenho de árvores de decisão e redes neurais em relação a modelos de regressão tradicionais para predição de churn (HADDEN *et al.*, 2007).

No campo específico da avaliação de modelos sob desbalanceamento, De la Cruz Huayanay, Bazán e Russo (2025) conduziram estudo de simulação com doze métricas de classificação, concluindo que o MCC, o G-Mean e o Kappa de Cohen mantêm desempenho consistente na identificação do modelo corretamente especificado, enquanto a AUC e a acurácia falham em todos os cenários avaliados. Os autores registram duas delimitações de alcance que dialogam diretamente com este trabalho: o estudo não contempla amostras pequenas, tendo empregado tamanhos de 5.000 e 10.000 observações, e sugerem, como extensão, a comparação com algoritmos de classificação como Naive Bayes, K-Nearest Neighbors, Árvore de Decisão, Support Vector Machines e Random Forest. O presente trabalho situa-se nesse recorte, ao avaliar esses algoritmos sobre uma base de 1.178 clientes com aproximadamente cinquenta observações na classe minoritária.

Revisões sistemáticas recentes mapearam tendências e desafios da área. Imani *et al.* (2025), ao sintetizarem estudos publicados entre 2020 e 2024, documentam a ampla adoção de métodos ensemble baseados em árvores, que mantêm desempenho competitivo em datasets tabulares de tamanho moderado, contexto no qual modelos mais complexos nem sempre compensam o custo computacional adicional. Manzoor *et al.* (2024) complementam esse panorama ao mapear 212 estudos publicados entre 2015 e 2023, sistematizando recomendações de engenharia de features e de avaliação para modelos de churn. Os autores destacam a importância de variáveis comportamentais complementares ao RFM e enfatizam que o desempenho preditivo depende fortemente da qualidade da preparação dos dados, e não apenas da escolha do algoritmo. Em um recorte mais específico, Haddadi *et al.* (2024) conduziram estudo comparativo sobre técnicas de resampling para churn em

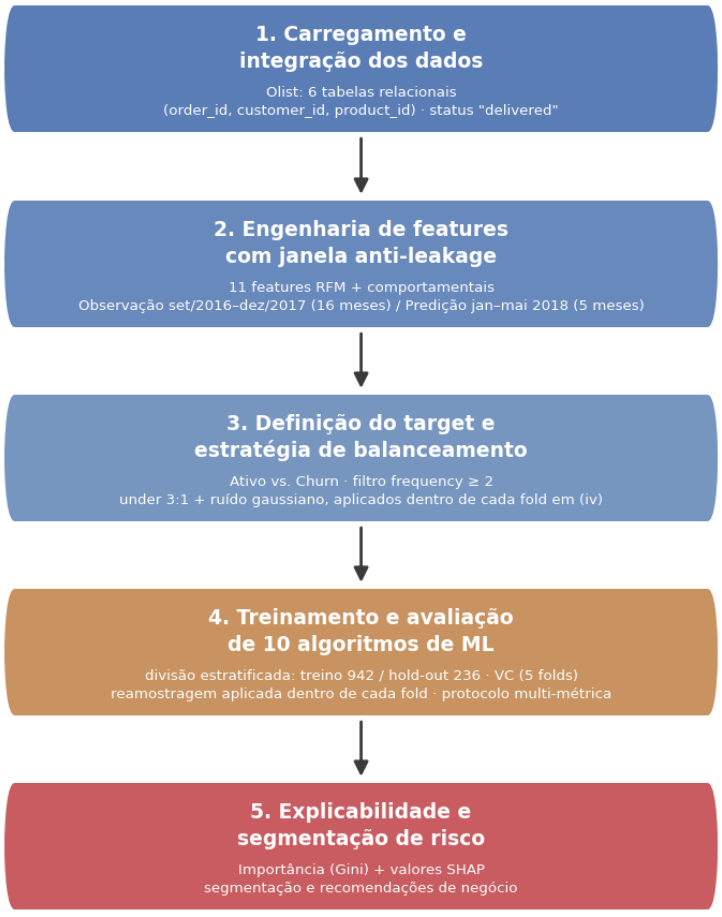
datasets desbalanceados, avaliando métodos como SMOTE, ADASYN e uma abordagem de resampling em duas fases, esta última especialmente compatível com redes neurais profundas.

No contexto específico do dataset Olist (OLIST, 2018), Matuszelański e Kopczewska (2022) conduziram um dos estudos mais completos disponíveis, combinando abordagens espaciais e de Machine Learning. Os autores documentaram a característica predominante de clientes com compra única como desafio metodológico central e recomendaram filtros baseados na frequência mínima de compras. A adoção desses filtros, aliada à definição rigorosa de janelas temporais, constitui estratégia necessária para tornar o problema tratável do ponto de vista de Machine Learning, conforme proposto neste trabalho.

3 METODOLOGIA

Este trabalho adota uma abordagem quantitativa de natureza aplicada, fundamentada na construção e avaliação experimental de modelos preditivos de customer churn. O estudo compreende cinco etapas sequenciais, detalhadas ao longo deste capítulo e do Capítulo 4: (i) carregamento e integração dos dados; (ii) engenharia de features com janela temporal anti-leakage; (iii) definição do target e estratégia de balanceamento de classes; (iv) treinamento e avaliação comparativa de dez algoritmos de Machine Learning; e (v) análise de importância de features, valores SHAP e segmentação de risco dos clientes. A Figura 1 sintetiza o encadeamento dessas etapas.

Figura 1 – Pipeline metodológico do estudo



Fonte: elaborado pelo autor.
Nota: a estratégia de balanceamento é definida na etapa (3) e aplicada na etapa (4), dentro de cada partição da validação cruzada, conforme o protocolo descrito na Seção 3.5.

3.1 Base de Dados e Integração

A base de dados utilizada é o Olist Brazilian E-Commerce Public Dataset (OLIST, 2018), composto por seis tabelas relacionais: pedidos, clientes, itens de pedido, pagamentos, avaliações e produtos. A integração das tabelas foi realizada por meio de chaves primárias e estrangeiras compartilhadas (order_id, customer_id e product_id), resultando em um dataset unificado cujo período de cobertura, conforme a documentação do conjunto de dados (OLIST, 2018), estende-se de setembro de 2016 a outubro de 2018. Foram considerados exclusivamente pedidos com status "delivered", garantindo que apenas transações efetivamente concluídas compusessem a base de análise.

3.2 Estratégia Temporal Anti-Leakage

A fim de evitar o vazamento de informação futura para o conjunto de treino, problema conhecido como data leakage, adotou-se uma estratégia de janela temporal dupla. A janela de observação, na qual as features comportamentais de cada cliente são computadas, encerra-se em 31 de dezembro de 2017 e abrange todo o histórico transacional disponível até essa data (setembro de 2016 a dezembro de 2017, aproximadamente dezesseis meses), assegurando suficiência estatística e contemplando um ciclo sazonal completo. A janela de predição, de 1.º de janeiro a 31 de maio de 2018, define o período no qual se verifica se o cliente realizou nova compra, determinando, assim, sua classificação como Ativo (retornou) ou Churn (não retornou). Essa separação temporal garante que nenhuma informação posterior ao momento de predição influencie os modelos.

A escolha do horizonte de predição foi deliberada: cinco meses equilibram sensibilidade à recompra e representatividade do horizonte preditivo, janela compatível com um contexto de e-commerce marcado pela predominância de clientes de compra única, característica documentada para o mesmo dataset por Matuszelański e Kopczewska (2022). A Figura 2 representa graficamente essa separação temporal.

Figura 2 – Estratégia de janela temporal dupla (anti-leakage)



Fonte: elaborado pelo autor.

3.3 Engenharia de Features RFM

Com base na janela de observação, foram calculadas onze features por cliente, seguindo a metodologia RFM e incluindo variáveis complementares de comportamento transacional. Destas, três correspondem diretamente às dimensões do modelo, uma é derivada de duas delas e sete foram acrescentadas como atributos auxiliares. A Tabela 1 sumariza as features construídas e explicita, na coluna Dimensão, a correspondência de cada uma com o RFM.

Tabela 1 – Features RFM construídas na janela de observação (até dez/2017)

Feature	**Dimensão**	**Tipo**	**Descrição / Fórmula**
recency_days	R	Numérica	01/01/2018 − data do último pedido (em dias)
frequency	F	Numérica	COUNT(DISTINCT order_id) por customer_unique_id
monetary	M	Numérica	SUM(valor do pedido) por customer_unique_id
avg_ticket	M*	Numérica	monetary / frequency
avg_delivery_days	C	Numérica	MEAN(data_entrega − data_compra)
avg_review_score	C	Numérica	MEAN(review_score)
avg_installments	C	Numérica	MEAN(payment_installments)
avg_freight	C	Numérica	MEAN(freight_value)
n_categories	C	Numérica	COUNT(DISTINCT product_category_name)
top_category	C	Categórica	MODE(product_category_name) → Label Encoding
customer_state	C	Categórica	UF do cliente → Label Encoding

Fonte: elaborado pelo autor.
Nota: na coluna Dimensão, R, F e M identificam as features que operacionalizam diretamente a Recência, a Frequência e o valor Monetário do modelo RFM; M designa variável derivada das dimensões M e F, e não uma quarta dimensão; C identifica as variáveis complementares, acrescentadas ao modelo como atributos auxiliares de comportamento, de experiência de compra e de contexto do cliente. Registros sem categoria de produto identificada, correspondentes a 1,8% do conjunto integrado, recebem o rótulo "desconhecido" na etapa de construção das features (Seção 3.5). Esse rótulo é computado como categoria distinta por COUNT(DISTINCT product_category_name), de modo que clientes com pedidos nessa condição podem ter a contagem de n_categories acrescida em uma unidade.*

A correspondência com o modelo RFM é, portanto, a seguinte. A Recência é operacionalizada por recency_days, a Frequência por frequency e o valor Monetário por monetary, uma feature para cada dimensão. A variável avg_ticket não constitui dimensão adicional: é o quociente entre monetary e frequency, isto é, uma recomposição das duas dimensões que já estão no modelo, razão pela qual foi mantida separada na classificação. As sete demais são complementares ao RFM e distribuem-se em quatro naturezas distintas: experiência de compra (avg_delivery_days e avg_freight, atributos do serviço prestado, e não do comportamento do cliente); satisfação declarada (avg_review_score); comportamento de pagamento (avg_installments); e perfil de consumo (n_categories e top_category). A estas soma-se customer_state, de natureza contextual, que caracteriza a localização do cliente e não o seu comportamento transacional. As features categóricas compreendem top_category e customer_state, ambas submetidas a Label Encoding antes do treinamento. A opção pela codificação ordinal, em detrimento da codificação binária por one-hot, decorre da cardinalidade dessas variáveis frente ao tamanho da base: o catálogo de produtos do dataset contém 73 categorias distintas, às quais se soma o rótulo "desconhecido", de modo que a expansão binária elevaria a dimensionalidade a patamar incompatível com 1.178 observações. Cabe registrar a limitação inerente à escolha: modelos baseados em árvores tratam o inteiro atribuído a cada categoria como grandeza ordenada, produzindo partições sobre uma ordem que não possui significado substantivo. Esse efeito soma-se ao viés da importância por impureza de Gini em variáveis categóricas de cardinalidade elevada, discutido na Seção 4.7, e recomenda cautela na interpretação da posição de top_category nos rankings de importância. Codificações alternativas são registradas entre os trabalhos futuros. Clientes com frequency igual a 1 foram excluídos do escopo de modelagem, pois compradores únicos não possuem histórico suficiente para caracterizar comportamento de recompra e sua inclusão trivializaria o target Churn sem adicionar poder preditivo real.

Essa decisão de filtragem foi submetida à validação empírica no notebook que acompanha esta monografia: um modelo Random Forest de referência foi treinado em duas configurações, com o filtro adotado (frequency ≥ 2; 1.178 clientes) e incluindo os compradores únicos (frequency ≥ 1; mais de 42 mil clientes, com 98,9% de Churn). A inclusão dos compradores únicos reduziu o ROC-AUC em aproximadamente 0,29 ponto (de 0,8106 para 0,5231), aproximando o modelo de um classificador aleatório, e degradou o MCC em cerca de 79% (de 0,1931 para 0,0400). O resultado confirma empiricamente que os compradores únicos não agregam sinal preditivo de recompra, apenas diluem o problema, corroborando a recomendação de Matuszelański e Kopczewska (2022) para o dataset Olist.

A feature n_categories foi incluída por hipótese de negócio (clientes que diversificam categorias demonstram maior engajamento com a plataforma), em linha com as recomendações de Manzoor *et al.* (2024) sobre variáveis comportamentais complementares

ao RFM. A variável revelou-se, posteriormente, um dos três principais drivers preditivos do modelo, em empate técnico de importância com a recência. Tal equivalência entre diversidade de categorias e recência não é reportada nos estudos anteriores aplicados ao Olist, incluindo Matuszelański e Kopczewska (2022). Sua relevância sugere que a diversificação de categorias merece investigação como possível alavanca de retenção proativa, hipótese a ser confirmada em bases de maior volume.

3.4 Target e Balanceamento de Classes

O target binário foi definido como: Churn = 1 para clientes que não realizaram nenhuma compra na janela de predição; e Ativo = 0 para aqueles que efetuaram ao menos uma transação no período. A base resultante apresentou desbalanceamento acentuado, com 95,8% dos clientes classificados como Churn e 4,2% como Ativos. Cabe destacar que essa proporção se verifica em uma coorte composta exclusivamente por clientes recorrentes, o que evidencia que, mesmo entre consumidores com histórico de recompra, os intervalos entre transações tendem a exceder o horizonte de predição adotado, característica consistente com a baixa taxa de retorno documentada para o dataset Olist (MATUSZELAŃSKI; KOPCZEWSKA, 2022).

Para mitigar o efeito do desbalanceamento extremo, que tende a produzir modelos enviesados para a classe majoritária e com baixa capacidade preditiva real (HE; GARCIA, 2009), adotou-se uma estratégia combinada de under e oversampling aplicada exclusivamente ao conjunto de treino. O undersampling reduziu a classe majoritária (Churn) a no máximo três vezes o tamanho da classe minoritária (Ativo). O oversampling sintético por ruído gaussiano de média zero e desvio-padrão 0,05, aplicado sobre as features já padronizadas (média 0, desvio padrão 1), expandiu a classe Ativo até igualar o tamanho da maioria, produzindo um conjunto de treino perfeitamente balanceado. Não se trata de interpolação entre vizinhos, como no SMOTE: cada instância sintética é uma cópia de uma observação real da classe minoritária somada a perturbação de baixa magnitude, procedimento que preserva a vizinhança original em vez de criar pontos em regiões não observadas do espaço de features. O procedimento corresponde à replicação ruidosa (*noisy replication*) formulada por Lee (2000) para classificação binária com classes assimétricas, e encontra respaldo teórico no resultado de Bishop (1995), segundo o qual o treinamento com ruído aditivo de baixa variância equivale a uma forma de regularização de Tikhonov, o que explica por que a perturbação atua como regularizador em vez de introduzir ruído estrutural. O conjunto de teste foi mantido com a distribuição original, preservando a validade da avaliação.

A escolha dessa estratégia apoiou-se em uma análise comparativa sistemática das alternativas de tratamento do desbalanceamento, sintetizada no Quadro 1, que pondera vantagens e riscos de cada uma à luz do tamanho reduzido da classe minoritária (aproxi-

madamente 50 clientes ativos). Optou-se pela combinação de undersampling moderado (razão 3:1) com oversampling gaussiano por preservar a vizinhança real dos dados sem descartar informação da classe majoritária nem gerar instâncias em regiões não representativas, como poderia ocorrer com o SMOTE (CHAWLA *et al.*, 2002) em um conjunto tão pequeno e esparso. Trata-se, portanto, de alternativa deliberadamente mais conservadora, cuja adequação foi verificada empiricamente por meio da análise de representatividade conduzida na Seção 4.6.

A fim de corroborar essa escolha de desenho, as quatro estratégias (sem balanceamento, undersampling puro, SMOTE e a combinação adotada) foram comparadas empiricamente sob um mesmo modelo de referência, mantendo-se fixo um Random Forest (n_estimators = 300, max_depth = 10), de modo que o que se contrasta são estratégias de reamostragem, e não algoritmos. A comparação foi conduzida em dois regimes: um split de referência e trinta divisões estratificadas independentes, com a reamostragem aplicada dentro de cada partição da validação cruzada e o limiar derivado das probabilidades out-of-fold, conforme o protocolo descrito na Seção 3.5. Os resultados dessa comparação são reportados na Seção 4.2.

Quadro 1 – Análise comparativa de estratégias de balanceamento de classes

Estratégia	**Vantagens**	**Desvantagens / Riscos**
Sem balanceamento	Preserva a distribuição real; sem artefatos sintéticos.	Modelos enviesados para a classe majoritária, com regra de decisão que só alcança recall não trivial na classe Ativo mediante limiar muito acima do padrão.
Undersampling puro	Simples; reduz custo computacional; sem dados sintéticos.	Descarta a quase totalidade da classe Churn; base de treino diminuta (cerca de 80 amostras) com 40 Ativos.
SMOTE (oversampling sintético)	Amplia a classe minoritária por interpolação entre vizinhos reais; consagrado na literatura.	Em datasets pequenos e esparsos, gera instâncias em regiões não representativas; risco de ruído estrutural.
Under + oversampling gaussiano (adotada)	Equilibra as classes; retém três vezes mais amostras Churn que o undersampling puro; perturbação de baixa magnitude preserva a vizinhança real.	Ainda descarta cerca de 87% da classe Churn presente no conjunto de treino; dois terços da classe Ativo no treino são sintéticos; exige validação de representatividade (Seção 4.6).

Fonte: elaborado pelo autor.

3.5 Protocolo de Treinamento e Avaliação

Os dados foram divididos em treino (80%) e teste (20%) por meio de StratifiedShuffleSplit, garantindo a proporção original de classes em ambos os conjuntos. Sobre a matriz de modelagem assim particionada, tanto a imputação de valores ausentes pela mediana quanto a padronização via StandardScaler tiveram seus parâmetros estimados exclusivamente no conjunto de treino e apenas aplicados ao conjunto de teste, procedimento que preserva a separação entre aprendizado e predição e evita a contaminação do treino por informação do teste (KAUFMAN *et al.*, 2012).

Precede essa etapa o tratamento de ausências na construção das features, conduzido sobre a tabela transacional da janela de observação, isto é, antes da agregação por cliente e, portanto, antes da divisão entre treino e teste. Registra-se explicitamente a implicação dessa anterioridade: as estatísticas ali empregadas foram estimadas sobre a totalidade daquela tabela, e não apenas sobre as observações que viriam a compor o conjunto de treino. São duas as estatísticas dependentes da amostra: a mediana de review_score, que alimenta a feature avg_review_score, e a mediana do valor do pedido, que alimenta monetary e avg_ticket. As demais ausências receberam valores que não dependem da amostra e, por construção, não transportam informação entre partições: zero para o frete, um para o número de parcelas e o rótulo "desconhecido" para a categoria do produto, ausente em 1,8% dos registros, conforme a nota da Tabela 1.

O efeito dessa anterioridade foi quantificado. A tabela transacional da janela de observação contém 52.915 linhas referentes a 42.395 clientes, dos quais apenas 1.178 compõem a amostra de modelagem após o filtro de recorrência e 236 integram o conjunto de teste, equivalentes a 0,56% da tabela; as medianas são, portanto, determinadas majoritariamente por clientes que não pertencem nem ao treino nem ao teste. Recalculadas exclusivamente sobre as observações do conjunto de treino, a mediana de review_score permanece idêntica (5,00 em ambos os casos), apesar de incidir sobre 442 registros ausentes (0,84% da tabela); a mediana do valor do pedido difere (R$ 103,55 contra R$ 95,94), mas incide sobre um único pedido ausente entre 43.695, pertencente a cliente situado fora da amostra de modelagem. Em consequência, nenhuma das três features derivadas dessas estatísticas assume valor distinto sob os dois procedimentos nos 1.178 clientes modelados, de modo que o vazamento entre partições é, nesta base, numericamente nulo. Reconhece-se, ainda assim, que estimar tais estatísticas restritas ao conjunto de treino constitui o procedimento metodologicamente correto, e que a equivalência aqui verificada é propriedade desta base, não garantia do procedimento; a reordenação dessa etapa é registrada entre os trabalhos futuros.

Foram treinados e avaliados dez algoritmos de Machine Learning: Regressão Logística, Árvore de Decisão, Random Forest, Extra Trees, Gradient Boosting, HistGradient Boosting, AdaBoost, K-Nearest Neighbors (KNN), Gaussian Naive Bayes e Support Vector Machine (SVM). Cada modelo foi submetido a validação cruzada estratificada com cinco

folds (StratifiedKFold) no conjunto de treino e avaliado no hold-out de teste. A imputação, a padronização e a reamostragem são ajustadas dentro de cada partição, exclusivamente sobre a porção de ajuste, procedimento necessário para que instâncias sintéticas derivadas de uma mesma observação original não se distribuam entre folds distintos (HASTIE; TIBSHIRANI; FRIEDMAN, 2009; KAUFMAN *et al.*, 2012). Registra-se que parte dos estimadores mantém o parâmetro class_weight = "balanced" por padrão defensivo; sob o conjunto de treino perfeitamente balanceado (120/120), o parâmetro atribui pesos iguais às classes e é, portanto, neutro.

O protocolo de avaliação adota um conjunto abrangente de métricas sensíveis ao desbalanceamento, incorporando as três recomendadas por De la Cruz Huayanay, Bazán e Russo (2025), a saber, MCC (Coeficiente de Correlação de Matthews), G-Mean e Kappa de Cohen, além de ROC-AUC, Average Precision, F1-Macro, Precisão e Recall por classe. Essas métricas não possuem o mesmo estatuto na decisão: a hierarquia que as ordena é apresentada no Quadro 2 e fundamentada ao final desta seção. Adota-se a classe Churn como positiva em todas as métricas por classe e na leitura da matriz de confusão, de modo que falso positivo designa cliente Ativo classificado como Churn, e falso negativo, cliente Churn classificado como Ativo.

Quadro 2 – Hierarquia das métricas de avaliação segundo o papel na seleção

Camada	**Métrica**	**Papel**
Primária (decide a seleção; estimada fora da amostra)	ROC-AUC out-of-fold; clientes Ativos capturados em cobertura fixa; ocupação das faixas de risco	Mede a qualidade da ordenação dos clientes por risco, a eficiência do recorte por unidade de esforço e a usabilidade da segmentação como instrumento de priorização, que é o entregável do trabalho.
Secundária (caracteriza a decisão binária; reportada, não decisória)	MCC, G-Mean e Kappa de Cohen; Precisão e Recall por classe	Descreve o comportamento da regra de decisão no limiar adotado. As três primeiras são as recomendadas por De la Cruz Huayanay, Bazán e Russo (2025) para cenários desbalanceados.
Diagnóstica (apoia a leitura; não compara desempenho)	Average Precision; F1-Macro; Δ; limiar de classificação	Average Precision admite apenas comparação entre modelos, dada a linha de base de 0,958 na classe Churn; F1-Macro serve de critério alternativo na varredura do limiar; Δ indica a concordância direcional entre estimativa reamostrada e hold-out; e o limiar é parâmetro da regra, não medida de desempenho.

Fonte: elaborado pelo autor.

O limiar de classificação constitui parâmetro livre da regra de decisão e, como tal,

deve ser estimado sobre dados que não participem do relato de desempenho; estimá-lo no conjunto de teste equivale a utilizá-lo duas vezes, uma para ajustar o parâmetro e outra para reportar o resultado, o que caracteriza viés de seleção na avaliação (CAWLEY; TALBOT, 2010; HASTIE; TIBSHIRANI; FRIEDMAN, 2009). Dado que o valor padrão de 0,50 raramente é ótimo (FAWCETT, 2006) e que o tamanho da classe minoritária inviabiliza a extração de uma terceira partição de validação, adotou-se o seguinte procedimento: as probabilidades preditas foram obtidas por validação cruzada estratificada de cinco folds sobre o conjunto de treino, com a reamostragem aplicada exclusivamente à porção de ajuste de cada partição e a porção de validação mantida na distribuição original das classes; sobre essas probabilidades out-of-fold, agregadas, o limiar foi varrido uma única vez no intervalo de 0,01 a 0,99, selecionando-se o valor que maximiza o Kappa de Cohen, mesmo critério adotado por De la Cruz Huayanay, Bazán e Russo (2025). O limiar assim obtido foi congelado e aplicado ao hold-out, que permanece utilizado uma única vez. Como as probabilidades out-of-fold são estimadas sob a prevalência original, o limiar transfere-se ao conjunto de teste sem necessidade de correção adicional pelo viés de amostragem formalizado por Dal Pozzolo *et al.* (2015). A escolha do Kappa de Cohen como critério de varredura mostrou-se pouco sensível: em oito dos dez algoritmos avaliados, incluindo o Random Forest adotado como modelo final, o limiar selecionado coincide com o que resultaria da maximização do F1-Macro. Divergem apenas o SVM, cujo limiar passaria de 0,37 para 0,23, e a Árvore de Decisão, de 0,61 para 0,01.

O critério de seleção do modelo adotado foi reformulado em relação à concepção inicial deste trabalho. A verificação de sobreajuste pela diferença entre validação cruzada e hold-out, conduzida sob o protocolo corrigido descrito acima, não excluiu nenhum dos dez algoritmos. Essa diferença é definida com sinal, $\Delta = \text{CV-AUC} - \text{AUC}$, e não em valor absoluto: apenas Δ positivo, em que a estimativa reamostrada supera a observada fora da amostra, é compatível com o otimismo que o diagnóstico pretende detectar; Δ negativo indica hold-out mais favorável que a validação cruzada e nada informa sobre sobreajuste. A maior diferença positiva observada foi de 0,1347 (Árvore de Decisão), abaixo do limite de 0,15 fixado para esta verificação. A prática de contrastar a estimativa reamostrada com a de um conjunto reservado, como diagnóstico do otimismo introduzido pelo procedimento de seleção, é recomendada por Hastie, Tibshirani e Friedman (2009) e por Cawley e Talbot (2010), que não estabelecem, contudo, um valor numérico de corte. O limite de 0,15 é, portanto, um parâmetro operacional definido por este trabalho antes da execução do benchmark, cuja função é tornar o critério auditável, e não uma grandeza extraída da literatura.

Cabe explicitar o alcance desse diagnóstico. Com dez instâncias da classe Ativo no conjunto de teste, a ROC-AUC ali estimada apresenta erro padrão da ordem de 0,09 pela aproximação de Hanley e McNeil (1982), o que corresponde a um intervalo de confiança de 95% com amplitude próxima de 0,33. Diferenças entre as duas estimativas inferiores a essa

amplitude são compatíveis com a variabilidade amostral entre partições, sem que se faça necessária qualquer hipótese sobre o ajuste do modelo. O limite de 0,15 é, por conseguinte, empregado como sinalizador descritivo de divergências que mereçam inspeção, e não como teste de sobreajuste, para o qual o regime amostral deste trabalho não oferece poder estatístico. A sensibilidade a essa escolha é reportada na Seção 4.3. Os valores elevados de validação cruzada obtidos na concepção inicial decorriam do procedimento então adotado, no qual a validação era conduzida sobre o conjunto já balanceado; a magnitude da correção é reportada na Seção 4.3. A seleção passou, assim, a fundamentar-se na natureza do entregável, discutida na Seção 4.3 e detalhada na Seção 4.8: o produto do modelo não é uma decisão binária em um ponto de corte, mas uma priorização de clientes em faixas de risco, que depende da ordenação dos scores e não do limiar. O procedimento adotado é de dois estágios. O primeiro é de elegibilidade e decorre do objetivo específico (4), que requer a análise da importância de features do modelo escolhido por impureza de Gini: permanecem elegíveis apenas os estimadores que expõem essa medida de forma nativa. O segundo ordena os elegíveis por dois aspectos, a qualidade da ordenação dos clientes por risco e a usabilidade da segmentação em faixas que dela resulta.

Aplica-se à seleção do estimador o mesmo princípio já adotado para o limiar: nenhuma grandeza empregada na decisão provém do conjunto de teste. Todas as quantidades comparadas no segundo estágio foram estimadas sobre as probabilidades out-of-fold do conjunto de treino, a saber, a área sob a curva ROC fora da amostra, o número de clientes Ativos capturados em cobertura fixa e a ocupação das faixas de risco sob os cortes adotados. O conjunto de teste permanece reservado a uma única avaliação, posterior à escolha, cujos valores são relatados na Seção 4.3 como estimativa final e não como fundamento da seleção. Essa separação atende à recomendação de Cawley e Talbot (2010) quanto ao viés de seleção introduzido quando o mesmo conjunto serve para escolher e para reportar, e corrige a assimetria da concepção inicial deste trabalho, na qual o cuidado era aplicado ao limiar, porém não à escolha do estimador.

Todas as operações estocásticas do pipeline, incluindo divisão treino/teste, balanceamento e treinamento dos modelos, utilizam semente fixa (random_state = 42), garantindo reprodutibilidade exata dos resultados em uma mesma configuração de ambiente; excetua-se a análise de robustez apresentada na Seção 4.2, que varia deliberadamente a semente de particionamento. Cabe registrar, contudo, que a fixação de semente assegura determinismo apenas dentro de uma mesma versão das bibliotecas: alterações de implementação interna entre versões do scikit-learn (PEDREGOSA *et al.*, 2011) podem produzir variações marginais nas métricas e na ordenação de features de importância próxima, sem comprometer as conclusões qualitativas do estudo. Os valores reportados neste trabalho correspondem à execução de referência documentada no notebook que acompanha esta monografia, disponível no repositório do autor (UGULINO, 2026). O repositório contém o código integral do pipeline, as saídas de cada etapa na execução de

referência e o arquivo de ambiente com as versões das bibliotecas utilizadas. O conjunto de dados não é redistribuído; sua origem é a indicada em OLIST (2018).

A multiplicidade de métricas adotada exige hierarquia explícita, sob pena de que algoritmos distintos sejam apontados como superiores conforme o indicador privilegiado, situação efetivamente verificada neste trabalho e discutida na Seção 4.3. A hierarquia decorre da natureza do entregável, e não de preferência entre indicadores: o produto do modelo é uma priorização de clientes em faixas de risco, e não uma decisão binária em um ponto de corte. Em consequência, as métricas que dependem do limiar caracterizam a regra de decisão, porém não medem a qualidade da priorização, razão pela qual não são decisórias. As métricas primárias são, ademais, estimadas sobre as probabilidades out-of-fold do conjunto de treino, conforme já exposto, de modo que a hierarquia e a independência do conjunto de teste constituem um único critério, e não dois.

Cabe registrar a tensão com a recomendação de De la Cruz Huayanay, Bazán e Russo (2025), cujas três métricas são aqui adotadas e reportadas integralmente. Aquelas recomendações dirigem-se à avaliação de regras de decisão binária sob desbalanceamento, propósito distinto do perseguido neste trabalho; sua adoção como critério primário conduziria à seleção de outro algoritmo, conforme discutido na Seção 4.3. A divergência não se resolve por arbitragem entre métricas, mas pela definição prévia do que o modelo entrega. O Quadro 2 sintetiza a hierarquia adotada.

4 AVALIAÇÃO EXPERIMENTAL

4.1 Análise Exploratória dos Dados

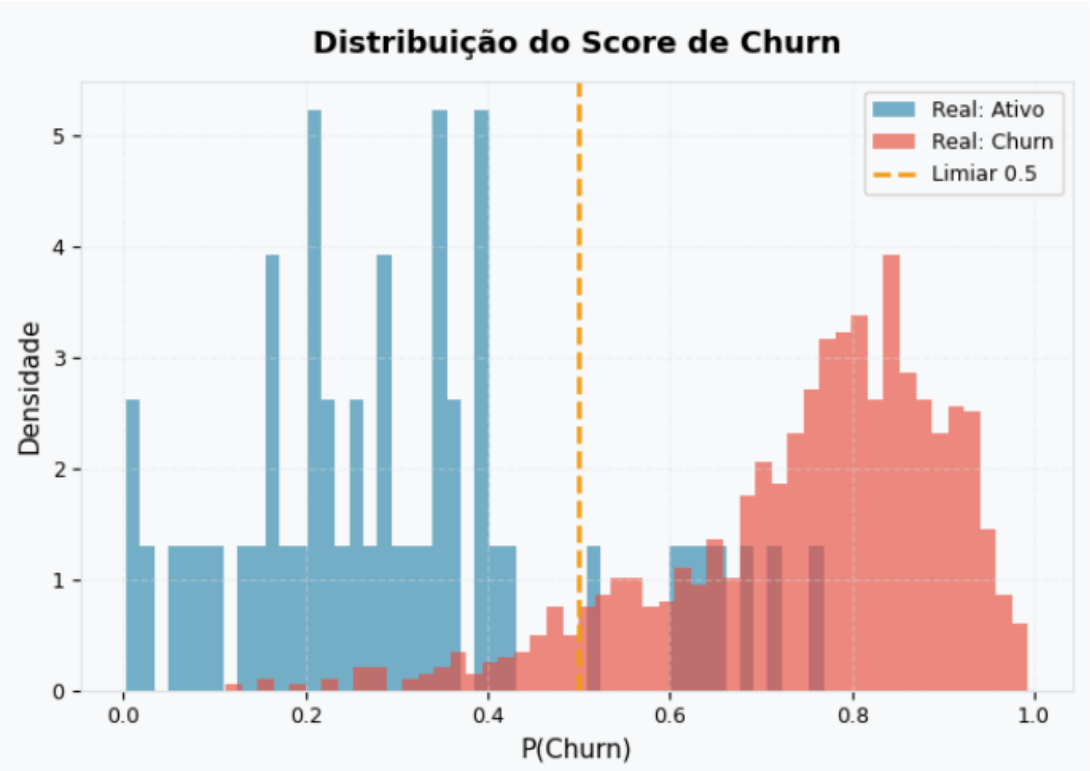
A análise exploratória revelou padrões comportamentais consistentes com a literatura de churn em e-commerce de varejo (MATUSZELAŃSKI; KOPCZEWSKA, 2022). A distribuição de recência demonstra que clientes Ativos situam-se majoritariamente nos primeiros cem dias desde a última compra (66% dos casos), com média de 84 dias, enquanto clientes Churn apresentam distribuição mais dispersa, com média de 126 dias e ocorrências isoladas que ultrapassam 400 dias de ausência. Essa separação confirma a recência, uma das dimensões centrais do framework RFM (HUGHES, 1994), como variável com poder discriminativo relevante.

A análise de frequência, segunda dimensão do RFM, evidencia que ambas as classes apresentam mediana de dois pedidos, mínimo imposto pelo filtro adotado, mas os clientes Ativos exibem média superior (2,56 contra 2,08 pedidos), com maior dispersão e valores extremos de até oito pedidos, contra seis entre os Churn. O review score médio apresenta diferença marginal entre as classes (Ativos: 4,25; Churn: 4,21), sugerindo que a satisfação declarada não é fator determinante isolado para a retenção, indicação de que o churn configura-se como um problema de engajamento, e não de qualidade do serviço (MANZOOR *et al.*, 2024).

O perfil comparativo multivariado confirma que as dimensões mais discriminativas entre Ativos e Churn são o valor monetário total, terceira dimensão do RFM (HUGHES, 1994), com média de R$ 372,25 entre os Ativos contra R$ 299,12 entre os Churn, e o número de categorias distintas, indicador de engajamento não capturado pelo RFM puro (MANZOOR *et al.*, 2024), com média de 1,80 categorias entre os Ativos contra 1,54 entre os Churn. O ticket médio (R$ 150,70 contra R$ 143,97), assim como o tempo de entrega e o review score, não apresentou separação expressiva entre as classes nesta análise univariada, indicando menor relevância preditiva isolada dessas variáveis.

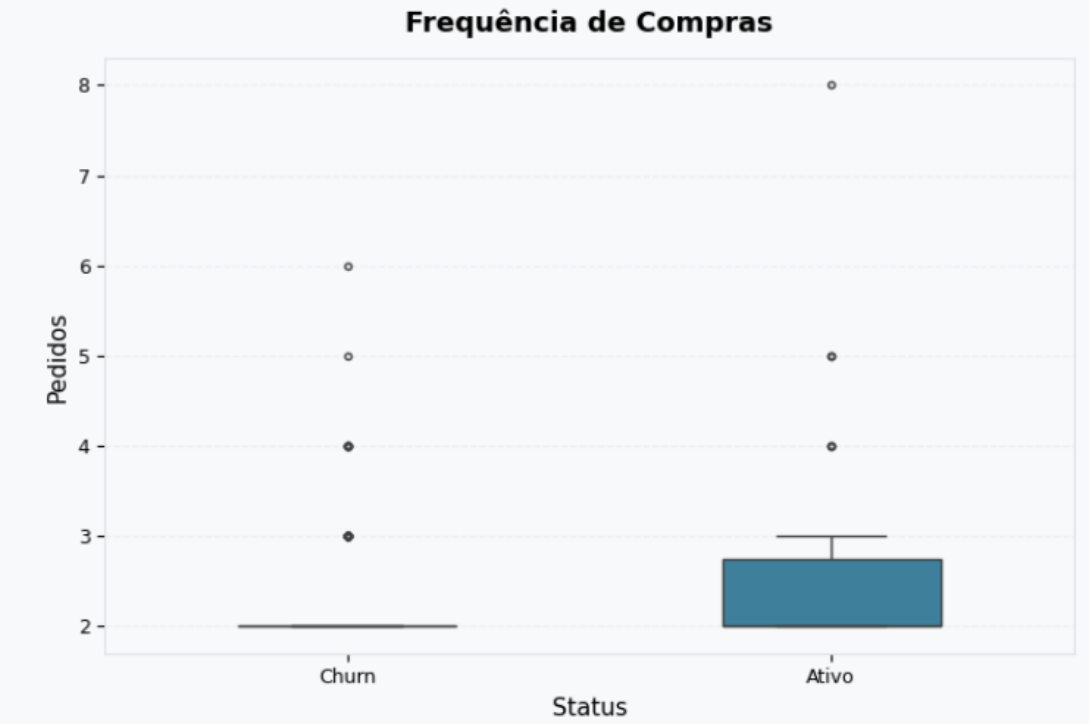
A Figura 3 evidencia a concentração dos clientes Ativos em intervalos curtos desde a última compra, enquanto os clientes Churn dispersam-se por períodos mais longos. A Figura 4 mostra medianas idênticas de dois pedidos, com os Ativos apresentando maior dispersão e valores extremos superiores. A Figura 5 confirma a diferença marginal de review score entre as classes. A Figura 6 explicita o desbalanceamento de 95,8% contra 4,2%.

Figura 3 – Análise exploratória de recência



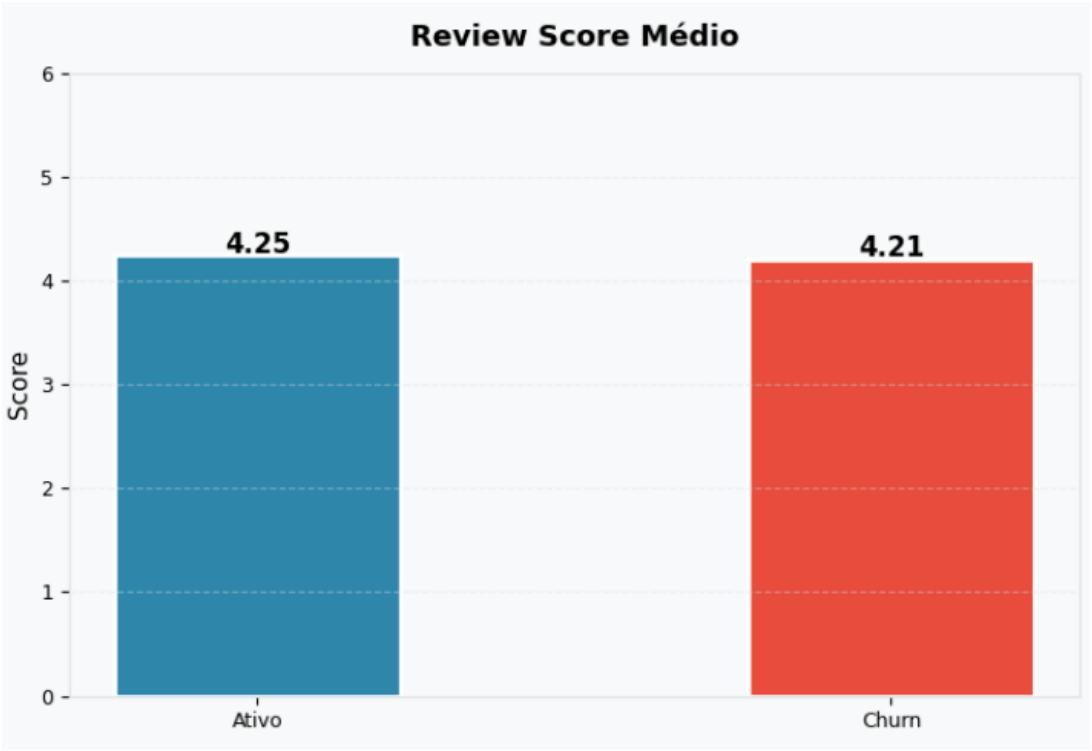
Fonte: elaborado pelo autor.

Figura 4 – Análise exploratória de frequência



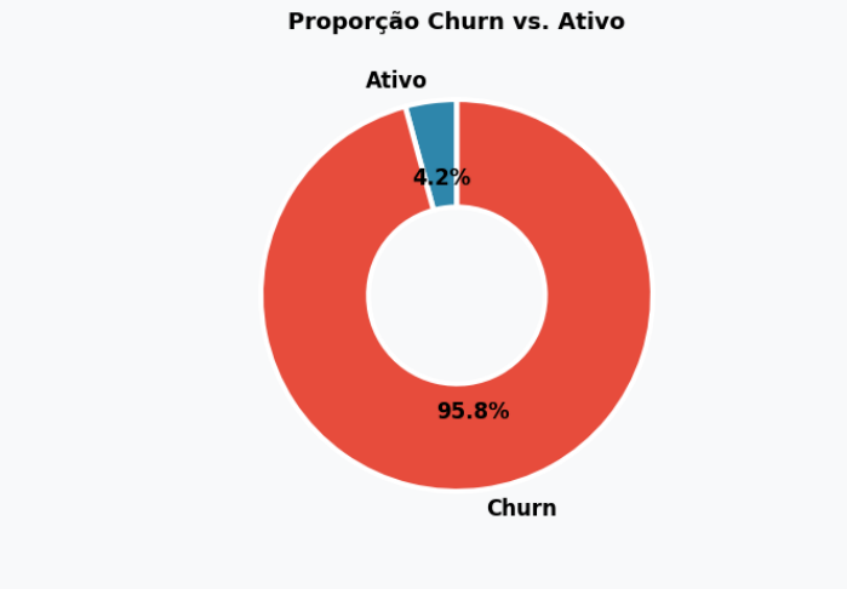
Fonte: elaborado pelo autor.

Figura 5 – Análise exploratória de review score



Fonte: elaborado pelo autor.

Figura 6 – Proporção Churn versus Ativo



Fonte: elaborado pelo autor.

4.2 Comparação Empírica de Estratégias de Balanceamento

A estratégia de reamostragem adotada, descrita na Seção 3.4, foi submetida a comparação empírica com as três alternativas consideradas, sob o protocolo de avaliação da Seção 3.5. As Tabelas 2 e 3 sintetizam os resultados.

Tabela 2 – Comparação empírica de estratégias de balanceamento (split de referência)

Estratégia	N treino	ROC-AUC	CV-AUC	MCC	Kappa	F1-Macro	Rec. Ativo	Rec. Churn	Limiar
Sem balanceamento	942	0,8018	0,6017	0,2983	0,2680	0,6319	0,20	0,9912	0,75
Undersampling puro (1:1)	80	0,7451	0,6080	0,1943	0,1884	0,5930	0,30	0,9425	0,27
SMOTE	1.804	0,7327	0,5928	0,1253	0,1233	0,5610	0,20	0,9469	0,44
Under 3:1 + gaussiano (adotada)	**240**	**0,8106**	**0,6814**	**0,1931**	**0,1918**	**0,5957**	**0,20**	**0,9735**	**0,38**

Fonte: elaborado pelo autor.
Nota: modelo de referência Random Forest (n_estimators = 300, max_depth = 10), mantido fixo nas quatro estratégias; o que se compara aqui são estratégias de reamostragem, não algoritmos. A reamostragem é aplicada dentro de cada partição da validação cruzada, e o limiar de classificação é derivado das probabilidades out-of-fold do conjunto de treino, conforme o protocolo descrito na Seção 3.5. Como o limiar é derivado independentemente em cada estratégia, as métricas dependentes de limiar (MCC, Kappa, F1-Macro e os recalls) são calculadas em pontos de corte distintos e não constituem comparação direta entre estratégias; a comparação estritamente pareada é a das colunas ROC-AUC e CV-AUC.

Tabela 3 – Robustez das estratégias de balanceamento em trinta divisões estratificadas

Estratégia	ROC-AUC média	MCC médio	Kappa médio	Amplitude da ROC-AUC
Sem balanceamento	0,6543 ± 0,0778	0,1168 ± 0,1167	0,1031 ± 0,1004	0,462 - 0,800
Undersampling puro (1:1)	0,6510 ± 0,0769	0,0439 ± 0,0765	0,0392 ± 0,0689	0,501 - 0,802
SMOTE	0,6615 ± 0,0660	0,1060 ± 0,0761	0,0895 ± 0,0696	0,539 - 0,810
Under 3:1 + gaussiano (adotada)	**0,6686 ± 0,0831**	**0,1140 ± 0,0804**	**0,1053 ± 0,0726**	**0,500 - 0,822**

Fonte: elaborado pelo autor.
Nota: aplica-se aqui a mesma observação da Tabela 2 quanto ao modelo de referência e ao protocolo de avaliação. As trinta divisões são sorteios aleatórios estratificados do mesmo conjunto de clientes e do mesmo período, variando apenas a semente de particionamento; medem, portanto, a sensibilidade dos resultados ao particionamento dos dados, e não a generalização para períodos futuros, que demandaria validação respeitando a ordem cronológica.

A comparação empírica das quatro estratégias, conduzida no notebook que acompanha esta monografia e sintetizada nas Tabelas 2 e 3, corrobora a escolha adotada, e o faz sob três evidências de naturezas distintas. Na validação cruzada conduzida exclusivamente sobre o conjunto de treino, critério que não depende do hold-out, a estratégia adotada obteve a maior CV-AUC (0,6814), à frente do undersampling puro (0,6080), da ausência de balanceamento (0,6017) e do SMOTE (0,5928). Para verificar se esse resultado não decorria

de uma partição favorável, o experimento foi repetido em trinta divisões estratificadas independentes, nas quais a estratégia adotada manteve a maior ROC-AUC média (0,669), seguida pelo SMOTE (0,662), pela ausência de balanceamento (0,654) e pelo undersampling puro (0,651). No split de referência, a mesma combinação apresenta a maior ROC-AUC (0,811), à frente da ausência de balanceamento (0,802), do undersampling puro (0,745) e do SMOTE (0,733), evidência que se reporta como descritiva, uma vez que medida sobre o conjunto de teste.

O desempenho inferior do undersampling puro é consistente com a redução drástica do conjunto de treino que a estratégia impõe: com apenas 40 clientes Ativos no treino, o balanceamento 1:1 produz 80 amostras, base insuficiente para algoritmos ensemble. O SMOTE (CHAWLA *et al.*, 2002), por sua vez, interpola entre vizinhos reais, procedimento que em conjuntos pequenos e esparsos tende a gerar instâncias em regiões pouco representativas do espaço de features. A ausência de balanceamento, embora competitiva em ROC-AUC, preserva o viés estrutural para a classe majoritária que a literatura documenta em cenários de desbalanceamento extremo (HE; GARCIA, 2009).

Cabe registrar duas ressalvas. A primeira é que, segundo o Coeficiente de Correlação de Matthews, uma das três métricas recomendadas por De la Cruz Huayanay, Bazán e Russo (2025), a ausência de balanceamento supera a estratégia adotada no split de referência (0,2983 contra 0,1931, Tabela 2). O mesmo se verifica no Kappa de Cohen (0,2680 contra 0,1918) e no F1-Macro (0,6319 contra 0,5957), ambos igualmente favoráveis à ausência de balanceamento nesse split. Cabe observar, contudo, que essa vantagem não se traduz em ganho na classe minoritária: ambas as estratégias identificam corretamente a mesma proporção de clientes Ativos (Recall-Ativo de 0,20), e a diferença de MCC decorre exclusivamente do desempenho na classe majoritária (Recall-Churn de 0,9912 contra 0,9735). Na média das trinta divisões independentes, a diferença praticamente desaparece (MCC de 0,1140 para a estratégia adotada contra 0,1168 para a ausência de balanceamento, com desvios-padrão de 0,0804 e 0,1167), e a estratégia adotada apresenta o maior Kappa médio do conjunto (0,1053). A segunda ressalva é que as diferenças entre as estratégias situam-se dentro de um desvio-padrão, de modo que os resultados indicam tendência, e não superioridade estatisticamente estabelecida. A amplitude da ROC-AUC entre divisões, de 0,500 a 0,822 para a estratégia adotada, decorre do tamanho reduzido da classe Ativo no conjunto de teste (aproximadamente dez instâncias), limitação inerente ao problema e discutida ao longo deste trabalho. Reconhece-se, por fim, que o oversampling por ruído amplia a classe minoritária a partir de uma base amostral reduzida, o que motiva a análise de representatividade conduzida na Seção 4.6.

4.3 Benchmark Comparativo de Algoritmos

A Tabela 4 apresenta os resultados consolidados dos dez algoritmos avaliados, ordenados por ROC-AUC no conjunto de teste e acompanhados das métricas complementares MCC, G-Mean e Kappa, cujos rankings são analisados na Seção 4.4. O Random Forest obteve o melhor desempenho em termos de discriminação global (AUC = 0,8106), seguido pelo HistGradient Boosting (AUC = 0,7615) e pelo Extra Trees (AUC = 0,7491). No extremo oposto, a Árvore de Decisão apresentou o pior resultado (AUC = 0,4772), valor inferior ao do classificador aleatório, cujo AUC teórico é 0,50 (FAWCETT, 2006), seguida pelo KNN (AUC = 0,5336). Em ambos os casos, o desempenho aproxima-se ou situa-se abaixo do classificador aleatório, resultado discutido adiante à luz do protocolo de validação adotado.

Tabela 4 – Benchmark comparativo dos dez algoritmos de Machine Learning

Modelo	AUC	AP	CV-AUC	Δ	F1-Macro	MCC	G-Mean	Kappa	Prec. Ativo	Rec. Ativo	Rec. Churn	Limiar
Random Forest	**0,8106**	**0,9905**	0,6814	−0,1293	0,5957	0,1931	0,4412	0,1918	0,2500	0,20	0,9735	0,38
HistGradient Boosting	0,7615	0,9872	**0,7363**	−0,0252	0,6049	0,2143	**0,5342**	0,2110	0,2143	**0,30**	0,9513	0,18
Extra Trees	0,7491	0,9860	0,6777	−0,0714	0,5649	0,1639	0,3148	0,1370	0,3333	0,10	0,9912	0,34
Regressão Logística	0,7075	0,9838	0,6326	−0,0749	**0,6440**	**0,3517**	0,4462	**0,2939**	**0,6667**	0,20	**0,9956**	0,12
SVM	0,7035	0,9833	0,6238	−0,0798	0,4920	0,0250	0,4111	0,0197	0,0541	0,20	0,8451	0,37
Gradient Boosting	0,6642	0,9796	0,6695	+0,0053	0,5339	0,0679	0,3106	0,0678	0,1111	0,10	0,9646	0,08
Naive Bayes	0,6405	0,9552	0,6390	−0,0015	0,5887	0,1778	0,4402	0,1775	0,2222	0,20	0,9690	0,01
AdaBoost	0,5544	0,9694	0,5372	−0,0172	0,5725	0,2100	0,3155	0,1547	0,5000	0,10	**0,9956**	0,47
KNN	0,5336	0,9596	0,5913	+0,0577	0,5143	0,0314	0,3063	0,0307	0,0667	0,10	0,9381	0,09
Árvore de Decisão	0,4772	0,9559	0,6119	+0,1347	0,4592	0,0178	0,4708	0,0112	0,0484	**0,30**	0,7389	0,61

Fonte: elaborado pelo autor.
Nota: Δ é a diferença com sinal entre CV-AUC e AUC no hold-out, isto é, Δ = CV-AUC − AUC. Valores positivos indicam desempenho reamostrado superior ao observado fora da amostra, única direção compatível com otimismo do procedimento de validação; valores negativos indicam o oposto e não constituem evidência de sobreajuste. AP designa a Average Precision para a classe Churn, cuja linha de base no conjunto de teste é 0,958, valor correspondente à prevalência dessa classe; a informação relevante nessa coluna é a comparação entre modelos, e não a magnitude absoluta. Rec. Ativo corresponde à proporção das dez instâncias da classe Ativo do conjunto de teste corretamente identificadas. O limiar de cada modelo foi derivado das probabilidades out-of-fold do conjunto de treino, conforme a Seção 3.5, e todas as métricas dependentes de limiar foram calculadas nesse valor. Nenhum modelo foi descartado pelo critério de diferença entre validação cruzada e hold-out. O melhor valor de cada métrica aparece em negrito, com empates assinalados em todas as linhas correspondentes. Duas colunas não recebem destaque por não admitirem um ótimo: Δ é diagnóstico direcional, de modo que o valor mais próximo de zero não designa o melhor modelo, mas a maior concordância entre duas estimativas igualmente sujeitas a erro amostral; e o limiar é parâmetro da regra de decisão, derivado independentemente para cada algoritmo, e não medida de desempenho. Cabe ainda observar que valores elevados de Rec. Churn acompanhados de Rec. Ativo baixo refletem o viés para a classe majoritária descrito por He e Garcia (2009), e não desempenho superior.

A validação cruzada, conduzida com a reamostragem aplicada dentro de cada partição, não indicou sobreajuste em nenhum dos dez algoritmos. A leitura do Δ exige, contudo, atenção ao sinal. Apenas valores positivos, em que a estimativa reamostrada supera a observada fora da amostra, são compatíveis com o otimismo que caracteriza o sobreajuste ao procedimento de validação. Sob essa definição, somente três algoritmos apresentam Δ positivo, a saber, a Árvore de Decisão (+0,1347), o KNN (+0,0577) e o Gradient Boosting (+0,0053); nos sete restantes o desempenho no hold-out superou o da validação cruzada, situação que não configura sobreajuste. O Random Forest encontra-se entre estes últimos, com Δ de $-0{,}1293$, de modo que sua magnitude elevada decorre de desempenho no hold-out superior ao reamostrado, e não do contrário.

Essa observação impõe uma segunda qualificação, relativa à magnitude. A classe Ativo dispõe de apenas dez instâncias no conjunto de teste, o que torna a ROC-AUC ali estimada sujeita a erro amostral substancial. Pela aproximação de Hanley e McNeil (1982), com dez observações de uma classe e 226 da outra, o erro padrão da ROC-AUC do Random Forest é de aproximadamente 0,084, de modo que o intervalo de confiança de 95% para aquele valor abrange de 0,65 a 0,97, amplitude de 0,33. Diferenças entre CV-AUC e hold-out de magnitude inferior a essa amplitude são, portanto, compatíveis com variabilidade amostral entre partições, sem necessidade de recurso a qualquer hipótese sobre o ajuste do modelo. Os erros padrão dos demais algoritmos situam-se na mesma ordem de grandeza, entre 0,084 e 0,097, uma vez que dependem majoritariamente do tamanho da classe minoritária, comum a todos.

Em consequência, o limite de 0,15 fixado na Seção 3.5 é rebaixado à condição de diagnóstico descritivo, e não de critério de exclusão: sua função é sinalizar divergências que mereçam inspeção, não estabelecer um teste de sobreajuste, para o qual o regime amostral deste trabalho não oferece poder estatístico. Nenhum modelo foi excluído por esse critério, que, portanto, não participou da escolha do modelo adotado. Registra-se, ainda, que um corte simétrico de 0,10 sobre o valor absoluto descartaria a Árvore de Decisão e o Random Forest conjuntamente, embora seus Δ apontem em direções opostas, o que ilustra por que a formulação em valor absoluto, adotada na concepção inicial deste trabalho, é inadequada ao fim pretendido. Esse resultado contrasta com o obtido na concepção inicial deste trabalho, em que a validação cruzada era conduzida sobre o conjunto de treino já balanceado. Naquele protocolo, instâncias sintéticas geradas por perturbação de uma mesma observação original distribuíam-se entre folds distintos, e o modelo avaliava, na partição de validação, quase duplicatas de exemplos vistos no ajuste. O efeito da correção é sistemático e ordena-se pela capacidade de memorização de cada algoritmo: a estimativa de validação cruzada caiu 0,3251 no AdaBoost, 0,3222 no KNN e 0,2657 no Extra Trees, contra apenas 0,0789 na Regressão Logística e 0,0634 no Naive Bayes, modelos paramétricos cuja estrutura não permite memorizar instâncias próximas. O caso do KNN é ilustrativo: sua estimativa de validação cruzada passou de 0,9135 para 0,5913, valor compatível com

o desempenho de 0,5336 obtido no hold-out. Conclui-se que a diferença entre validação cruzada e hold-out observada na concepção inicial media vazamento de informação entre partições, e não sobreajuste ao conjunto de treino.

Sob as três métricas recomendadas por De la Cruz Huayanay, Bazán e Russo (2025), o modelo indicado seria o HistGradient Boosting: ele lidera o G-Mean (0,5342, o maior valor do conjunto) e ocupa a segunda posição em MCC (0,2143) e em Kappa de Cohen (0,2110). É também um dos dois algoritmos que identificam o maior número de clientes Ativos, três das dez instâncias do hold-out, empatado com a Árvore de Decisão mas com precisão muito superior (0,2143 contra 0,0484), e o que apresenta a menor diferença entre validação cruzada e hold-out entre os três modelos de melhor desempenho (0,0252), além da maior CV-AUC do conjunto (0,7363). A liderança isolada em MCC (0,3517) e Kappa (0,2939) cabe, contudo, à Regressão Logística, cuja vantagem não se sustenta na classe minoritária: o modelo identifica as mesmas duas instâncias Ativas que o Random Forest, e sua superioridade decorre integralmente da redução de falsos negativos, isto é, de clientes Churn incorretamente classificados como Ativos (um caso contra seis). Trata-se do mesmo padrão registrado na Seção 4.2 a respeito da ausência de balanceamento. O Random Forest, por sua vez, lidera a ROC-AUC (0,8106) e a Average Precision para a classe Churn (0,9905), as duas métricas do conjunto que independem do limiar de classificação e que medem, portanto, a qualidade da ordenação dos clientes por risco.

Os valores absolutos de MCC e Kappa de Cohen, com máximos de 0,35 e 0,29 respectivamente entre os dez modelos, situam-se abaixo do limiar usualmente associado a concordância substancial (LANDIS; KOCH, 1977). É importante enfatizar que essa limitação decorre estruturalmente da composição do conjunto de teste: com apenas dez instâncias da classe Ativo em um hold-out de 236 clientes, no qual a proporção de 4,2% da base foi preservada, qualquer erro de classificação na classe minoritária impacta desproporcionalmente o MCC e o Kappa, comportamento previsto analiticamente por Luque *et al.* (2019) e coerente com a sensibilidade do MCC a todos os quadrantes da matriz de confusão, destacada por Chicco e Jurman (2020). A mesma escassez restringe o número de configurações possíveis da matriz de confusão: o Recall da classe Ativo assume apenas três valores distintos entre os dez algoritmos avaliados (0,10, 0,20 e 0,30), e nenhum modelo ultrapassa três acertos em dez. Não se trata de falha algorítmica, mas de consequência matemática do desbalanceamento extremo preservado no hold-out, escolha metodológica deliberada para preservar a validade da avaliação em condições reais de operação.

Os três modelos de melhor desempenho, Random Forest, HistGradient Boosting e Regressão Logística, apresentam perfis distintos de vantagens e desvantagens, sintetizados no Quadro 3. A inclusão da Regressão Logística no quadro decorre de sua liderança isolada em MCC e Kappa de Cohen: sob as métricas recomendadas por De la Cruz Huayanay, Bazán e Russo (2025), ela é candidata obrigatória, ainda que a literatura a trate como

modelo de referência e não como concorrente dos ensembles (PRABADEVI; SHALINI; KAVITHA, 2023). A escolha entre os três não é absoluta, mas está condicionada ao objetivo do negócio e à estrutura de custos da operação de retenção.

Quadro 3 – Análise de vantagens e desvantagens dos três modelos de melhor desempenho

Modelo	**Vantagens**	**Desvantagens**
Random Forest (selecionado)	Maior ROC-AUC (0,8106) e maior Average Precision para a classe Churn (0,9905), as duas métricas que independem do limiar e medem a qualidade da ordenação dos clientes por risco; melhor captura de clientes Ativos em cobertura fixa, liderando ou empatando em todas as frações avaliadas entre 10% e 60% do conjunto de teste; alcança 90% dos clientes Ativos abordando 35,6% das observações, a menor cobertura entre os três modelos; retém nove dos dez clientes Ativos do conjunto de teste fora da faixa Crítico, em 39,0% das observações, lift de 2,31 vezes; importância de features nativa via impureza de Gini, requisito do objetivo específico (4).	Menores MCC (0,1931), Kappa de Cohen (0,1918) e G-Mean (0,4412) entre os três modelos; identifica duas das dez instâncias Ativas do hold-out, contra três do HistGradient Boosting; menor Average Precision para a classe Ativo (0,1494, contra 0,2559 do HistGradient Boosting), métrica dominada pelo extremo inicial da ordenação; maior distância em módulo entre validação cruzada e hold-out entre os três (Δ de $-0{,}1293$, negativo e, portanto, sem relação com sobreajuste); ROC-AUC média em validação cruzada de 0,6814, inferior aos 0,7363 do HistGradient Boosting; maior custo de memória em implantação.

Modelo	Vantagens	Desvantagens
HistGradient Boosting (alternativo)	Lidera o G-Mean (0,5342, o maior valor do conjunto de dez algoritmos); segundo maior MCC (0,2143) e Kappa de Cohen (0,2110); identifica três das dez instâncias Ativas do hold-out, o maior número entre os três modelos; maior Average Precision para a classe Ativo entre os três (0,2559), o que indica acerto no extremo inicial da ordenação; maior CV-AUC do conjunto (0,7363) e menor diferença em relação ao hold-out entre os três (0,0252); treino rápido em dados tabulares.	ROC-AUC de 0,7615, inferior aos 0,8106 do Random Forest; scores concentrados no extremo superior da escala (primeiro quartil de 0,7927 e mediana de 0,9621, contra 0,6545 e 0,7781 do Random Forest), o que aloca 77,6% da base completa e 79,7% do conjunto de teste na faixa Crítico, reduzindo as demais faixas a 9,6%, 5,6% e 7,2% na base completa e a 8,1%, 5,9% e 6,4% no conjunto de teste; captura menos clientes Ativos que o Random Forest em todas as coberturas entre 20% e 50% do conjunto de teste, e requer 49,6% de cobertura para alcançar 90% dos Ativos, contra 35,6% do Random Forest; retém três dos dez clientes Ativos fora da faixa Crítico, em 20,3% das observações, lift de 1,48 vezes; menor Recall da classe Churn entre os três (0,9513); o HistGradientBoostingClassifier não expõe medida nativa de importância de features, o que inviabiliza a análise de estabilidade da ordenação por Gini conduzida na Seção 4.7.

Modelo	Vantagens	Desvantagens
Regressão Logística (referência sob métricas de decisão binária)	Lidera isoladamente o MCC (0,3517) e o Kappa de Cohen (0,2939), duas das três métricas recomendadas por De la Cruz Huayanay, Bazán e Russo (2025); maior Precisão na classe Ativo (0,6667) e maior Recall na classe Churn (0,9956) entre os dez algoritmos; distribuição de scores mais dispersa dos três modelos (intervalo interquartílico de 0,3614, contra 0,2056 do Random Forest), ocupando as quatro faixas de risco de forma mais uniforme (5,8%, 31,2%, 33,4% e 29,6% na base completa); modelo paramétrico, de baixo custo computacional e interpretação direta por coeficientes, cuja estrutura não permite memorizar instâncias, o que se reflete na queda de apenas 0,0789 entre a estimativa de validação cruzada vazada e a corrigida.	Menor ROC-AUC entre os três (0,7075) e menor Average Precision para a classe Churn (0,9838); pior captura de clientes Ativos em cobertura fixa, com dois dos dez em 20% do conjunto de teste, contra quatro do Random Forest, e lift de 0,98 vezes nessa cobertura, valor indistinguível do acaso; requer 52,5% de cobertura para alcançar 90% dos clientes Ativos, a maior dos três modelos, e 66,9% das observações para reter dez dos dez Ativos fora da faixa Crítico, lift de 1,49 vezes; sua vantagem em MCC e Kappa decorre integralmente da redução de falsos negativos na classe majoritária (um caso contra seis do Random Forest) e não de ganho na classe Ativo, na qual identifica as mesmas duas instâncias; não dispõe de medida de importância por impureza, requisito do objetivo específico (4).

Fonte: elaborado pelo autor.

Nota: as grandezas deste quadro são medidas no conjunto de teste e destinam-se à caracterização do comportamento dos três modelos de melhor desempenho, não tendo fundamentado a escolha entre eles. A seleção foi conduzida sobre as probabilidades out-of-fold do conjunto de treino, conforme descrito a seguir e na Seção 3.5.

A seleção do modelo adotado foi conduzida em dois estágios e, em ambos, sem recurso ao conjunto de teste. O primeiro estágio é de elegibilidade e decorre do objetivo específico (4), declarado antes de qualquer experimento: a análise de importância de features do modelo escolhido apoia-se na impureza de Gini e na estabilidade dessa ordenação entre partições. Permanecem elegíveis, por conseguinte, apenas os estimadores que expõem medida nativa de importância por impureza, a saber, Random Forest, Extra Trees, Gradient Boosting, Árvore de Decisão e AdaBoost. O HistGradient Boosting não a expõe, tampouco a Regressão Logística, o SVM, o KNN e o Naive Bayes. Trata-se de restrição de escopo decorrente dos objetivos do trabalho, e não de juízo de desempenho.

O segundo estágio ordena os modelos elegíveis segundo a natureza do entregável, e todas as grandezas nele empregadas foram estimadas sobre as probabilidades out-of-fold

do conjunto de treino (n = 942, dos quais 40 clientes Ativos), as mesmas de que se deriva o limiar conforme a Seção 3.5. O primeiro aspecto é a qualidade da ordenação dos clientes por risco, uma vez que a estratificação em faixas não constitui decisão binária em um ponto de corte, mas priorização dependente da posição relativa de cada cliente na escala de scores. Sob esse aspecto, o Random Forest apresenta a maior área sob a curva ROC fora da amostra entre os elegíveis (0,6784, contra 0,6739 do Extra Trees, 0,6702 do Gradient Boosting, 0,6087 da Árvore de Decisão e 0,5347 do AdaBoost) e captura o maior número de clientes Ativos quando a cobertura é fixada em 30% da base (23 dos 40, contra 21 do Gradient Boosting e 19 do Extra Trees). O segundo aspecto é a usabilidade da segmentação em faixas, que constitui o produto descrito na Seção 4.8: aplicados às mesmas probabilidades out-of-fold os cortes da Tabela 8, o Random Forest aloca 55,0% dos clientes na faixa Crítico e retém 28 dos 40 Ativos fora dela, isto é, 70,0% dos clientes recuperáveis, ao custo de 45,0% de cobertura e com lift de 1,56. Entre os elegíveis, constitui o melhor compromisso: o Gradient Boosting alcança lift superior (2,03), mas concentra 81,5% da base na faixa Crítico e retém apenas 15 dos 40 Ativos; o Extra Trees retém 31, porém exige 58,6% de cobertura, com lift de 1,32; e o AdaBoost degenera, alocando 0,1% na faixa Crítico e exigindo a abordagem de 99,9% da base, com lift unitário.

Registra-se explicitamente o que esses mesmos critérios indicariam na ausência da restrição de elegibilidade. O HistGradient Boosting apresenta a maior área sob a curva ROC fora da amostra entre os dez algoritmos avaliados (0,7323, contra 0,6784 do Random Forest) e captura mais clientes Ativos em cobertura fixa, de modo que sua exclusão decorre do requisito de interpretabilidade, e não de inferioridade na ordenação. Em contrapartida, a segmentação dele resultante é substancialmente menos utilizável: sobre as mesmas probabilidades out-of-fold, concentra 75,1% dos clientes na faixa Crítico, contra 55,0% do Random Forest, e retém 22 dos 40 Ativos fora dela, contra 28. Seu recorte é mais preciso por unidade de cobertura (lift de 2,20 contra 1,56), porém estreito: alcança 55,0% dos clientes recuperáveis, ante 70,0% do Random Forest. Essa concentração decorre da dispersão de seus scores, e não da ordenação que produz, e sua correção demandaria calibração prévia de probabilidades, registrada entre os trabalhos futuros. Cabe ainda registrar que, sob as três métricas recomendadas por De la Cruz Huayanay, Bazán e Russo (2025), aplicáveis à avaliação de decisões binárias, o modelo adotado não seria o Random Forest, que ocupa a quarta posição em MCC e em G-Mean e a terceira em Kappa de Cohen; a escolha recairia sobre o HistGradient Boosting ou sobre a Regressão Logística, que empatam em posição média nos três rankings (1,67 cada). Esse empate é ilustrativo: as métricas recomendadas apontam a inadequação do Random Forest para a decisão binária, mas não desempatam entre si, o que reforça que o critério de escolha precisa vir da natureza do entregável.

Concluída a seleção, o conjunto de teste foi empregado uma única vez, para a avaliação final do modelo adotado. Os valores de hold-out reportados na Tabela 4 e nos

parágrafos seguintes possuem, portanto, caráter de estimativa final e de caracterização comparativa do comportamento dos dez algoritmos, não tendo participado da decisão. Reconhece-se que as diferenças entre os modelos elegíveis situam-se dentro de um desvio-padrão da variabilidade entre partições documentada na Tabela 3, de modo que a seleção indica tendência, e não superioridade estatisticamente estabelecida.

Registra-se, ademais, uma limitação operacional do HistGradient Boosting relativa à distribuição de suas probabilidades preditas. Aplicado à base completa, esse modelo concentra os scores junto do extremo superior da escala (primeiro quartil de 0,7927, mediana de 0,9621 e terceiro quartil de 0,9915), enquanto o Random Forest mantém a distribuição centrada em valores intermediários da escala (primeiro quartil de 0,6545, mediana de 0,7781 e terceiro quartil de 0,8601) e a Regressão Logística, a mais dispersa das três (primeiro quartil de 0,4204, mediana de 0,6000 e terceiro quartil de 0,7818). Esse deslocamento das probabilidades para a classe majoritária do treino é coerente com o viés induzido pelo treinamento em conjunto artificialmente balanceado, formalizado por Dal Pozzolo *et al.* (2015), e manifesta-se de forma mais acentuada no HistGradient Boosting do que nos demais, sem prejuízo da ordenação relativa dos clientes, o que explica a preservação de seu ROC-AUC. A consequência prática recai sobre a granularidade da segmentação de risco em faixas apresentada na Seção 4.8. Aplicados os mesmos limiares da Tabela 8 à base completa, o HistGradient Boosting aloca 77,6% dos clientes na faixa Crítico e distribui os demais em 9,6% no Baixo, 5,6% no Médio e 7,2% no Alto, contra 58,1%, 2,3%, 8,6% e 31,0% do Random Forest e 29,6%, 5,8%, 31,2% e 33,4% da Regressão Logística, respectivamente. O mesmo padrão reproduz-se no conjunto de teste, o que afasta a hipótese de artefato das observações de treino: nele o HistGradient Boosting aloca 79,7% dos clientes na faixa Crítico, restando 8,1% no Baixo, 5,9% no Médio e 6,4% no Alto, enquanto o Random Forest aloca 61,0% no Crítico, 30,9% no Alto, 6,4% no Médio e 1,7% no Baixo, e a Regressão Logística, 33,1%, 31,8%, 30,1% e 5,1%. A escala do modelo alternativo comporta, portanto, essencialmente uma faixa útil, o que compromete a capacidade de priorizar clientes por grau de risco. Registra-se, contudo, que a dispersão da escala não é, isoladamente, critério de escolha: a Regressão Logística apresenta a distribuição mais uniforme dos três modelos e o pior desempenho na identificação de clientes recuperáveis por unidade de cobertura, conforme se demonstra a seguir.

Cabe dimensionar o trade-off em termos absolutos. A vantagem do HistGradient Boosting na detecção da classe minoritária corresponde a um cliente Ativo adicional identificado entre os dez do conjunto de teste, ao custo de onze falsos negativos na classe Churn contra seis do Random Forest. Do ponto de vista da operação de retenção, a comparação relevante é a concentração de clientes Ativos nas faixas de menor risco, necessariamente restrita ao conjunto de teste, uma vez que a base completa contém as observações utilizadas no ajuste. Nesse recorte, o Random Forest reúne dois dos dez clientes Ativos em 8,1% das observações, lift de 2,48 vezes, e o HistGradient Boosting reúne três

em 14,0%, lift de 2,15 vezes. A diferença entre os dois valores corresponde a um único cliente e não autoriza afirmar superioridade de qualquer dos modelos, de modo que esse critério não se presta ao desempate. Adotando-se o recorte complementar, a exclusão da faixa Crítico, o Random Forest retém nove dos dez clientes Ativos em 39,0% do conjunto de teste, lift de 2,31 vezes, contra três dos dez em 20,3% do HistGradient Boosting, lift de 1,48 vezes, e dez dos dez em 66,9% da Regressão Logística, lift de 1,49 vezes. A Regressão Logística alcança a totalidade dos clientes Ativos, mas ao custo de abordar dois terços do conjunto de teste, cobertura que descaracteriza o próprio propósito da priorização.

Os três recortes acima entregam frações distintas do conjunto de teste, o que faz o lift refletir simultaneamente a qualidade da ordenação e o ponto em que o corte de 75% incide sobre a distribuição de cada modelo. Para isolar a ordenação, os clientes foram ordenados do menor para o maior score e mediu-se, em coberturas fixas, quantos dos dez clientes Ativos do conjunto de teste seriam alcançados. O Random Forest lidera ou empata em todas as coberturas avaliadas: em 30% das observações captura oito dos dez clientes Ativos, contra seis do HistGradient Boosting e cinco da Regressão Logística; em 40%, nove contra oito e sete; e em 50%, dez contra nove e oito. Consequentemente, alcança 90% dos clientes Ativos abordando 35,6% do conjunto de teste, contra 49,6% do HistGradient Boosting e 52,5% da Regressão Logística. Abaixo de 30% de cobertura nenhum dos três modelos ultrapassa quatro acertos em dez, e a partir de 60% os três alcançam a totalidade dos Ativos, de modo que a escolha do modelo só produz efeito operacional relevante no intervalo intermediário, precisamente aquele em que o Random Forest apresenta vantagem. Cabe a ressalva de que o conjunto de teste contém apenas dez clientes Ativos, de modo que cada unidade capturada equivale a dez pontos percentuais de Recall e diferenças de um único cliente não são conclusivas.

Some-se a isso que o HistGradientBoostingClassifier não expõe medida nativa de importância de features. A análise de interpretabilidade conduzida na Seção 4.7, requisito do objetivo específico (4), apoia-se na importância por impureza de Gini e na estabilidade dessa ordenação em trinta partições estratificadas, ambas indisponíveis para o modelo alternativo. Os valores SHAP permaneceriam calculáveis, e são efetivamente empregados na Tabela 7 como terreno comum de comparação entre os três modelos, mas isoladamente não reproduziriam a evidência de estabilidade, que é estimada sobre a ordenação por Gini. Replicar a análise exigiria substituir o estimador pela importância por permutação, que a própria Seção 4.7 mostra não ser informativa neste regime amostral, ajuste que extrapola o escopo deste trabalho. O HistGradient Boosting permanece recomendado como alternativa, condicionada à aplicação prévia de técnicas de calibração de probabilidades, como Platt scaling ou regressão isotônica, cuja eficácia na correção de probabilidades produzidas por boosting foi demonstrada empiricamente por Niculescu-Mizil e Caruana (2005), especialmente em contextos de custo por contato elevado, nos quais a redução de falsos positivos é prioritária.

4.4 Correlação entre Rankings de Métricas

A análise de correlação de Spearman entre os rankings dos dez modelos revelou comportamento heterogêneo entre as métricas avaliadas. Os rankings por ROC-AUC e por Kappa de Cohen apresentam a correlação mais elevada do conjunto (rho = 0,6485), única estatisticamente significativa ao nível de 5% (p = 0,043). A correlação com o ranking por MCC é moderada e não significativa (rho = 0,5515; p = 0,098), e a correlação com o ranking por G-Mean é fraca (rho = 0,2970; p = 0,405), indicando que essas duas métricas ordenam os modelos de maneira substancialmente distinta.

A divergência é evidenciada de forma direta pelo próprio ranking, que produz três vencedores distintos entre os quatro critérios avaliados: o Random Forest lidera a ROC-AUC (0,8106), o HistGradient Boosting lidera o G-Mean (0,5342) e a Regressão Logística lidera simultaneamente o MCC (0,3517) e o Kappa (0,2939). Nenhum dos três modelos ocupa a primeira posição em mais de dois dos quatro critérios, e o líder por ROC-AUC figura apenas na quarta posição do ranking de G-Mean.

Esse resultado converge com a recomendação de De la Cruz Huayanay, Bazán e Russo (2025) contra o uso isolado da ROC-AUC, ainda que por evidência de natureza distinta: enquanto aqueles autores avaliam, em simulação, a capacidade de cada métrica de identificar o modelo verdadeiro, este trabalho observa a divergência entre rankings de modelos em dados reais. A fraca associação entre os rankings de ROC-AUC e G-Mean justifica a adoção do portfólio de métricas complementares utilizado neste trabalho e reforça a necessidade de que estudos comparativos de churn em e-commerce não se limitem à ROC-AUC como único critério avaliativo. Cabe registrar, contudo, que os coeficientes foram estimados sobre apenas dez observações, de modo que os valores devem ser interpretados como indicativos da tendência observada neste conjunto de modelos, e não como estimativas populacionais precisas; apenas uma das três correlações atinge significância ao nível de 5%.

4.5 Análise do Limiar de Classificação e Curvas de Desempenho

A análise do ponto de corte para o Random Forest, apresentada na Figura 9, indicou que o limiar que maximiza o Kappa de Cohen sobre as probabilidades out-of-fold do conjunto de treino situa-se em 0,38, abaixo do valor padrão de 0,50 (FAWCETT, 2006). Esse resultado decorre do treinamento em um conjunto balanceado artificialmente, procedimento que altera as probabilidades a priori e, por consequência, enviesa as probabilidades posteriores estimadas pelo modelo, fenômeno formalizado analiticamente por Dal Pozzolo *et al.* (2015). O deslocamento é evidenciado pela própria distribuição das probabilidades preditas no conjunto de teste, cuja mediana é de 0,779 e cujo valor mínimo é de 0,112, indicando concentração na faixa superior da escala. A proximidade entre as distribuições

out-of-fold do treino (mediana de 0,772) e do hold-out (mediana de 0,779) confirma que o limiar derivado da primeira transfere-se adequadamente ao segundo.

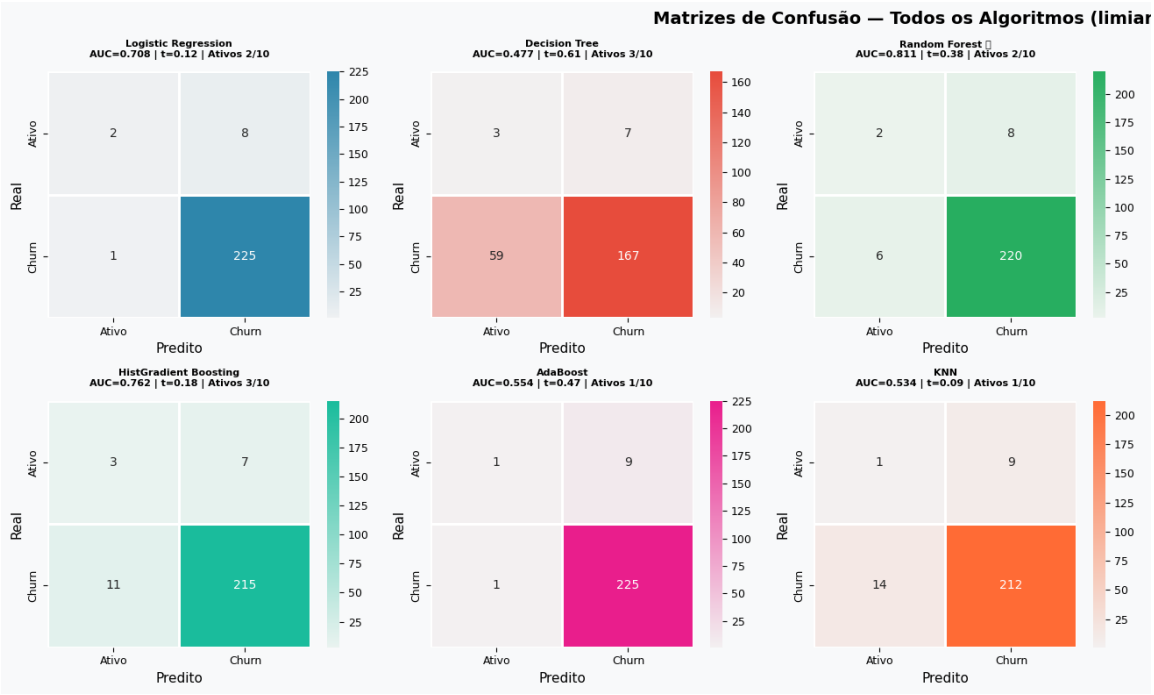
Cabe dimensionar o efeito do procedimento de derivação do limiar. O valor de 0,38, obtido sobre o conjunto de treino, produz Kappa de 0,1918 no hold-out. Caso o limiar fosse selecionado diretamente sobre o conjunto de teste, como na concepção inicial deste trabalho, o valor escolhido seria 0,34 e o Kappa reportado seria 0,2254. A diferença de 0,0336 entre os dois valores corresponde exatamente ao viés otimista que a seleção do limiar no conjunto de avaliação incorpora ao resultado, e a magnitude desse viés não pode ser conhecida sem que se disponha do procedimento correto como referência. Todas as métricas dependentes de limiar reportadas neste trabalho foram calculadas no limiar derivado do treino.

No limiar padrão de 0,50, 91,9% dos clientes de teste são classificados como Churn, proporção inferior à real (95,8%), o que indica que parte dos clientes que de fato não retornaram recebe probabilidade prevista abaixo de 0,50 e seria incorretamente classificada como Ativo. A redução do limiar para 0,38 atenua esse deslocamento, ampliando a cobertura da classe majoritária ao custo de maior número de falsos positivos, isto é, de clientes Ativos incorretamente classificados como Churn, trade-off dimensionado na Seção 4.3. Cabe registrar que o viés decorrente do balanceamento afeta as métricas dependentes de limiar, mas não a ordenação das probabilidades preditas (DAL POZZOLO *et al.*, 2015), o que corrobora a adoção de métricas independentes de limiar como critério primário de seleção.

As matrizes de confusão resultantes (Figuras 7 e 8) confirmam a elevada capacidade de identificação da classe Churn, com Recall de 0,97 (220 das 226 instâncias), e evidenciam, ao mesmo tempo, a limitação imposta pela classe Ativo, representada por apenas dez instâncias no conjunto de teste, das quais duas são corretamente identificadas. O teto observado entre os dez algoritmos avaliados é de três acertos em dez (Tabela 4), obtido pelo HistGradient Boosting e pela Árvore de Decisão, o que situa o desempenho do modelo adotado próximo ao máximo alcançável neste regime amostral e reforça que a limitação é da base, e não do algoritmo.

A Curva Precision-Recall (Figura 10) corrobora a qualidade preditiva do modelo, análise especialmente apropriada em desbalanceamento severo (SAITO; REHMSMEIER, 2015). A Average Precision (AP) para a classe Churn é de 0,9905, valor que deve ser lido contra a linha de base de 0,958 correspondente à prevalência dessa classe no conjunto de teste. A informação útil dessa métrica está, portanto, na comparação entre modelos, e não em sua magnitude absoluta, que é estruturalmente alta em qualquer classificador sob esse grau de desbalanceamento. Para a classe Ativo, minoritária, a AP situa-se em 0,1494, aproximadamente 3,5 vezes o baseline de um classificador aleatório (0,042), desempenho superior ao acaso, mas limitado pela escassez de exemplos positivos, apenas dez instâncias

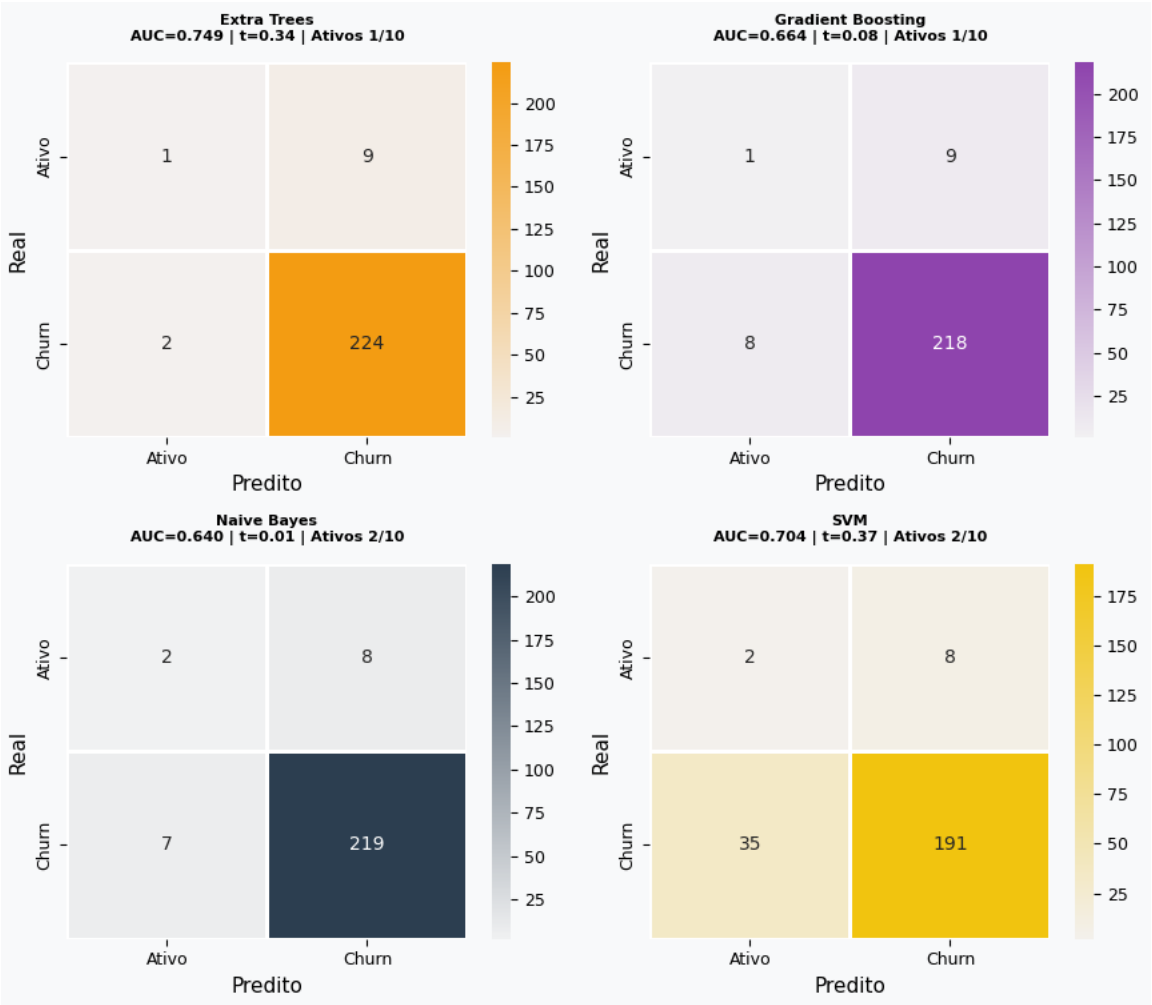
Figura 7 – Matrizes de confusão do Logistic Regression, Decision Tree, Random Forest, Extra Trees e Gradient Boosting no conjunto de teste (limiar out-of-fold)



Fonte: elaborado pelo autor.

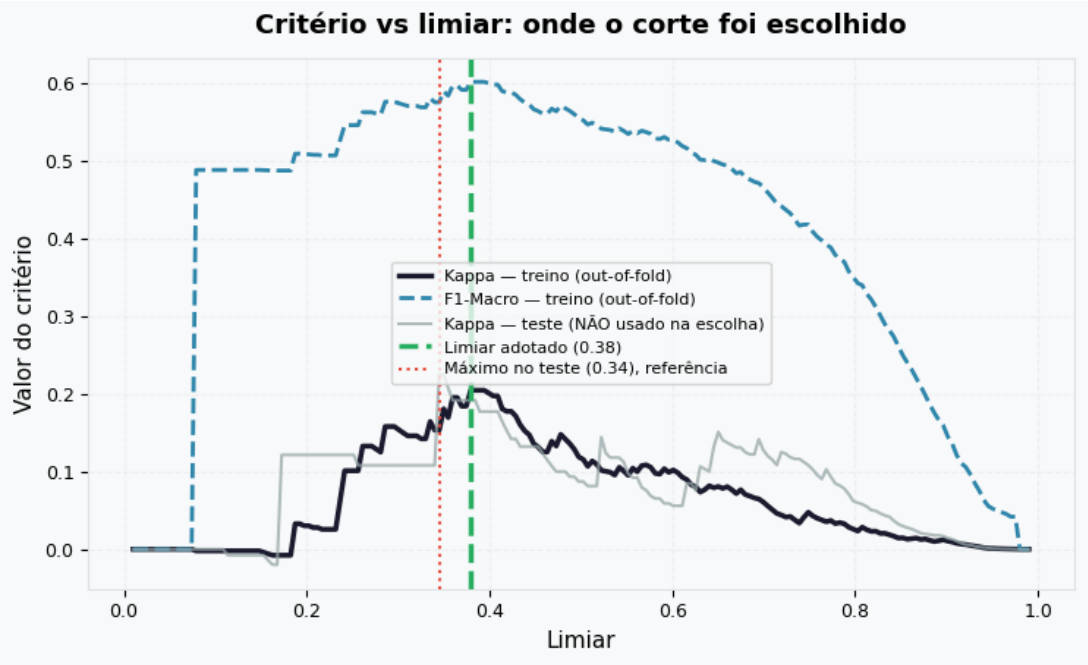
no conjunto de teste. Os valores correspondentes nos dois modelos concorrentes são de 0,2559 no HistGradient Boosting e 0,1749 na Regressão Logística, divergência analisada na Seção 4.3.

Figura 8 – Matrizes de confusão do HistGradient Boosting, AdaBoost, KNN, Naive Bayes e SVM no conjunto de teste (limiar out-of-fold)



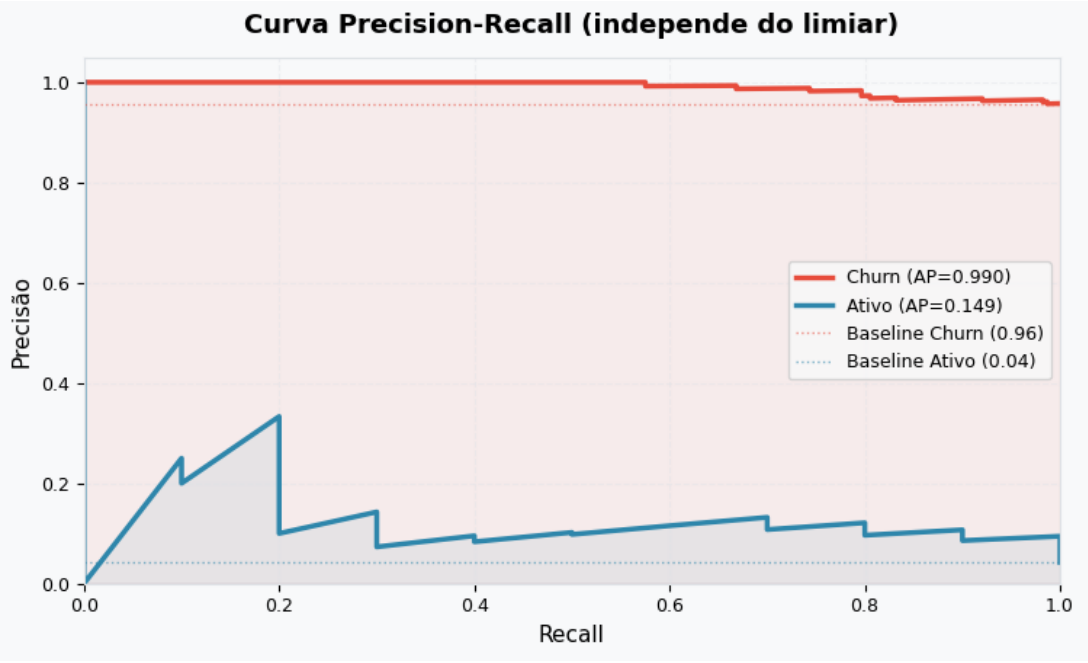
Fonte: elaborado pelo autor.

Figura 9 – Critério de escolha do ponto de corte em função do limiar (Random Forest)



Fonte: elaborado pelo autor.

Figura 10 – Curva Precision-Recall por classe, independente do limiar (Random Forest)



Fonte: elaborado pelo autor.

4.6 Validação da Representatividade do Balanceamento

A fim de verificar se o subconjunto da classe Churn retido no treino após o undersampling aleatório preserva a distribuição estatística da classe original (HE; GARCIA, 2009), foram aplicados dois testes complementares: o Population Stability Index (PSI) e o teste de Kolmogorov-Smirnov (KS). A comparação contrapõe as 1.128 observações da classe Churn completa às 120 efetivamente utilizadas no treino após o undersampling na razão 3:1, correspondentes a uma taxa de retenção de 10,6%. A Tabela 5 apresenta os resultados para as nove features numéricas.

Tabela 5 – Validação de representatividade via PSI e KS-test (features numéricas)

Feature	Tipo	N Completo	N Retido	PSI	KS	p-valor	Status
recency_days	Contínua	1.128	120	0,0375	0,0574	0,845	Representativa
frequency	Discreta	1.128	120	0,0039	0,0041	1,000	Representativa
monetary	Contínua	1.128	120	0,0209	0,0418	0,987	Representativa
avg_ticket	Contínua	1.128	120	0,0265	0,0473	0,958	Representativa
avg_delivery_days	Contínua	1.128	120	0,0340	0,0537	0,896	Representativa
avg_review_score	Contínua	1.128	120	0,0103	0,0305	1,000	Representativa
avg_installments	Contínua	1.128	120	0,1293	0,1035	0,182	Atenção
avg_freight	Contínua	1.128	120	0,0602	0,0812	0,448	Representativa
n_categories	Discreta	1.128	120	0,0022	0,0101	1,000	Representativa

Fonte: elaborado pelo autor.

Oito das nove features apresentaram PSI inferior a 0,10, limiar de instabilidade convencionalmente adotado, com p-valores do teste KS superiores a 0,44, indicando ausência de diferença estatisticamente significativa entre as distribuições. A única exceção é a variável avg_installments, cujo PSI de 0,1293 situa-se na faixa de atenção, ainda que o teste KS não rejeite a hipótese de igualdade das distribuições ($p = 0{,}182$). Nenhuma feature foi classificada como distorcida.

Esses resultados são consistentes com a preservação da distribuição da classe Churn no subconjunto retido. O peso da conclusão recai sobre o PSI: oito das nove features situam-se abaixo de 0,10 e a nona, avg_installments, permanece na faixa de atenção, sem que nenhuma variável alcance a faixa de distorção. O teste de Kolmogorov-Smirnov entra como verificação complementar, cabendo registrar que a não rejeição da hipótese de igualdade não equivale a demonstrá-la: com 120 observações retidas contra 1.128, a potência do teste é limitada, e diferenças de magnitude moderada não seriam necessariamente detectadas. Tomados em conjunto, os dois indicadores sustentam que o conjunto de treino foi construído sobre uma amostra do Churn real, e não sobre uma versão sistematicamente distorcida da classe majoritária, com desvio restrito a uma única variável de importância intermediária no modelo.

Registra-se que essa verificação alcança o undersampling da classe majoritária. A expansão sintética da classe Ativo, responsável por dois terços das instâncias minoritárias

do conjunto de treino, não é objeto do mesmo teste: com quarenta observações originais, os testes empregados teriam potência insuficiente para distinguir a distribuição sintética da original. Sua adequação é discutida qualitativamente no Quadro 1 e na Seção 4.6.1, e a validação quantitativa da perturbação gaussiana permanece entre os trabalhos futuros.

4.6.1 Discussão: representatividade e clientes informativos

A validação por PSI e KS-test atesta que o undersampling aleatório preserva a distribuição estatística marginal das features. Cabe, contudo, uma reflexão metodológica complementar: a estratégia de seleção aleatória trata todas as observações da classe majoritária como igualmente informativas, hipótese que nem sempre se sustenta. A literatura de aprendizado sensível a instâncias distingue observações seguras, que representam de forma confiável a região central da distribuição, de observações redundantes ou ruidosas, cuja remoção não compromete, e pode até favorecer, a capacidade discriminativa do modelo (KUBAT; MATWIN, 1997).

No contexto deste trabalho, essa perspectiva é particularmente relevante para a classe minoritária, composta por aproximadamente 50 clientes Ativos. Por se tratar de uma amostra reduzida, cada observação da classe Ativo representa parcela expressiva da informação disponível sobre o comportamento de recompra, razão pela qual a perturbação gaussiana adotada no oversampling preserva integralmente as observações originais, em vez de substituí-las por instâncias interpoladas.

Uma extensão natural seria substituir o undersampling aleatório da classe Churn por uma seleção orientada por informatividade, como o one-sided selection (KUBAT; MATWIN, 1997), que remove observações redundantes e ruidosas da classe majoritária, retendo preferencialmente as mais confiáveis. Dado que o undersampling aleatório demonstrou representatividade estatística em oito das nove features analisadas, conforme a Seção 4.6, é razoável esperar que o ganho marginal dessa abordagem seja limitado neste dataset específico, ainda que essa hipótese não tenha sido testada empiricamente. A seleção orientada por informatividade permanece, assim, como direção promissora para bases de maior volume, e é registrada entre os trabalhos futuros.

4.7 Interpretabilidade: Importância das Features e SHAP

A análise de importância de features via impureza de Gini (BREIMAN, 2001) revelou que a frequência de compras é, com folga, a variável mais determinante para a predição do churn, respondendo por 23,19% da importância total do modelo (Tabela 6). As cinco features mais relevantes, frequency (23,19%), recency_days (12,19%), n_categories (11,88%), avg_installments (7,84%) e avg_delivery_days (7,41%), respondem conjuntamente por 62,52% da importância total. Destaca-se que recency_days e n_categories encontram-se em empate técnico: a diferença de importância entre ambas é de

aproximadamente 0,3 ponto percentual, de modo que a ordenação exata entre a segunda e a terceira posições é sensível a variações de implementação e de versão de biblioteca (PEDREGOSA *et al.*, 2011), embora a composição do trio dominante, frequência, recência e diversidade de categorias, permaneça estável entre execuções.

Tabela 6 – Importância das cinco principais features do modelo Random Forest (Gini)

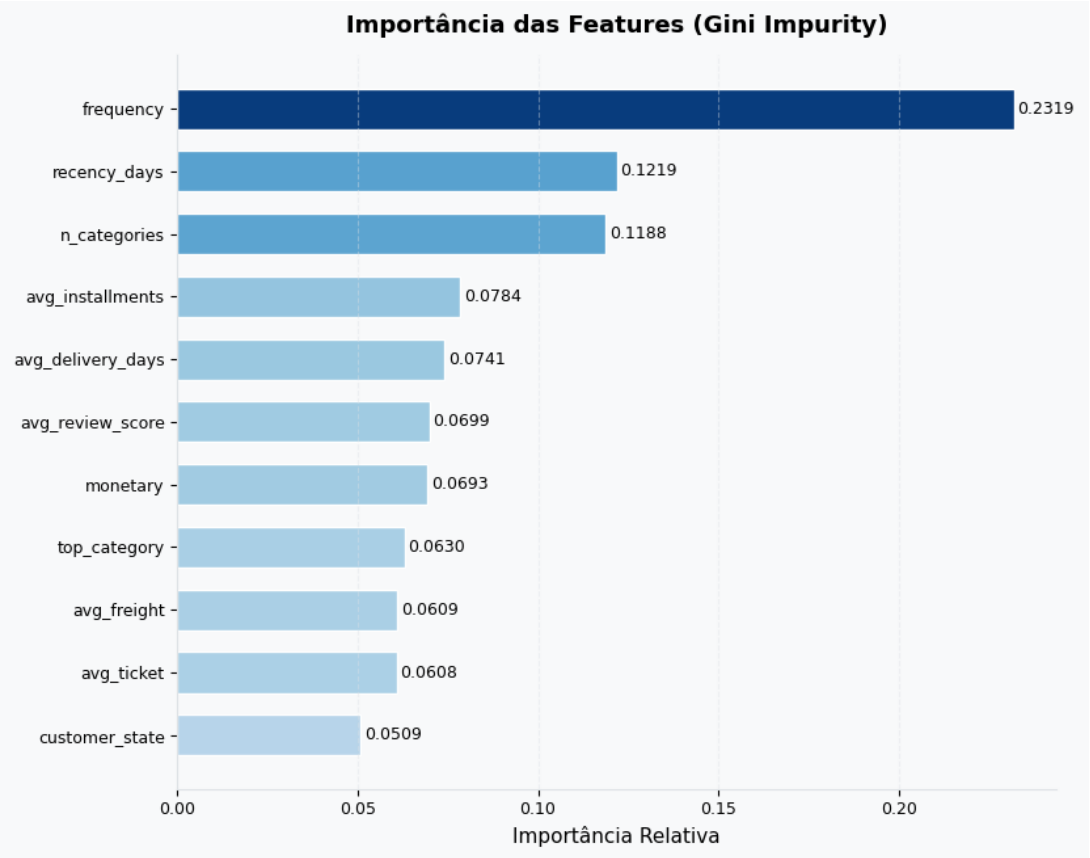
Pos.	**Feature**	**Importância**	**Insight Estratégico**
1ª	frequency	23,19%	Principal driver de recompra: clientes que compram mais vezes apresentam menor propensão ao churn
2ª	recency_days	12,19%	Recência elevada é forte sinal de inatividade iminente; empate técnico com n_categories
3ª	n_categories	11,88%	Diversidade de categorias como proxy de engajamento; empate técnico com recency_days
4ª	avg_installments	7,84%	Uso de parcelamento em mais vezes associa-se a maior risco, sugerindo compras pontuais em vez de relacionamento recorrente
5ª	avg_delivery_days	7,41%	Tempo de entrega como fator de experiência que influencia a decisão de retorno

Fonte: elaborado pelo autor.
Nota: recency_days e n_categories apresentam importâncias em empate técnico, com diferença de aproximadamente 0,3 ponto percentual. Dada essa proximidade, a ordenação exata entre a 2ª e a 3ª posições não deve ser interpretada como hierarquia estabelecida, ainda que a composição do trio dominante permaneça consistente. As importâncias são apresentadas com duas casas decimais; o total de 62,52% reportado no texto é calculado sobre os valores sem arredondamento, cuja soma é 0,625163.

O resultado para n_categories (número de categorias distintas adquiridas) merece destaque especial: sua presença consistente entre os três principais drivers preditivos, em empate técnico com a recência, sugere que a diversidade de categorias de compra é um forte indicador de engajamento com a plataforma. A Figura 11 apresenta a importância relativa de todas as variáveis, evidenciando o domínio de frequency e a proximidade entre recency_days e n_categories, e a Figura 12 destaca o recorte das cinco primeiras posições. Esse achado reforça a relevância da diversidade de compras como indicador de engajamento, aspecto pouco explorado na literatura de churn aplicada ao Olist. Clientes que compram em múltiplas categorias tendem a apresentar maior propensão ao retorno, o que representa insumo relevante para estratégias de cross-selling visando à retenção (KOTLER; KELLER, 2016).

A análise SHAP via TreeExplainer (LUNDBERG *et al.*, 2020) enriquece o ranking de Gini ao revelar as direções dos efeitos (Figura 14). A Figura 13 apresenta a importância média absoluta dos valores SHAP, cuja ordenação pode ser confrontada diretamente com a da Figura 11. A concordância entre os dois métodos é elevada: as quatro features mais

Figura 11 – Importância das features por impureza de Gini (Random Forest)

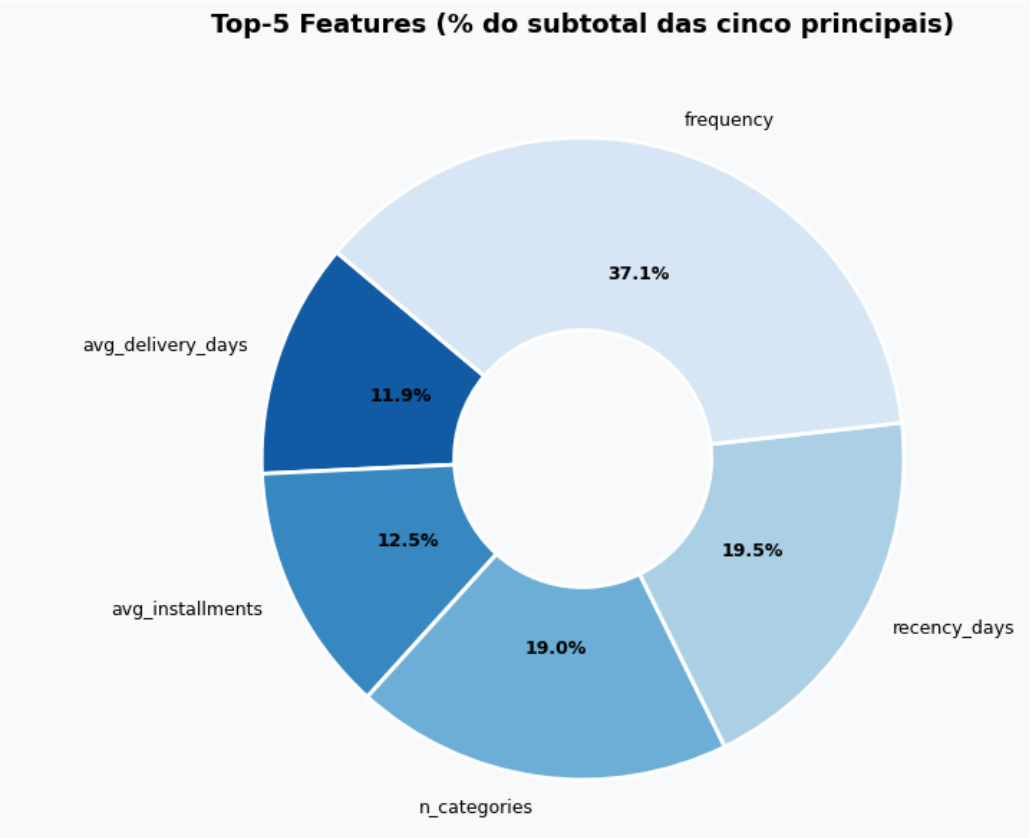


Fonte: elaborado pelo autor.

relevantes ocupam posições idênticas em ambos os rankings, com divergência superior a uma posição em apenas duas das onze variáveis. Cabe registrar, contudo, que essa concordância não constitui validação independente da hierarquia de importância. A importância por impureza de Gini quantifica a redução de impureza produzida por cada variável nas árvores ajustadas, e o TreeSHAP percorre exatamente essas mesmas árvores para decompor as predições: ambos os estimadores derivam da mesma estrutura de modelo, de modo que sua concordância é esperada por construção. A evidência de estabilidade adotada neste trabalho é de outra natureza e apresenta-se a seguir. O valor base do modelo, $\mathbb{E}[f(x)] = 0{,}504$, reflete o balanceamento aplicado ao conjunto de treino, conforme discutido na Seção 4.5.

Para verificar a estabilidade da ordenação por critério independente do estimador, o modelo foi reajustado em trinta partições estratificadas independentes, registrando-se a posição de cada feature no ranking de importância por Gini em cada uma delas. A variável frequency ocupou a primeira posição nas trinta partições, sem exceção. A variável n_categories permaneceu entre as três primeiras em 29 das trinta, com posições variando entre a segunda e a quarta, e recency_days em 22 das trinta, com posições entre a segunda e a quinta. A variável seguinte em estabilidade, monetary, figurou entre as três primeiras em apenas quatro partições, o que delimita com clareza o trio dominante.

Figura 12 – Top-5 Features por impureza de Gini (Random Forest)

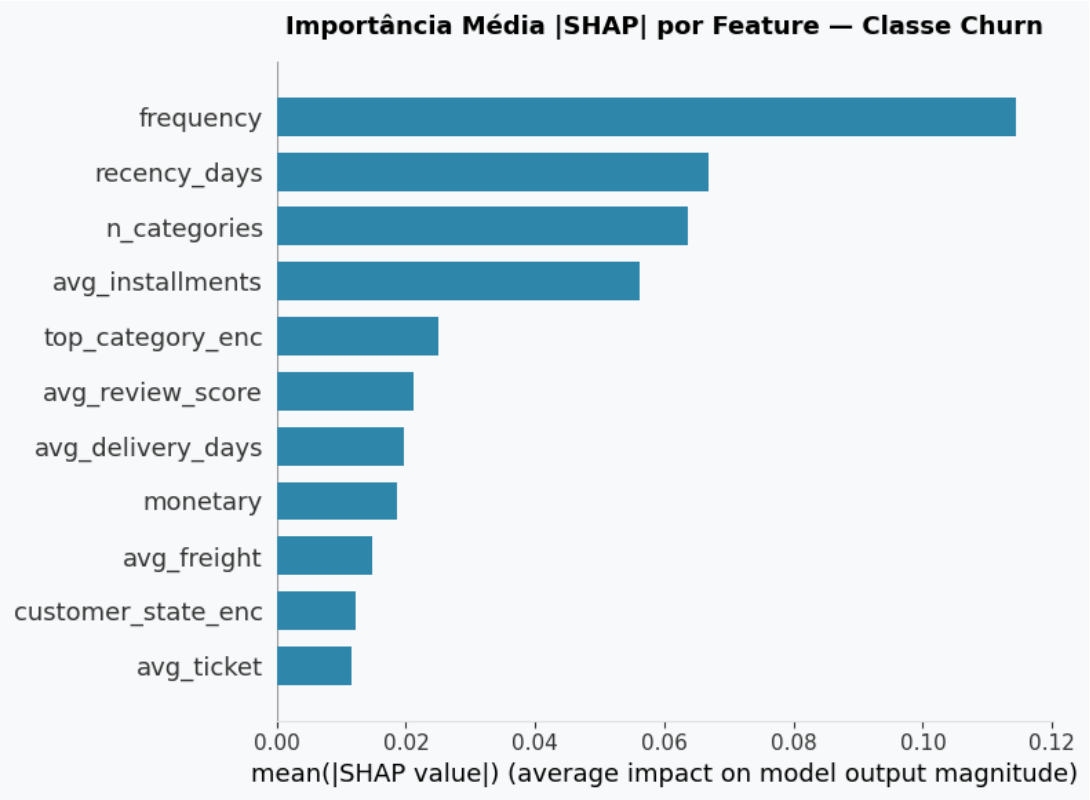


Fonte: elaborado pelo autor.

Esse resultado sustenta a afirmação de estabilidade da hierarquia entre partições e, adicionalmente, confirma o empate técnico entre recency_days e n_categories registrado na Tabela 6: embora a recência esteja 0,3 ponto percentual à frente na partição de referência, a diversidade de categorias apresenta posição média superior no conjunto das trinta partições (2,30 contra 3,17).

Registra-se, por completude, que um terceiro estimador de importância, a permutação de features calculada sobre o conjunto de teste, produz ordenação distinta das duas anteriores, elevando avg_installments à primeira posição e deslocando frequency para a quarta. Esse estimador não é informativo no regime amostral deste trabalho: com dez instâncias da classe Ativo no hold-out, o desvio-padrão de cada estimativa situa-se entre 44% e 93% da respectiva média nas nove variáveis de média positiva, e as duas restantes apresentam média negativa, valor que não admite interpretação substantiva. A imprecisão é suficiente para dissolver a própria ordenação que o estimador produz: a primeira e a segunda colocadas, avg_installments (0,0788 $\pm$ 0,0449) e recency_days (0,0721 $\pm$ 0,0508), apresentam intervalos amplamente sobrepostos. A divergência observada não refuta, portanto, a ordenação por Gini, mas impede que se afirme robustez da hierarquia ao método de estimação, razão pela qual a estabilidade entre partições foi adotada como evidência.

Figura 13 – Importância média |SHAP| das features (Random Forest)



Fonte: elaborado pelo autor.

A análise de interpretabilidade conduzida até aqui apoia-se no Random Forest, modelo adotado. Cabe verificar em que medida a hierarquia de importância obtida é propriedade dos dados ou artefato do estimador escolhido. A importância por impureza de Gini não permite essa verificação, por não estar disponível no HistGradientBoostingClassifier nem se aplicar a modelos lineares. Os valores SHAP, ao contrário, são calculáveis para os três modelos e constituem, portanto, o único terreno comum de comparação. A Tabela 7 apresenta a posição de cada feature no ranking por importância média absoluta e sua participação relativa no total de cada modelo, calculadas sobre o mesmo conjunto de teste.

A convergência entre os três estimadores é substancial e estatisticamente significativa: a correlação de Spearman entre os rankings é de 0,800 entre Random Forest e HistGradient Boosting ($p = 0{,}003$) e de 0,709 nos dois pares que envolvem a Regressão Logística ($p = 0{,}015$). A recência ocupa a segunda posição nos três modelos, sem exceção, o que a torna o achado mais robusto da análise de interpretabilidade. A frequência lidera nos dois modelos baseados em árvores e cai para a terceira posição no modelo linear, resultado coerente com a natureza da relação: o beeswarm plot evidencia que o efeito da frequência é essencialmente descontínuo, concentrado na diferença entre dois pedidos e mais de dois, padrão que um modelo linear captura apenas parcialmente.

Registram-se duas divergências relevantes. A primeira é a variável avg_installments,

Tabela 7 – Posição e participação relativa das features no ranking por importância média |SHAP| nos três modelos

Feature	**Pos. RF**	**Pos. HistGB**	**Pos. RL**	**% RF**	**% HistGB**	**% RL**
frequency	1ª	1ª	3ª	27,0	19,4	13,9
recency_days	2ª	2ª	2ª	15,7	13,4	19,0
n_categories	3ª	6ª	4ª	15,0	8,2	10,6
avg_installments	4ª	4ª	1ª	13,2	11,7	21,0
top_category	5ª	5ª	7ª	5,9	9,5	6,1
avg_review_score	6ª	9ª	8ª	5,0	4,9	5,8
avg_delivery_days	7ª	3ª	6ª	4,7	11,8	6,4
monetary	8ª	7ª	9ª	4,4	6,4	4,7
avg_freight	9ª	11ª	11ª	3,5	4,3	2,5
customer_state	10ª	8ª	10ª	2,9	5,9	3,7
avg_ticket	11ª	10ª	5ª	2,7	4,6	6,4

Fonte: elaborado pelo autor.
Nota: RF designa o Random Forest, HistGB o HistGradient Boosting e RL a Regressão Logística. Os valores absolutos de |SHAP| *não são comparáveis entre modelos e por isso não são reportados: o TreeExplainer aplicado ao Random Forest devolve contribuições em espaço de probabilidade, ao passo que o HistGradient Boosting e a Regressão Logística as devolvem em log-odds. São comparáveis a posição no ranking e a participação relativa, esta definida como a importância média absoluta da feature dividida pela soma das importâncias das onze features do mesmo modelo. Para a Regressão Logística os valores foram obtidos por LinearExplainer, que sob independência de features corresponde à forma fechada apresentada na Seção 2.6. Conjunto de teste, n = 236.*

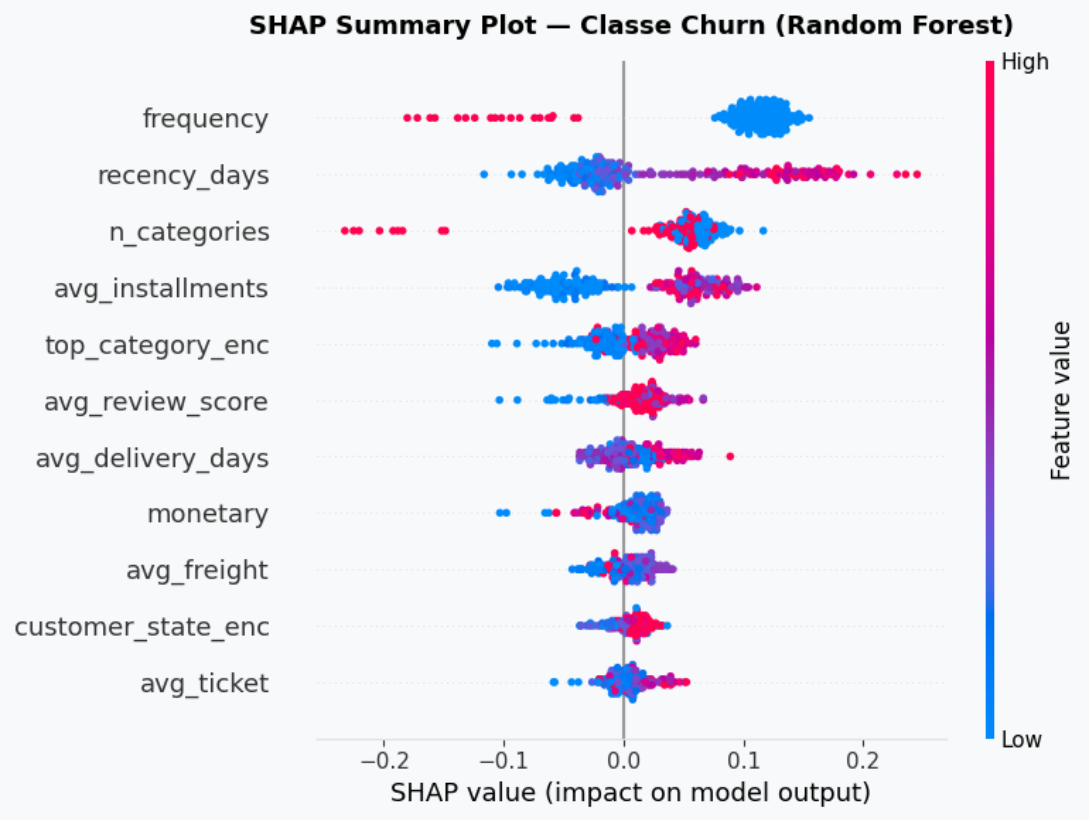
que ocupa a primeira posição na Regressão Logística e a quarta nos dois ensembles; sua elevação também havia sido observada pela importância por permutação, o que constitui indício independente de que seu peso é subestimado pelo Gini, ainda que aquele estimador não seja informativo neste regime amostral. A segunda é avg_delivery_days, terceira no HistGradient Boosting e sétima no Random Forest, deslocamento que sugere sensibilidade do algoritmo de boosting a limiares do tempo de entrega não capturados pelo ensemble por bagging. A variável n_categories, terceira no Random Forest e quarta na Regressão Logística, cai para a sexta posição no HistGradient Boosting, de modo que a composição do trio dominante identificada nesta seção é confirmada por dois dos três estimadores, e não pelos três.

O beeswarm plot evidencia que valores baixos de frequency (poucos pedidos) aumentam significativamente a probabilidade predita de churn, enquanto valores altos a reduzem, relação capturada por uma correlação de $-0{,}862$ entre o valor da feature e sua contribuição SHAP. Para n_categories, o padrão é análogo (correlação de $-0{,}648$): clientes com maior diversidade de categorias apresentam contribuições SHAP negativas para o churn, ou seja, a diversidade reduz o risco predito. Para recency_days, a direção é a esperada e a associação é a mais forte entre as três (correlação de $+0{,}895$): maior recência eleva o risco de churn. Os dependence plots e os waterfall plots de instâncias

representativas, apresentados ao final desta seção, detalham respectivamente os limiares não lineares dessas relações e a decomposição individual da predição para clientes típicos de cada classe.

Registra-se, como divergência pontual entre os métodos, que a variável top_-category ocupa a quinta posição no ranking SHAP, três posições acima do observado pela impureza de Gini. Esse deslocamento sugere que a categoria dominante de compra exerce efeito direcional mais relevante do que a redução de impureza isoladamente permite inferir, achado consistente com a limitação conhecida da importância por Gini em variáveis categóricas de cardinalidade elevada.

Figura 14 – Valores SHAP (beeswarm) das features no conjunto de teste



Fonte: elaborado pelo autor.

4.7.1 Perfil do cliente que retorna: leitura sob a ótica da retenção

Embora a variável-alvo seja formalmente o churn, os valores SHAP permitem inverter a leitura e caracterizar diretamente o perfil do cliente que volta a comprar, objetivo de maior valor acionável para a organização. As contribuições SHAP que reduzem a probabilidade de churn correspondem, por complementaridade, aos atributos associados à retenção. Sob essa ótica, o cliente com maior propensão a retornar à plataforma apresenta o seguinte perfil: (i) realiza compras com maior frequência (2,56 pedidos em média, contra

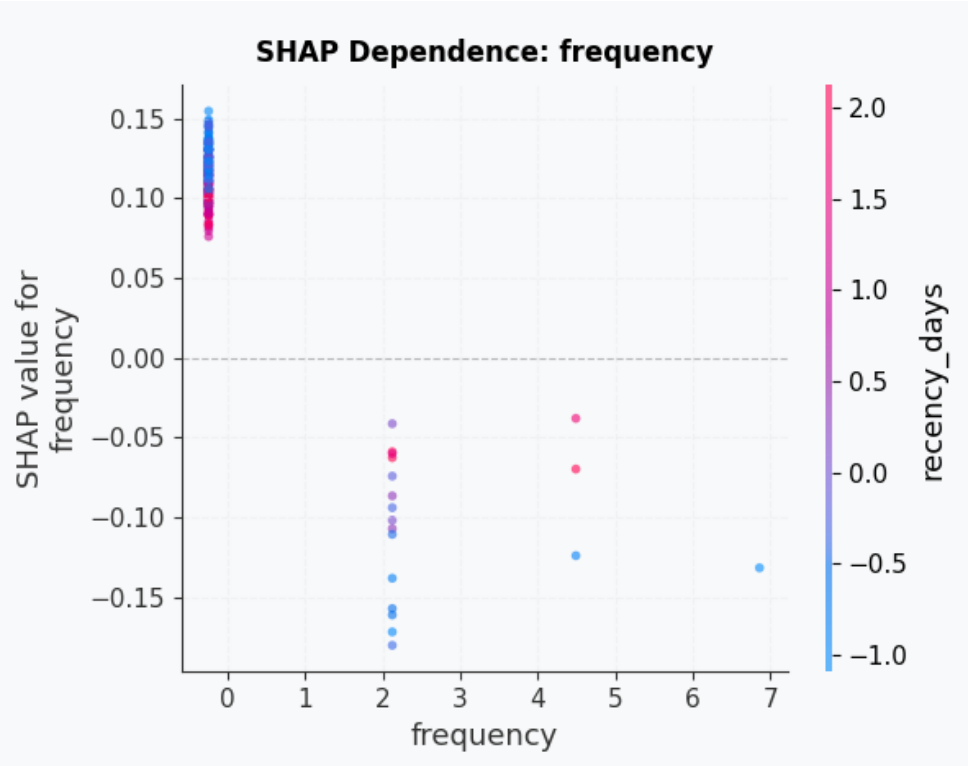
2,08 entre os clientes Churn, conforme a Seção 4.1); (ii) mantém recência baixa, com intervalos curtos entre transações; e (iii) compra em mais categorias distintas (n_categories elevado), indicando exploração ampla do catálogo. Em contraste, o uso de parcelamento em mais vezes (avg_installments elevado) associa-se a maior risco de churn, possivelmente por sinalizar compras pontuais de maior ticket em vez de um relacionamento recorrente com a loja. Cabe observar que essa última variável é a que ocupa a primeira posição no ranking SHAP da Regressão Logística (Tabela 7), o que sugere que seu efeito seja predominantemente monotônico e, por isso, mais bem capturado por um modelo linear.

Esse achado tem implicação estratégica direta: a diversidade de categorias, um dos três principais drivers do modelo, sugere que estimular o cliente a explorar novas categorias, via recomendação e cross-selling, é mecanismo promissor para elevar a probabilidade de retorno (KOTLER; KELLER, 2016). A análise exploratória (Seção 4.1) corrobora esse perfil ao mostrar que clientes Ativos apresentam maior valor monetário acumulado (R$ 372,25 contra R$ 299,12) e compram em categorias mais variadas (1,80 contra 1,54 categorias, em média) que os clientes Churn. Cabe observar que o valor monetário acumulado, embora discrimine as classes na análise exploratória, ocupa apenas a sétima posição na importância por impureza de Gini, o que sugere que seu poder preditivo é em parte absorvido pela frequência de compras, com a qual mantém dependência direta.

Registra-se, como ressalva metodológica, que a classe Ativo conta com aproximadamente 50 clientes na base completa, de modo que o perfil de retenção descrito, ainda que consistente entre a análise exploratória, a importância por Gini estimada em trinta partições e os valores SHAP dos três modelos, deve ser interpretado como hipótese robusta a ser confirmada em bases de maior volume.

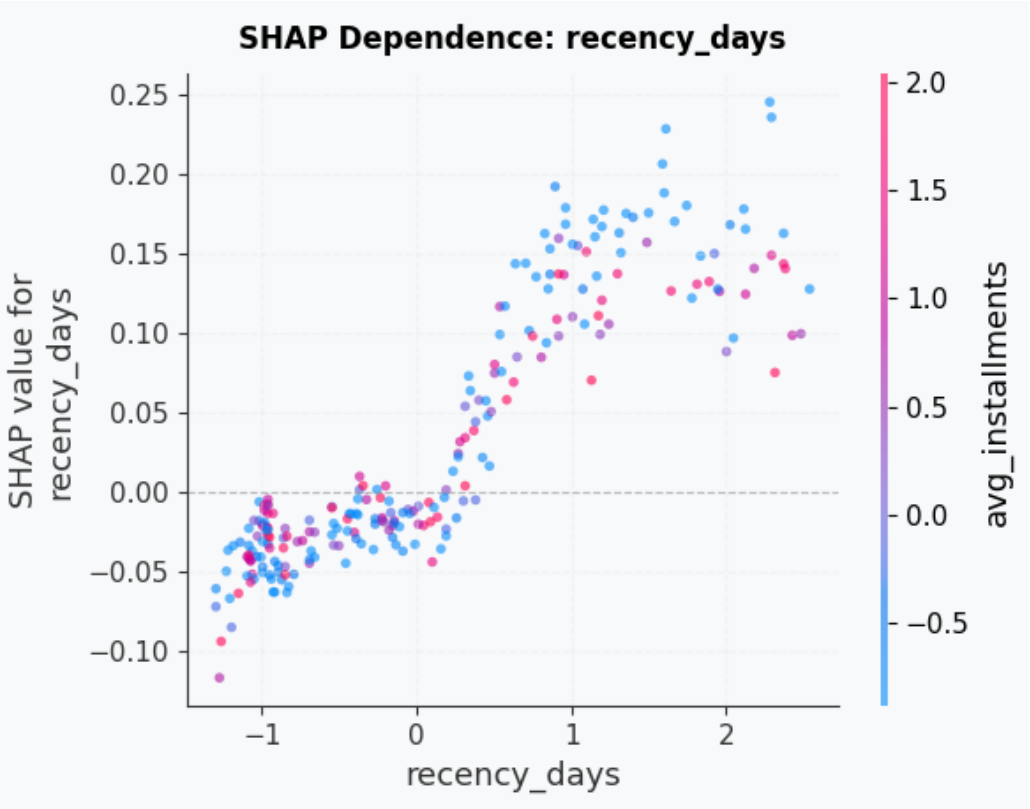
Todos os valores das figuras abaixo referem-se ao Random Forest, modelo adotado nas análises subsequentes, calculados sobre o conjunto de teste. Os dependence plots das Figuras 15, 16 e 17 evidenciam que as relações capturadas pelo modelo não são lineares. Para frequency, as contribuições concentram-se em dois agrupamentos disjuntos: clientes com dois pedidos recebem contribuição positiva para o churn, entre 0,08 e 0,15, e clientes com três ou mais pedidos recebem contribuição negativa, o que caracteriza um limiar de decisão e não uma tendência gradual. Para recency_days a relação é monotônica crescente e aproximadamente sigmóide, com a transição de contribuição negativa para positiva ocorrendo em torno da média da distribuição padronizada. Para n_categories o padrão repete a descontinuidade observada em frequency, com separação nítida entre clientes de uma ou duas categorias e clientes de três ou mais. Essa descontinuidade é a razão estrutural pela qual a frequência perde posições no ranking SHAP da Regressão Logística (Tabela 7): um modelo linear não representa limiares dessa natureza.

Figura 15 – Dependence plots da feature frequency no SHAP (Random Forest)



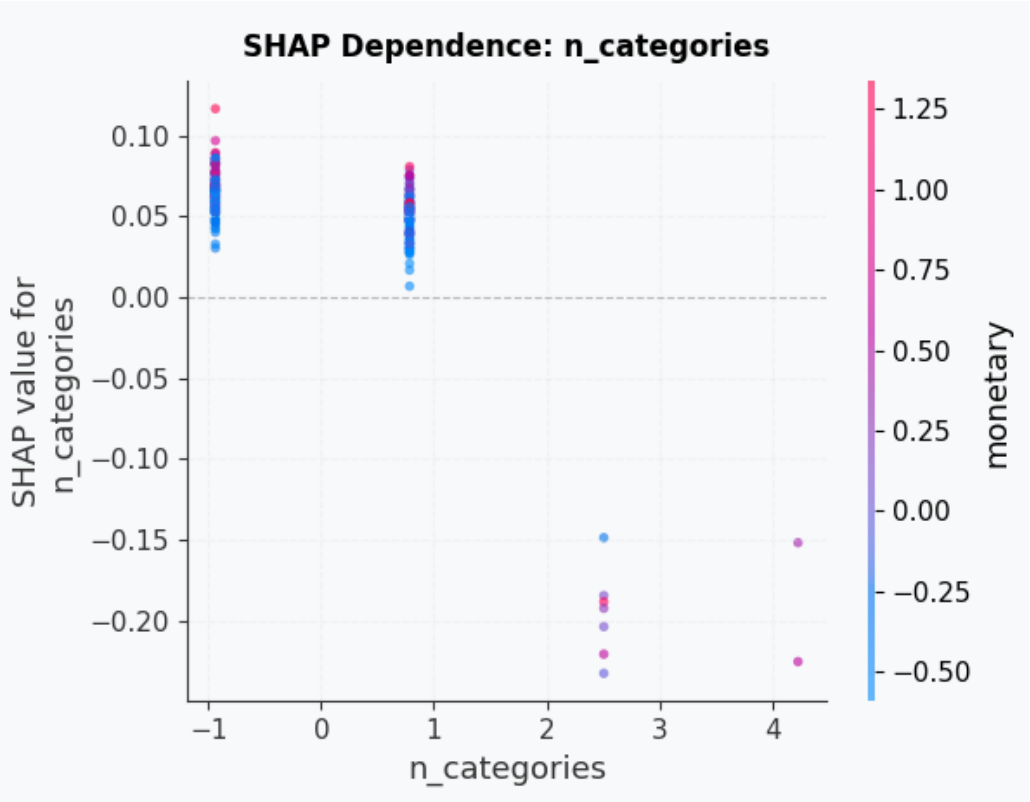
Fonte: elaborado pelo autor.

Figura 16 – Dependence plots da feature recency_days no SHAP (Random Forest)



Fonte: elaborado pelo autor.

Figura 17 – Dependence plots da feature n_categories no SHAP (Random Forest)



Fonte: elaborado pelo autor.

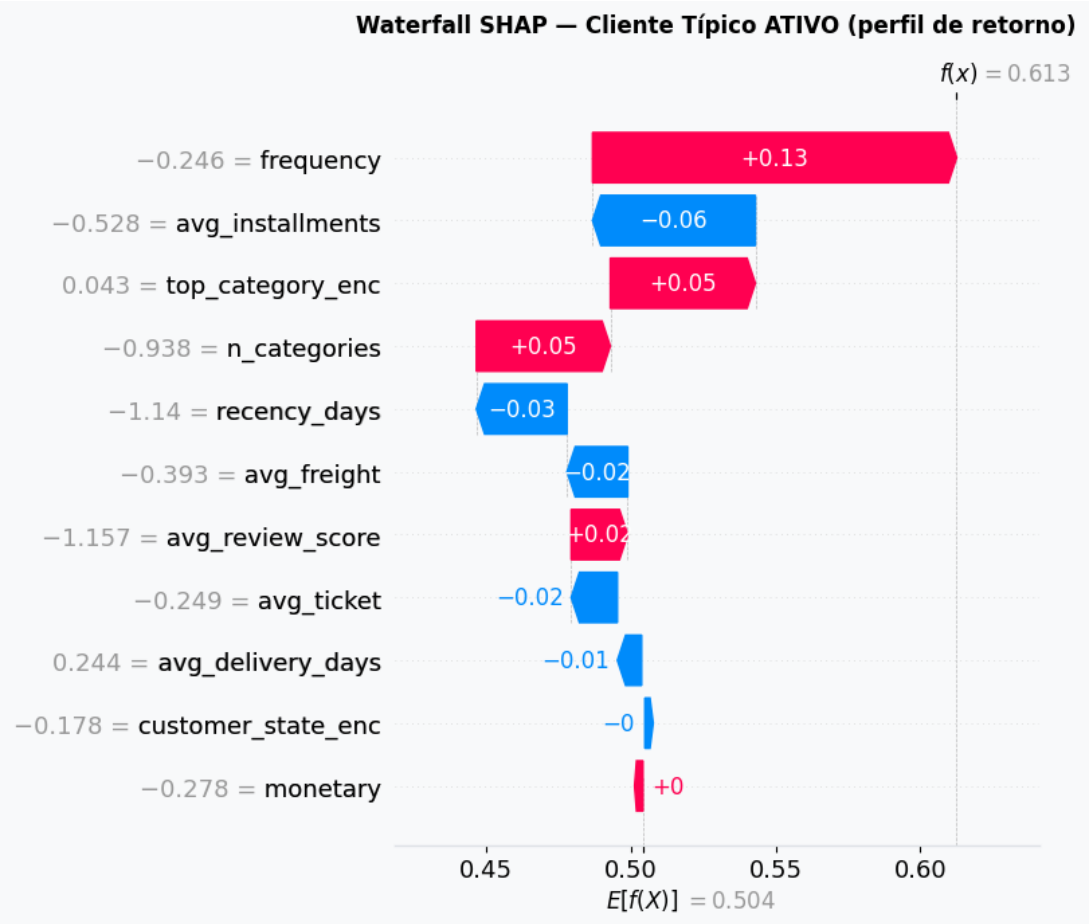
As Figuras 18 e 19 decompõem a predição individual dos clientes mais próximos do centroide de cada classe no espaço de features padronizado. Ambas partem do mesmo valor base, $\mathbb{E}[f(x)] = 0{,}504$, que reflete o balanceamento aplicado ao conjunto de treino conforme a Seção 4.5.

O cliente representativo da classe Churn (Figura 19) recebe $f(x) = 0{,}841$, valor consistente com sua classe real. A decomposição atribui o deslocamento principalmente à frequência (+0,12), à diversidade de categorias (+0,08) e ao parcelamento médio (+0,07), reproduzindo em nível individual a hierarquia agregada da Figura 13.

O cliente representativo da classe Ativo (Figura 18) recebe $f(x) = 0{,}613$, valor acima do limiar de 0,38 e que, portanto, o classifica incorretamente como Churn. Longe de invalidar a ilustração, esse resultado a torna mais informativa: o cliente mais próximo do centroide da classe Ativo apresenta frequência e diversidade de categorias abaixo da média da base, atributos que o modelo associa ao abandono, e as contribuições que o afastam do churn, o parcelamento médio ($-0{,}06$) e a recência ($-0{,}03$), são insuficientes para compensá-los. A figura expõe, em um caso concreto, a razão do Recall de 0,20 na classe Ativo reportado na Tabela 4: o perfil médio do cliente que retorna não é suficientemente distinto do perfil do cliente que abandona, limitação devida ao tamanho reduzido da classe minoritária e não à especificação do modelo. Esse é também o fundamento do critério de

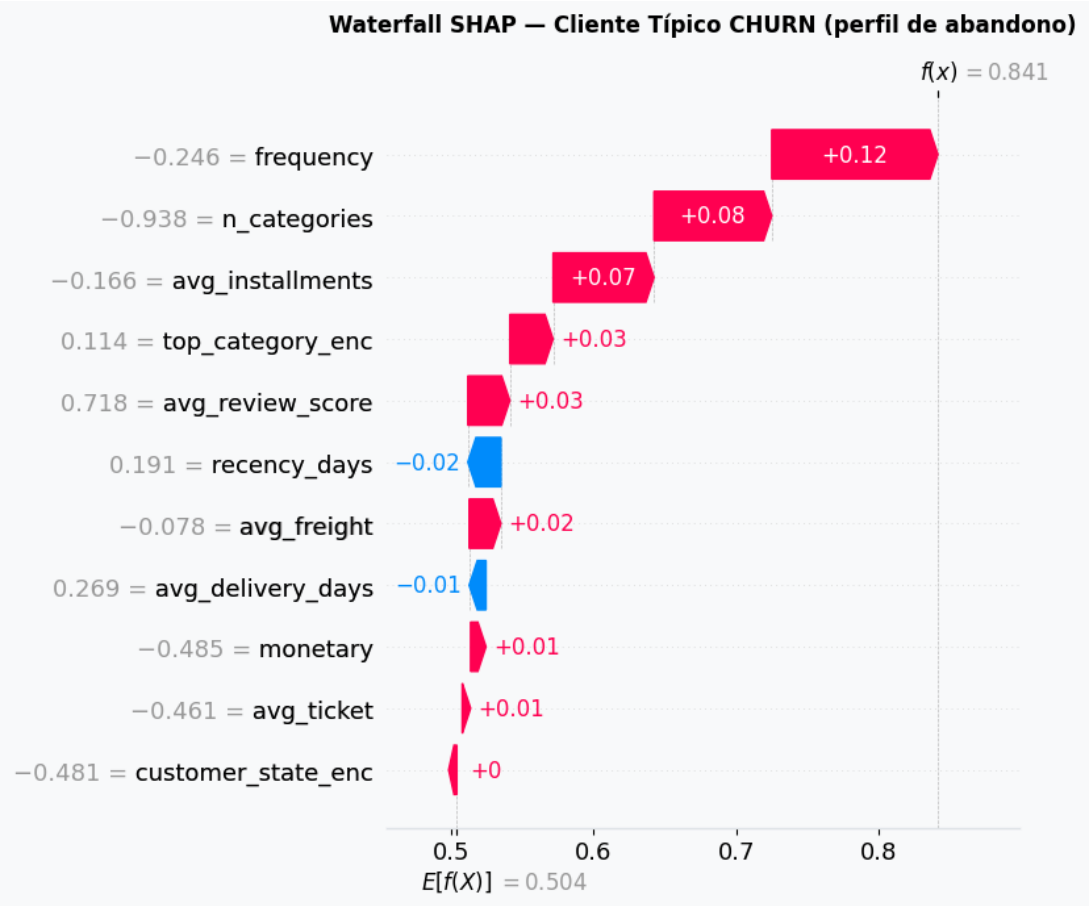
seleção adotado na Seção 4.3: uma vez que a decisão binária no limiar é estruturalmente limitada por esse regime amostral, o valor operacional do modelo reside na ordenação que ele produz, e não na classificação que dela resulta.

Figura 18 – Decomposição SHAP da predição para o cliente mais próximo do centroide da classe Ativo



Fonte: elaborado pelo autor.

Figura 19 – Decomposição SHAP da predição para o cliente mais próximo do centroide da classe Churn



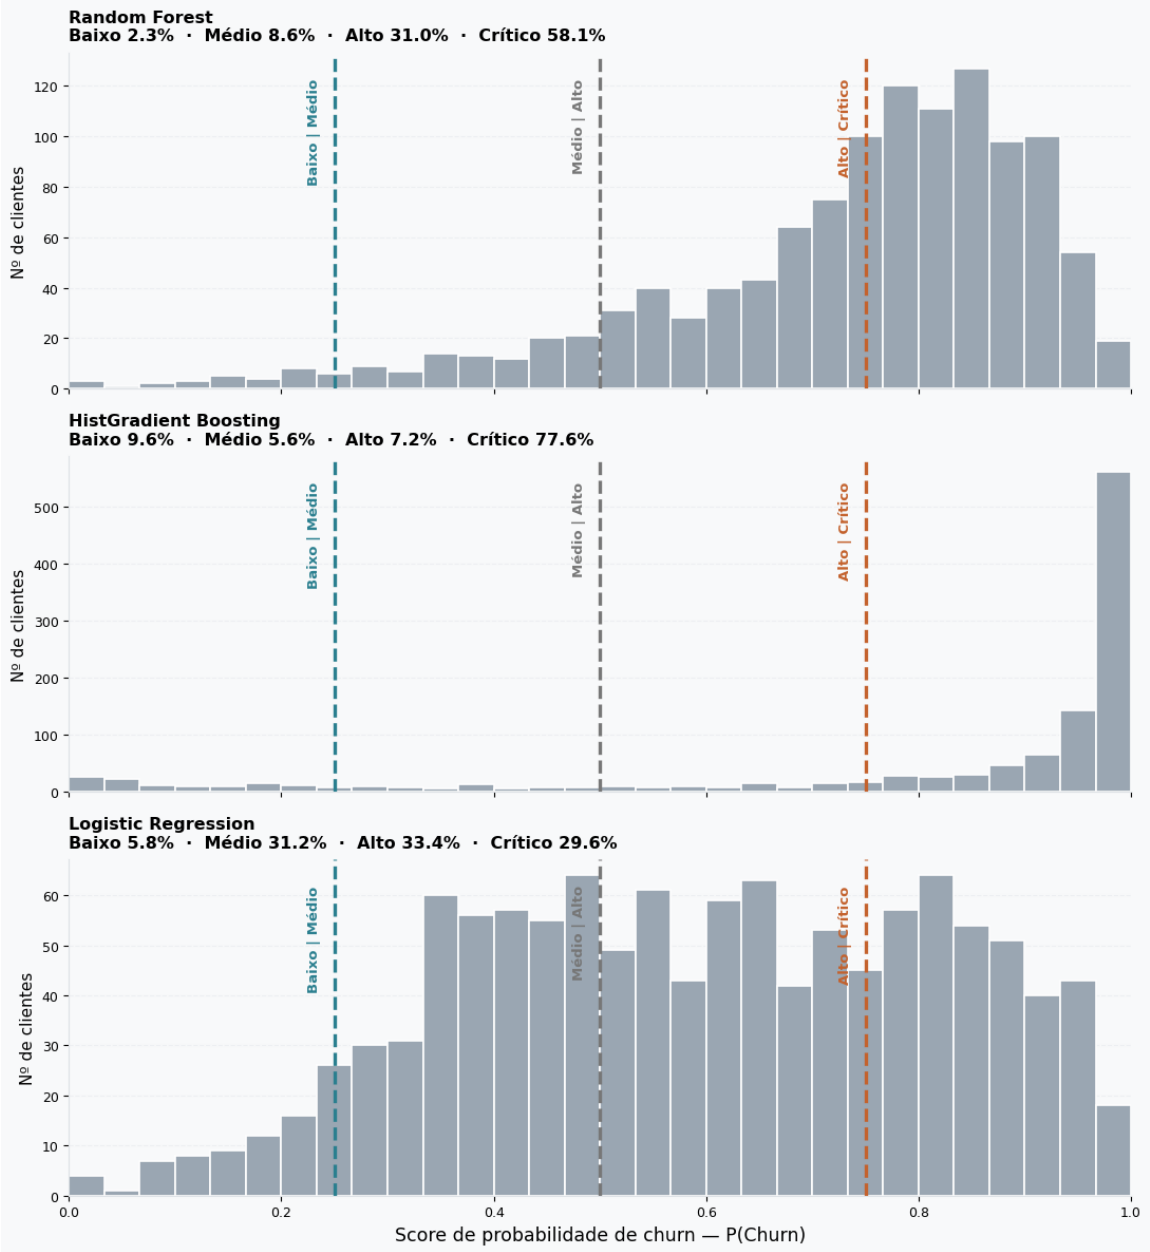
Fonte: elaborado pelo autor.

4.8 Segmentação de Risco e Recomendações de Negócio

Aplicado o modelo Random Forest à base completa de 1.178 clientes, cada cliente recebeu um score de probabilidade de churn, utilizado para classificação em quatro segmentos de risco (KOTLER; KELLER, 2016). Os limiares de 25%, 50% e 75% que delimitam os segmentos são cortes nominais da escala de probabilidade, adotados por interpretabilidade e não otimizados sobre os dados; sua adequação é aferida a posteriori pela taxa de churn observada em cada faixa. A Figura 20 apresenta a distribuição desses scores nos três modelos de melhor desempenho, com os limiares que delimitam os quatro segmentos, e a Tabela 8 detalha a distribuição e o perfil médio de cada segmento sob o modelo adotado.

A validade da segmentação é aferida pela taxa de churn efetivamente observada em cada faixa, isto é, pelo próprio rótulo que o modelo busca prever, e não por variáveis que integram seu conjunto de entrada. Cabe, antes, uma delimitação de escopo: a Tabela 8 descreve a base completa de 1.178 clientes, que inclui as observações utilizadas no ajuste do modelo, de modo que suas contagens refletem, em parte, o comportamento do classificador

Figura 20 – Distribuição dos scores de probabilidade de churn e limiares de segmentação nos três modelos



Fonte: elaborado pelo autor.

Nota: os três painéis aplicam os mesmos cortes nominais de 25%, 50% e 75%, que delimitam os segmentos de risco e não correspondem ao limiar de classificação de cada modelo (0,38 no Random Forest, 0,18 no HistGradient Boosting e 0,12 na Regressão Logística, conforme a Tabela 4). Os cortes de segmentação são uma escolha de negócio, aferida a posteriori pela taxa de churn observada em cada faixa; o limiar de classificação é parâmetro da regra de decisão binária, derivado das probabilidades out-of-fold conforme a Seção 3.5. Escopo: base completa de 1.178 clientes.

Tabela 8 – Segmentação de risco de churn e ações recomendadas por segmento

Segmento	Critério	Clientes	Recência Média	Ação Recomendada
Crítico	$P > 75\%$	685 (58,1%)	147,95 dias	Ação urgente: cupons e contato direto
Alto	$50\% < P \leq 75\%$	365 (31,0%)	95,78 dias	Ofertas e descontos personalizados
Médio	$25\% < P \leq 50\%$	101 (8,6%)	80,72 dias	Campanhas de reengajamento leve
Baixo	$P \leq 25\%$	27 (2,3%)	72,52 dias	Cross-sell e manutenção de engajamento

Fonte: elaborado pelo autor.

sobre dados já vistos. Sobre essa base, a taxa cresce de forma estritamente monotônica ao longo dos segmentos: 22,2% no Baixo, 79,2% no Médio, 98,1% no Alto e 99,9% no Crítico, com amplitude de 77,6 pontos percentuais entre os extremos.

A leitura com valor preditivo, contudo, é restrita ao conjunto de teste, cujos 236 clientes não participaram do ajuste. Nele, a progressão mantém-se na mesma direção (75,0% no Baixo e 99,3% no Crítico), com inversão entre as faixas Médio e Alto atribuível ao reduzido número de observações por segmento. Os dez clientes ativos do conjunto de teste distribuem-se em um no Baixo, um no Médio, sete no Alto e um no Crítico. O resultado operacionalmente relevante está, portanto, na exclusão da faixa Crítico: fora dela permanecem nove dos dez clientes Ativos, em 92 das 236 observações (39,0%), o que corresponde a um lift de 2,31 vezes sobre a proporção de Ativos no conjunto de teste (4,2%). A mesma métrica calculada sobre a base completa resulta em 2,34 vezes (49 dos 50 Ativos em 41,9% das observações), estabilidade que indica não haver, nesse recorte, ganho atribuível à memorização das observações de treino.

Registra-se, por transparência, que o recorte alternativo composto pelas duas faixas de menor risco não apresenta a mesma estabilidade: na base completa ele reúne 42 dos 50 clientes Ativos em 10,9% das observações, lift de 7,73 vezes, mas no conjunto de teste reúne apenas dois dos dez em 8,1%, lift de 2,48 vezes. A diferença decorre de os quarenta clientes ativos presentes no conjunto de treino situarem-se integralmente nessas duas faixas. Verifica-se, assim, que a estratificação separa risco fora da amostra, com magnitude da ordem de duas vezes, magnitude que deve ser lida com cautela em razão do número reduzido de clientes Ativos no conjunto de teste.

Com base nos scores de risco, propõem-se ações diferenciadas de retenção: clientes no segmento Baixo devem ser priorizados para cross-sell; no Médio, são candidatos a campanhas de reengajamento leve, como newsletters; o segmento Alto requer abordagem mais ativa, com descontos personalizados; e o segmento Crítico demanda ação urgente, com cupons de alto impacto antes do abandono definitivo. O princípio econômico orientador

é escalonar o investimento conforme o risco cresce, aplicação prática do argumento de Reichheld e Schefter (2000) de que, no comércio eletrônico, a rentabilidade do cliente depende da extensão do relacionamento, o que torna a retenção economicamente preferível à reaquisição. A leitura em cobertura fixa apresentada na Seção 4.3 fornece o parâmetro de dimensionamento dessas campanhas: abordar 35,6% dos clientes (fração medida no conjunto de teste, único recorte fora da amostra) é suficiente, sob o modelo adotado, para alcançar 90% dos clientes com propensão real ao retorno.

5 CONCLUSÃO

Este trabalho demonstrou que é possível construir modelos preditivos de churn com qualidade discriminativa relevante a partir de variáveis comportamentais simples, calculadas sobre dados transacionais reais de e-commerce brasileiro. O modelo selecionado atingiu ROC-AUC de 0,8106 na partição de referência, valor que deve ser lido em conjunto com duas estimativas convergentes obtidas por reamostragem: a validação cruzada de cinco folds sobre o conjunto de treino, conduzida com reamostragem interna a cada partição, resultou em 0,6814, e a média de trinta partições estratificadas independentes, em 0,6686 ($\pm$ 0,0831). A partição de referência situa-se, portanto, na faixa superior da distribuição amostral, e a expectativa realista de desempenho sob novas amostras desta mesma base é a indicada pelas duas últimas estimativas. Delimita-se, contudo, o alcance dessas estimativas: as trinta divisões são sorteios aleatórios do mesmo conjunto de clientes e do mesmo período, de modo que medem a sensibilidade do resultado ao particionamento, e não a generalização para períodos futuros. Esta última exigiria desenho de validação que respeitasse a ordem cronológica dos dados, conforme discutido entre as limitações. O pipeline proposto, com separação rigorosa de janelas temporais e estratégia combinada de balanceamento, mostrou-se eficaz para lidar com os principais desafios metodológicos do problema: data leakage, desbalanceamento extremo de classes e viés de avaliação.

Cabe registrar que a escolha do Random Forest não se apoiou na maximização de métricas de classificação binária. Sob as três métricas recomendadas por De la Cruz Huayanay, Bazán e Russo (2025), o modelo indicado seria o HistGradient Boosting, e a liderança isolada em MCC e Kappa de Cohen cabe à Regressão Logística. A adoção do Random Forest resulta de um procedimento em dois estágios, conduzido sem recurso ao conjunto de teste. O primeiro é de elegibilidade: o objetivo específico (4), declarado antes de qualquer experimento, requer a análise da importância de features do modelo escolhido por impureza de Gini, de modo que permanecem elegíveis apenas os estimadores que expõem essa medida de forma nativa. O segundo ordena os elegíveis pela natureza do entregável, uma vez que a operação de retenção proposta requer priorização de clientes em faixas de risco, e não decisão binária. Estimadas sobre as probabilidades out-of-fold do conjunto de treino, ambas as dimensões favorecem o Random Forest entre os elegíveis: apresenta a maior área sob a curva ROC fora da amostra (0,6784, contra 0,6739 do Extra Trees e 0,6702 do Gradient Boosting) e produz a segmentação mais utilizável, alocando 55,0% dos clientes na faixa Crítico e retendo 28 dos 40 clientes Ativos fora dela, isto é, 70,0% dos recuperáveis, ao custo de 45,0% de cobertura. A estratificação resultante é validada pela taxa de churn observada em cada faixa, crescente de 22,2% a 99,9% na base completa e preservada em direção no conjunto de teste.

Registra-se que o HistGradient Boosting apresenta a maior área sob a curva ROC fora da amostra entre os dez algoritmos avaliados (0,7323), de modo que sua exclusão decorre do requisito de interpretabilidade, e não de inferioridade na ordenação dos clientes por risco. A segmentação dele resultante é, contudo, substancialmente menos utilizável: sobre as mesmas probabilidades out-of-fold concentra 75,1% da base na faixa Crítico, consequência da aglomeração de seus scores junto do extremo superior da escala (mediana de 0,9621), e retém 22 dos 40 clientes Ativos fora dela, contra 28 do Random Forest. Permanece recomendado como alternativa, condicionado à calibração prévia de probabilidades. A Regressão Logística, embora produza a distribuição de scores mais uniforme entre as quatro faixas, exige 77,3% de cobertura para reter 35 dos 40 Ativos, o que evidencia que a dispersão da escala não constitui, isoladamente, critério suficiente. Registra-se, por fim, que o HistGradient Boosting apresenta ROC-AUC média superior em validação cruzada (0,7363 contra 0,6814) e estimativa reamostrada mais próxima da observada no hold-out (Δ de $-0{,}0252$ contra $-0{,}1293$, ambas negativas e, portanto, sem relação com sobreajuste), conforme a Tabela 4, vantagens que se estendem à captura em cobertura fixa e que reforçam, portanto, que sua exclusão se deve ao requisito de interpretabilidade e à concentração das faixas, e não ao desempenho de ordenação.

A análise de correlação de Spearman entre os rankings dos dez modelos revelou comportamento heterogêneo entre as métricas: o ranking por ROC-AUC apresenta correlação moderada com o de Kappa de Cohen (rho = 0,6485, única significativa ao nível de 5%, com p = 0,043) e com o de MCC (rho = 0,5515; p = 0,098), e correlação fraca com o de G-Mean (rho = 0,2970; p = 0,405), coeficientes estimados sobre dez modelos e, portanto, indicativos da tendência observada neste conjunto, e não estimativas populacionais precisas. A divergência é evidenciada de forma direta pelo próprio ranking, que produz três vencedores distintos entre os quatro critérios: Random Forest em ROC-AUC, HistGradient Boosting em G-Mean e Regressão Logística em MCC e Kappa. Esse resultado converge com a recomendação de De la Cruz Huayanay, Bazán e Russo (2025) contra o uso isolado da ROC-AUC como critério de seleção de modelos em cenários de dados desbalanceados, e reforça a importância de portfólios de métricas complementares em estudos de churn, prática ainda pouco adotada em trabalhos aplicados ao dataset Olist.

A análise de importância de features revelou que frequência de compras, recência e diversidade de categorias (n_categories) são os principais drivers preditivos do churn, respondendo por 47,26% da importância total do modelo na execução de referência. A estabilidade da hierarquia entre partições sustenta esse achado: em trinta divisões estratificadas independentes, frequency ocupou a primeira posição em todas, n_categories permaneceu entre as três primeiras em 29 e recency_days em 22. O destaque de n_categories, em empate técnico de importância com a recência, sugere que estratégias de cross-selling constituem mecanismo promissor de retenção proativa, resultado pouco explorado na literatura aplicada ao Olist e com implicação direta para o design de

campanhas de marketing. A comparação dos rankings por valores SHAP entre os três modelos de melhor desempenho, apresentada na Tabela 7, corrobora parcialmente essa hierarquia: a recência ocupa a segunda posição nos três estimadores e a frequência lidera nos dois modelos baseados em árvores, ao passo que a diversidade de categorias é confirmada entre as quatro primeiras por dois dos três modelos. Quanto à direção dos efeitos, os dependence plots apresentados na Seção 4.7.1 evidenciam relações não lineares: a frequência e a diversidade de categorias passam a contribuir negativamente para o churn a partir de três pedidos e de três categorias distintas, a recência mantém relação monotônica crescente com o risco, e o parcelamento médio elevado associa-se a maior propensão ao abandono. Lida sob a ótica da retenção, essa configuração caracteriza o perfil do cliente que volta a comprar: maior frequência (2,56 contra 2,08 pedidos), recência baixa e maior diversidade de categorias (1,80 contra 1,54), caracterização que deve ser interpretada como hipótese a confirmar em bases de maior volume, dada a dimensão da classe Ativo.

A validação da representatividade do balanceamento via PSI e KS-test indicou que, apesar de o subconjunto retido corresponder a apenas 10,6% da classe Churn completa (13,3% da parcela presente no conjunto de treino), oito das nove features numéricas preservaram a distribuição estatística original, com desvio marginal restrito à variável avg_installments (PSI = 0,1293, sem rejeição pelo teste KS). O resultado é compatível com a hipótese de que o modelo aprendeu padrões do Churn real, e não de uma versão sistematicamente distorcida da classe majoritária (HE; GARCIA, 2009), ressalvado que a potência do teste KS é limitada pelo tamanho do subconjunto retido e que a verificação alcança o undersampling da classe majoritária, não a expansão sintética da classe minoritária. Essa etapa de validação, não localizada nos estudos de churn aplicados ao dataset Olist consultados neste trabalho, constitui contribuição metodológica adicional.

As principais contribuições do trabalho incluem: a comparação sistemática de dez algoritmos aplicados ao e-commerce brasileiro com protocolo multi-métrica; a validação de um pipeline anti-leakage com janela temporal dupla; a comparação empírica de quatro estratégias de tratamento do desbalanceamento, incluindo análise de robustez em trinta divisões independentes; a validação estatística da representatividade do subconjunto efetivamente balanceado; a identificação de n_categories entre os três principais drivers preditivos do churn, pouco discutida na literatura aplicada ao Olist; a proposição de um critério de seleção de modelo baseado na captura em cobertura fixa, que neutraliza o tamanho do recorte e isola a qualidade da ordenação; e a documentação do efeito, sobre as estimativas de validação cruzada, da aplicação da reamostragem previamente ao particionamento, quantificado em queda de até 0,3251 na área sob a curva ROC para os algoritmos de maior capacidade.

O trabalho apresenta limitações decorrentes da filtragem de clientes com compra única, que reduz a base para 1.178 clientes, e da ausência de hiperparametrização

exaustiva. A limitação mais relevante refere-se ao tamanho da classe minoritária: com aproximadamente cinquenta clientes Ativos na base e dez no conjunto de teste, as métricas dependentes de limiar apresentam elevada sensibilidade a variações amostrais, e cada cliente capturado na análise de cobertura fixa equivale a dez pontos percentuais de Recall, de modo que diferenças de uma única unidade entre modelos não são conclusivas. A análise de robustez conduzida na Seção 4.2 quantifica esse efeito: em trinta divisões estratificadas independentes, a ROC-AUC variou entre 0,500 e 0,822, com média de 0,6686, o que indica que o desempenho da execução de referência situa-se na faixa superior da distribuição. Cabe registrar que o comportamento das métricas de classificação sob amostras pequenas é lacuna explicitamente apontada por De la Cruz Huayanay, Bazán e Russo (2025), cujo estudo empregou tamanhos de 5.000 e 10.000 observações, o que situa este trabalho fora do regime amostral em que aquelas recomendações foram estabelecidas. Registra-se ainda que nenhum dos estimadores de importância de features disponíveis resolve, isoladamente, a ordenação das variáveis nesse regime: a importância por permutação, calculada sobre um hold-out com dez instâncias da classe minoritária, apresenta desvios-padrão entre 44% e 93% das respectivas médias nas variáveis de média positiva, razão pela qual a estabilidade entre partições foi adotada como evidência. Limitação de natureza distinta refere-se ao alcance temporal da validação. O desenho adotado estabelece uma única fronteira cronológica, entre a janela de observação e a janela de predição, e todas as estimativas de desempenho derivam de reamostragens aleatórias do conjunto de clientes situado nessa fronteira. Tais reamostragens medem a sensibilidade dos resultados ao particionamento dos mesmos dados, e não constituem evidência de que o modelo preserve desempenho em períodos subsequentes: a robustez entre divisões aleatórias não deve ser interpretada como validade temporal ou externa. Demonstrá-la exigiria validação que respeitasse a ordem cronológica, por meio de múltiplos cortes temporais ou de esquema do tipo rolling-origin, em que o modelo é sucessivamente reajustado em janelas que avançam no tempo e avaliado no período imediatamente posterior a cada uma. Adicionalmente, o dataset Olist cobre o período de 2016 a 2018, o que pode não refletir integralmente a dinâmica atual do mercado brasileiro de e-commerce. Por fim, registra-se que ordenações entre features de importância muito próxima podem variar marginalmente entre versões das bibliotecas utilizadas (PEDREGOSA *et al.*, 2011), ainda que com semente fixa, razão pela qual as conclusões deste trabalho são formuladas sobre os padrões robustos a essas variações.

Trabalhos futuros podem explorar: (1) feature engineering com dados de sessão e comportamento de navegação; (2) modelos de churn em tempo real com processamento via streaming; (3) hiperparametrização via otimização bayesiana (Optuna) (IMANI *et al.*, 2025); (4) modelos de sobrevivência (Cox Proportional Hazards) para estimativa do tempo até o churn; (5) integração de SHAP por instância no contrato de serving da API para explicações personalizadas por cliente; (6) seleção de amostras típicas (clientes mais informativos) em substituição ao undersampling aleatório, conforme discutido na

Seção 4.6.1; (7) calibração de probabilidades (Platt scaling ou regressão isotônica) para os modelos de boosting, visando estabilizar o ponto de corte; (8) exposição do modelo como ferramenta via protocolo MCP (Model Context Protocol), permitindo que analistas de negócio consultem scores de risco e explicações SHAP em linguagem natural, integrando o modelo a fluxos conversacionais de apoio à decisão; (9) codificação alternativa das variáveis categóricas, por target encoding ou por agrupamento prévio de categorias de baixa frequência, em substituição ao Label Encoding adotado; e (10) reordenação do tratamento de ausências na construção das features, de modo que as estatísticas de imputação sejam estimadas após a divisão entre treino e teste, ajuste cujo efeito nesta base é nulo, conforme verificado na Seção 3.5, mas que elimina a dependência dessa propriedade empírica; e (11) validação de generalização temporal por múltiplos cortes cronológicos ou esquema rolling-origin, com reajuste sucessivo em janelas que avançam no tempo e avaliação no período imediatamente posterior a cada uma, única evidência capaz de sustentar afirmações sobre desempenho em períodos futuros.

REFERÊNCIAS

BATISTA, G. E. A. P. A.; PRATI, R. C.; MONARD, M. C. A study of the behavior of several methods for balancing machine learning training data. **ACM SIGKDD Explorations Newsletter**, v. 6, n. 1, p. 20–29, 2004.

BISHOP, C. M. Training with noise is equivalent to Tikhonov regularization. **Neural Computation**, v. 7, n. 1, p. 108–116, 1995.

BREIMAN, L. Random forests. **Machine Learning**, v. 45, n. 1, p. 5–32, 2001.

CAWLEY, G. C.; TALBOT, N. L. C. On over-fitting in model selection and subsequent selection bias in performance evaluation. **Journal of Machine Learning Research**, v. 11, p. 2079–2107, 2010.

CHAWLA, N. V. *et al.* SMOTE: synthetic minority over-sampling technique. **Journal of Artificial Intelligence Research**, v. 16, p. 321–357, 2002.

CHICCO, D.; JURMAN, G. The advantages of the Matthews correlation coefficient (MCC) over F1 score and accuracy in binary classification evaluation. **BMC Genomics**, v. 21, n. 6, p. 1–13, 2020.

COHEN, J. A coefficient of agreement for nominal scales. **Educational and Psychological Measurement**, v. 20, n. 1, p. 37–46, 1960.

DAL POZZOLO, A. *et al.* Calibrating probability with undersampling for unbalanced classification. *In*: IEEE SYMPOSIUM SERIES ON COMPUTATIONAL INTELLIGENCE, 2015, Cape Town. **Proceedings**. Piscataway: IEEE, 2015. p. 159–166.

DE LA CRUZ HUAYANAY, A.; BAZÁN, J. L.; RUSSO, C. M. Performance of evaluation metrics for classification in imbalanced data. **Computational Statistics**, v. 40, n. 3, p. 1447–1473, 2025.

FAWCETT, T. An introduction to ROC analysis. **Pattern Recognition Letters**, v. 27, n. 8, p. 861–874, 2006.

FRIEDMAN, J. H. Greedy function approximation: a gradient boosting machine. **Annals of Statistics**, v. 29, n. 5, p. 1189–1232, 2001.

HADDADI, S. J. *et al.* Customer churn prediction in imbalanced datasets with resampling methods: a comparative study. **Expert Systems with Applications**, v. 246, p. 123086, 2024.

HADDEN, J. *et al.* Computer assisted customer churn management: State-of-the-art and future trends. **Computers & Operations Research**, v. 34, n. 10, p. 2902–2917, 2007.

HANLEY, J. A.; MCNEIL, B. J. The meaning and use of the area under a receiver operating characteristic (ROC) curve. **Radiology**, v. 143, n. 1, p. 29–36, 1982.

HASTIE, T.; TIBSHIRANI, R.; FRIEDMAN, J. **The Elements of Statistical Learning**: Data Mining, Inference, and Prediction. 2. ed. New York: Springer, 2009.

HE, H.; GARCIA, E. A. Learning from imbalanced data. **IEEE Transactions on Knowledge and Data Engineering**, v. 21, n. 9, p. 1263–1284, 2009.

HUGHES, A. M. **Strategic Database Marketing**. Chicago: Probus Publishing Company, 1994.

IMANI, M. *et al.* Customer churn prediction: A systematic review of recent advances, trends, and challenges in machine learning and deep learning. **Machine Learning and Knowledge Extraction**, v. 7, p. 105, 2025.

KAUFMAN, S. *et al.* Leakage in data mining: Formulation, detection, and avoidance. **ACM Transactions on Knowledge Discovery from Data**, v. 6, n. 4, p. 1–32, 2012.

KOTLER, P.; KELLER, K. L. **Administração de Marketing**. 15. ed. São Paulo: Pearson, 2016.

KUBAT, M.; MATWIN, S. Addressing the curse of imbalanced training sets: one-sided selection. *In*: INTERNATIONAL CONFERENCE ON MACHINE LEARNING (ICML), 14., 1997, Nashville. **Proceedings**. San Francisco: Morgan Kaufmann, 1997. p. 179–186.

LANDIS, J. R.; KOCH, G. G. The measurement of observer agreement for categorical data. **Biometrics**, v. 33, n. 1, p. 159–174, 1977.

LEE, S. S. Noisy replication in skewed binary classification. **Computational Statistics & Data Analysis**, v. 34, n. 2, p. 165–191, 2000.

LUNDBERG, S. M.; LEE, S.-I. A unified approach to interpreting model predictions. **Advances in Neural Information Processing Systems**, v. 30, p. 4766–4777, 2017.

LUNDBERG, S. M. *et al.* From local explanations to global understanding with explainable AI for trees. **Nature Machine Intelligence**, v. 2, p. 56–67, 2020.

LUQUE, A. *et al.* The impact of class imbalance in classification performance metrics based on the binary confusion matrix. **Pattern Recognition**, v. 91, p. 216–231, 2019.

MANZOOR, A. *et al.* A review on machine learning methods for customer churn prediction and recommendations for business practitioners. **IEEE Access**, v. 12, p. 70434–70463, 2024.

MATTHEWS, B. W. Comparison of the predicted and observed secondary structure of T4 phage lysozyme. **Biochimica et Biophysica Acta (BBA) - Protein Structure**, v. 405, n. 2, p. 442–451, 1975.

MATUSZELAŃSKI, K.; KOPCZEWSKA, K. Customer churn in retail e-commerce business: spatial and machine learning approach. **Journal of Theoretical and Applied Electronic Commerce Research**, v. 17, n. 1, p. 165–198, 2022.

NESLIN, S. A. *et al.* Defection detection: Measuring and understanding the predictive accuracy of customer churn models. **Journal of Marketing Research**, v. 43, n. 2, p. 204–211, 2006.

NICULESCU-MIZIL, A.; CARUANA, R. Predicting good probabilities with supervised learning. *In*: INTERNATIONAL CONFERENCE ON MACHINE LEARNING, 22., 2005, Bonn. **Proceedings**. New York: ACM, 2005. p. 625–632.

OLIST. **Brazilian E-Commerce Public Dataset by Olist**. [S. l.]: Kaggle, 2018. Disponível em: https://www.kaggle.com/datasets/olistbr/brazilian-ecommerce. Acesso em: 22 fev. 2026.

PEDREGOSA, F. *et al.* Scikit-learn: Machine learning in Python. **Journal of Machine Learning Research**, v. 12, p. 2825–2830, 2011.

PRABADEVI, B.; SHALINI, R.; KAVITHA, B. R. Customer churning analysis using machine learning algorithms. **International Journal of Intelligent Networks**, v. 4, p. 145–154, 2023.

REICHHELD, F. F.; SCHEFTER, P. E-loyalty: your secret weapon on the web. **Harvard Business Review**, v. 78, n. 4, p. 105–113, 2000.

SAITO, T.; REHMSMEIER, M. The precision-recall plot is more informative than the ROC plot when evaluating binary classifiers on imbalanced datasets. **PLoS ONE**, v. 10, n. 3, p. e0118432, 2015.

SHAPLEY, L. S. A value for n-person games. *In*: KUHN, H. W.; TUCKER, A. W. (ed.). **Contributions to the Theory of Games II**. Princeton: Princeton University Press, 1953. p. 307–317.

TURBAN, E. *et al.* **Electronic Commerce 2018**: A Managerial and Social Networks Perspective. 9. ed. Cham: Springer, 2018.

UGULINO, F. **tcc-mba-usp**: código e saídas da execução de referência. [S. l.]: GitHub, 2026. Disponível em: https://github.com/ugulinofabiano/tcc-mba-usp. Acesso em: 16 ago. 2026.

VAFEIADIS, T. *et al.* A comparison of machine learning techniques for customer churn prediction. **Simulation Modelling Practice and Theory**, v. 55, p. 1–9, 2015.

Declaração de uso de INTELIGÊNCIA ARTIFICIAL, cuidados éticos e adequação à LGPD no TCC

MBA em Inteligência Artificial e Big Data – ICMC/USP

Aluno(a): _____

Título do TCC: _____

Declaro que, na elaboração deste Trabalho de Conclusão de Curso:

☐ **Não utilizei ferramentas de Inteligência Artificial Generativa como apoio à elaboração do TCC.**

☐ **Utilizei ferramentas de Inteligência Artificial Generativa como apoio à elaboração do TCC,**
conforme indicado abaixo.

1. **Como utilizei IA**: Marque as opções aplicáveis:

   ☐ Revisão, aprimoramento ou tradução de textos

   ☐ Busca, síntese ou organização de informações e literatura

   ☐ Geração, revisão ou depuração de código

   ☐ Análise, tratamento ou interpretação de dados

   ☐ Apoio à estruturação de ideias, metodologia ou solução

   ☐ Geração ou aprimoramento de imagens, gráficos ou outros conteúdos

   ☐ Outro: _____

   Ferramenta utilizadas: _____

   _____

2. **Nível de utilização**
   Marque a opção que melhor representa o uso de IA na elaboração do TCC:

   □ **Nível 1 – Apoio pontual**

   Uso em atividades específicas, como revisão de texto, tradução, esclarecimento de dúvidas ou sugestões pontuais.

   □ **Nível 2 – Apoio significativo**

   Uso recorrente em algumas etapas, como estruturação de conteúdo, programação, análise de dados ou desenvolvimento da solução.

   □ **Nível 3 – Apoio substancial**

   Uso relevante na geração ou desenvolvimento de conteúdos, códigos, análises ou outros elementos que integram o TCC.

3. **Declaração sobre cuidados Éticos e atendimento à LGPD**
   Cuidados éticos: quais foram os procedimentos éticos adotados em pesquisas envolvendo seres humanos, conforme as Normas e Diretrizes Regulamentadoras da Pesquisa Envolvendo Seres Humanos – Resolução C N S N° 466/2012, Norma Operacional 001/2013, Resolução C N S N° 510/2016 e Resolução C N S N° 674/2022 (para pesquisas nacionais). Em trabalhos nos quais pesquisas com seres humanos não foram realizadas, a seção deve ser preenchida com "Não se aplica" ou "Atende à Resolução C N S N° 510/2016".

   □ Não se aplica

   □ Cuidados adotados: _____

Quando o estudo envolver **coleta, uso ou análise de dados pessoais**, ainda que disponíveis publicamente, as pessoas autoras devem também indicar as medidas adotadas para proteção de dados pessoais, em conformidade com a **Lei Geral de Proteção de Dados Pessoais** – LGPD (Lei N° 13.709/2018), descrevendo, quando pertinente, os cuidados adotados no tratamento desses dados, tais como procedimentos de anonimização ou pseudonimização e medidas relacionadas ao armazenamento, acesso e segurança das informações. Imagens de pessoas menores de idade ou vulneráveis devem ser suprimidas ou devidamente anonimizadas no texto.

☐ Não se aplica

☐ Medidas adotadas: _____

---

4. **Declaração de responsabilidade**

Declaro que revisei, validei criticamente e assumo a responsabilidade pelos conteúdos produzidos com o auxílio de ferramentas de Inteligência Artificial.

Declaro, ainda, que compreendo plenamente, sou capaz de explicar e defender todo o conteúdo apresentado neste TCC, bem como que observei os princípios éticos e os requisitos de proteção de dados aplicáveis

Data: ____ / ____ / _____

Assinatura do(a) aluno(a): _____